# Sistem Atribusi Dampak Berita terhadap Abnormal Return Emiten BEI Berbasis Event Extraction dan Explainable Machine Learning

## Proposal Tugas Akhir

Oleh

**SEBASTIAN ALBERN NUGROHO**
**18223074**



**PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI**
**SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA**
**INSTITUT TEKNOLOGI BANDUNG**
**16 Oktober 2026**

## LEMBAR PENGESAHAN

**Sistem Atribusi Dampak Berita terhadap Abnormal Return Emiten BEI Berbasis Event Extraction dan Explainable Machine Learning**

# Proposal Tugas Akhir


Oleh

**SEBASTIAN ALBERN NUGROHO**
**18223074**

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung


Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 16 Oktober 2026

Pembimbing

Dr. Nur Ulfa Maulidevi, S.T., M.Sc.

NIP. 197603092008012010

# PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Proposal Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan Proposal Tugas Akhir.
3. Isi proposal ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa dokumen laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 16 Oktober 2026

SEBASTIAN ALBERN NUGROHO
NIM: 18223074

# PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan Proposal Tugas Akhir ini, saya telah menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu. Berikut adalah rincian penggunaan AI dalam penulisan tesis ini.

| No. | Jenis | Alat Bantu | Tingkat | Tempat |
|---|---|---|---|---|
| 1 | Memeriksa ejaan dan tata bahasa | Grammarly | Tinggi | Semua bab |
| 2 | Pembuatan teks | Microsoft Copilot | Sedang | Bab II dan Sub-bab III.2 hal. 34 |
| 3 | Pembuatan grafik, gambar, atau ilustrasi | Tidak ada | Tidak ada | Tidak ada |
| 4 | Pencarian informasi atau referensi | … | … | … |
| 5 | Menjelaskan definisi, konsep, gambar, tabel, atau topik tertentu | … | … | … |
| 6 | Penyusunan kode program | … | … | … |
| 7 | Penyusunan formula atau perhitungan matematis | … | … | … |
| 8 | Analisis data | … | … | … |
| 9 | Penyusunan kesimpulan atau rekomendasi | … | … | … |
| 10 | Lainnya (jelaskan) | … | … | … |

Bandung, 16 Oktober 2026

SEBASTIAN ALBERN NUGROHO
NIM: 18223074

# DAFTAR ISI


LEMBAR PENGESAHAN . . . . . iii
PERNYATAAN ORISINALITAS . . . . . v
PERNYATAAN PENGGUNAAN AI . . . . . vii
DAFTAR ISI . . . . . ix
DAFTAR GAMBAR . . . . . xi
DAFTAR TABEL . . . . . xiii
DAFTAR PERSAMAAN . . . . . xv
DAFTAR ALGORITMA . . . . . xvii
DAFTAR KODE PROGRAM . . . . . xix
DAFTAR SINGKATAN . . . . . xxi
DAFTAR SIMBOL . . . . . xxiii

**BAB I PENDAHULUAN** . . . . . **1**
I.1 Latar Belakang . . . . . 1
I.2 Rumusan Masalah . . . . . 4
I.3 Tujuan . . . . . 5
I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah . . . . . 5
I.5 Hipotesis Tugas Akhir . . . . . 6
I.6 Metodologi . . . . . 7
I.7 Sistematika Penulisan . . . . . 9

**BAB II STUDI LITERATUR** . . . . . **11**
II.1 Pasar Modal Indonesia sebagai Objek Kajian . . . . . 11
II.1.1 IHSG dan Indeks LQ45 . . . . . 11
II.1.2 Klasifikasi Sektor IDX-IC dan Indeks Sektoral . . . . . 12
II.1.3 Batas Auto Rejection dan Suspensi Perdagangan . . . . . 13
II.1.4 Berita sebagai Sumber Informasi bagi Pasar . . . . . 13
II.2 Efisiensi Pasar dan *Event Study* . . . . . 14
II.2.1 Hipotesis Pasar Efisien . . . . . 14
II.2.2 Tahapan *Event Study* . . . . . 14
II.2.3 *Return*, *Abnormal Return*, dan *Cumulative Abnormal Return* 15
II.3 Model *Return* yang Diharapkan . . . . . 16
II.3.1 Model Rata-Rata Konstan dan Model *Market-Adjusted* . . 17
II.3.2 *Market Model* . . . . . 17
II.3.3 Model Indeks Dua Faktor . . . . . 18
II.4 Pemrosesan Teks Berita untuk Analisis Saham . . . . . 20
II.4.1 Sentimen dan Jenis Peristiwa . . . . . 20
II.4.2 Klasifikasi Berbasis Aturan dan Supervisi Lemah . . . . . 20
II.4.3 TF-IDF dengan Logistic Regression dan SVM . . . . . 21
II.4.4 Transformer, BERT, dan IndoBERT . . . . . 22
II.4.5 Anotasi dan Kesepakatan Antaranotator . . . . . 22
II.5 *Gradient Boosting* dan XGBoost . . . . . 23
II.6 SHAP sebagai Metode Penjelasan Prediksi . . . . . 24
II.7 Metrik Evaluasi dan Uji Signifikansi . . . . . 25

II.7.1 Metrik Klasifikasi . . . . . 25
II.7.2 Metrik Regresi . . . . . 26
II.7.3 Uji Signifikansi Selisih Kinerja . . . . . 26
II.8 Penelitian Terkait . . . . . 27
II.8.1 Penelitian Berbasis Berita di Indonesia . . . . . 27
II.8.2 *Event Study* di Bursa Efek Indonesia . . . . . 28
II.8.3 Peristiwa dari Teks dan *Abnormal Return* . . . . . 28
II.8.4 *Explainable Machine Learning* untuk Prediksi Saham . . . 30
II.8.5 Posisi Penelitian . . . . . 30

**BAB III ANALISIS MASALAH . . . . . 33**
III.1 Analisis Kondisi Saat Ini . . . . . 33
III.2 Analisis Kebutuhan . . . . . 33
III.2.1 Identifikasi Masalah Pengguna . . . . . 33
III.2.2 Kebutuhan Fungsional . . . . . 33
III.2.3 Kebutuhan Nonfungsional . . . . . 34
III.3 Analisis Pemilihan Solusi . . . . . 34
III.3.1 Alternatif Solusi . . . . . 34
III.3.2 Analisis Penentuan Solusi . . . . . 34

**BAB IV DESAIN KONSEP SOLUSI . . . . . 37**

**BAB V RENCANA SELANJUTNYA . . . . . 39**

**DAFTAR PUSTAKA . . . . . 41**

**Lampiran A *SOURCE CODE* . . . . . 47**
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik . . . 47
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak . . . . . 48

# Daftar Gambar

II.1 Linimasa jendela estimasi dan jendela peristiwa yang digunakan dalam penelitian ini . . . . . 15

# Daftar Tabel

II.1 Sektor dan kode indeks sektoral IDX-IC . . . . . 12
II.2 Perbandingan model *return* yang diharapkan . . . . . 19
II.3 Perbandingan komponen penelitian terdahulu dengan penelitian ini . 30

# DAFTAR PERSAMAAN


II.1 *Return* harian emiten . . . . . 15
II.2 *Abnormal return* . . . . . 16
II.3 *Cumulative abnormal return* . . . . . 16
II.4 Arah *abnormal return* . . . . . 16
II.5 *Abnormal return* model *market-adjusted* . . . . . 17
II.6 *Market model* . . . . . 17
II.7 Model indeks dua faktor . . . . . 18
II.8 *Abnormal return* model dua faktor . . . . . 19
II.9 Simpangan baku residual pada jendela estimasi . . . . . 19
II.10 Bobot TF-IDF . . . . . 21
II.11 Cohen's kappa . . . . . 23
II.12 Prediksi XGBoost . . . . . 24
II.13 Fungsi objektif XGBoost . . . . . 24
II.14 Model penjelasan aditif SHAP . . . . . 24
II.15 Nilai Shapley . . . . . 25
II.16 F1 per kelas dan F1-macro . . . . . 26
II.17 *Mean absolute error* . . . . . 26
II.18 *Root mean squared error* . . . . . 26
II.19 Statistik uji McNemar . . . . . 27

# DAFTAR ALGORITMA

# DAFTAR *LISTING*

A.1 Binary search code . . . . . 47

# DAFTAR SINGKATAN

| Singkatan | Deskripsi | Pemakaian pertama kali |
|---|---|---|
| AI | *Artificial Intelligence* | 1 |
| CNN | *Convolutional Neural Network* | 2 |
| GPU | *Graphics Processing Unit* | 14 |

# DAFTAR SIMBOL

| Notasi | Deskripsi | Pemakaian pertama kali |
|---|---|---|
| $\alpha$ | Koefisien bobot untuk *loss function*, tingkat signifikansi statistik | 75 |
| $\beta$ | Koefisien bobot untuk *Binary Cross-Entropy loss* | 75 |
| $\lambda$ | Koefisien bobot untuk CTC *loss*, parameter regularisasi | 75 |
| $\theta$ | Parameter model *neural network* | 75 |
| $\sigma$ | Deviasi standar | 75 |
| $\mu$ | Rata-rata (*mean*) | 75 |
| $\epsilon$ | *Token blank*/kosong dalam CTC, konstanta kecil untuk stabilitas numerik | 75 |
| $\Delta$ | Delta (selisih/perubahan nilai) | 75 |
| $\pi$ | *Alignment path* dalam CTC | 75 |
| $\pi_t$ | *Token* pada *timestep* $t$ dalam *alignment path* | 76 |
| $\nabla$ atau $\partial$ | Operator gradien atau turunan parsial | 75 |
| $\sum$ | Operator penjumlahan | 75 |
| $\prod$ | Operator perkalian | 75 |
| $\int$ | Operator integral | 75 |
| argmax | Argumen yang memaksimalkan fungsi | 76 |
| $\sim$ | Terdistribusi menurut | 75 |
| $\rightarrow$ | Menuju atau konvergen ke | 75 |
| $\mathcal{L}$ | Fungsi *loss* (kerugian) | 75 |
| $\mathcal{L}_{total}$ | Total *loss function* | 75 |
| $\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$ | *Adversarial loss* | 75 |
| $\mathcal{L}_{reconstruction}$ | *Reconstruction loss* | 75 |
| $\mathcal{L}_{L1}$ | L1 *loss* (*Mean Absolute Error*) | 75 |
| $\mathcal{L}_{L2}$ | L2 *loss* (*Mean Squared Error*) | 75 |
| $\mathcal{L}_{CTC}$ | CTC (*Connectionist Temporal Classification*) *loss* | 75 |
| $\mathcal{L}_{perceptual}$ | *Perceptual loss* | 75 |

| | | |
|---|---|---|
| $\mathcal{L}_{pixel}$ | *Pixel-wise loss* | 75 |
| $\mathcal{L}_{BCE}$ | *Binary Cross-Entropy loss* | 75 |
| $\mathcal{L}_{GAN}$ | GAN *loss* | 75 |
| $\mathcal{L}_{cycle}$ | *Cycle consistency loss* | 75 |
| $G$ | *Generator* dalam GAN | 75 |
| $D$ | *Discriminator* dalam GAN | 75 |
| $G(z)$ | *Output* dari *generator* dengan *input* $z$ | 75 |
| $D(x)$ | *Output* dari *discriminator* dengan *input* $x$ | 75 |
| $G_{A \to B}$ | *Generator* dari domain $A$ ke $B$ | 75 |
| $G_{B \to A}$ | *Generator* dari domain $B$ ke $A$ | 75 |
| $V(D, G)$ | Fungsi nilai (*value function*) dalam GAN | 75 |
| $x$ | Sampel data asli, *input* citra | 75 |
| $y$ | Label atau *ground truth*, kondisi dalam *conditional GAN* | 75 |
| $z$ | *Noise vector* atau representasi laten | |
| $\mathbb{E}$ | Ekspektasi atau nilai harapan | 75 |
| $p_{data}$ | Distribusi data asli | 75 |
| $p_z$ | Distribusi *prior* (*noise*) | 75 |
| $p(y\|x)$ | Probabilitas bersyarat *output* $y$ *given input* $x$ | 75 |
| $p_t(\pi_t\|x)$ | Probabilitas *token* pada *timestep* $t$ | |
| $\mathcal{B}$ | Fungsi penciutan (*collapse function*) dalam CTC | 75 |
| $\mathcal{B}^{-1}$ | Fungsi invers penciutan dalam CTC | 75 |
| $T$ | Jumlah *timestep* atau panjang *sequence* | |
| $\|x - G(y)\|_1$ | L1 *distance* antara *ground truth* dan *generated image* | 75 |
| $\|x - G(y)\|_2$ | L2 *distance* antara *ground truth* dan *generated image* | 75 |
| $N \times N$ | Ukuran *patch* dalam PatchGAN | |
| $d$ | Cohen's $d$ (*effect size*) | 75 |
| $n$ | Jumlah sampel | 75 |
| $p$ | *p-value* (nilai probabilitas statistik) | 75 |

| | | |
|---|---|---|
| $r$ | Koefisien korelasi | 75 |
| $R^2$ | Koefisien determinasi | |
| $O(n)$ | Notasi Big-O untuk kompleksitas linear | 75 |
| $O(n^2)$ | Notasi Big-O untuk kompleksitas kuadratik | 75 |

# BAB I

# PENDAHULUAN

## I.1 Latar Belakang

Pergerakan harga saham suatu emiten di Bursa Efek Indonesia (BEI) tidak selalu disebabkan oleh berita yang berkaitan langsung dengan perusahaan tersebut. Harga suatu emiten dapat turun karena Indeks Harga Saham Gabungan (IHSG) sedang melemah, karena sektor industrinya sedang tertekan, atau karena terdapat berita yang secara khusus menyangkut perusahaan, seperti kasus hukum, pergantian direksi, atau rilis laporan keuangan. Dalam kajian keuangan, dampak suatu peristiwa terhadap nilai perusahaan umumnya diukur melalui *event study*. Pendekatan ini memanfaatkan asumsi bahwa informasi baru akan tercermin pada harga saham, sehingga dampaknya dapat diukur dari *abnormal return*, yaitu selisih antara *return* aktual dan *return* yang diharapkan berdasarkan kondisi pasar (Brown & Warner, 1985; MacKinlay, 1997). Bagi investor dan analis, pemisahan antara pengaruh pasar, pengaruh sektor, dan pengaruh berita menjadi penting karena menentukan bagaimana suatu informasi seharusnya ditanggapi.

Selain pengaruh pasar secara umum, pergerakan sektor juga perlu diperhitungkan dalam menghitung *return* yang diharapkan. Sejak 25 Januari 2021, BEI menerapkan klasifikasi IDX Industrial Classification (IDX-IC) yang menggantikan JASICA dan menyediakan sebelas indeks sektoral, seperti IDXENERGY, IDXBASIC, IDXFINANCE, dan IDXTECHNO (Sidik, 2021). Ketersediaan indeks sektoral ini memungkinkan *return* yang diharapkan dihitung tidak hanya dari pergerakan IHSG, tetapi juga dari pergerakan sektor emiten. Xiang (1993) menunjukkan bahwa faktor industri menjelaskan rata-rata 6,7% variasi residual *market model* pada data harian dan 11,5% pada data mingguan. Penelitian tersebut juga menyimpulkan bahwa apabila *return* saham sebenarnya mengikuti model dua faktor (pasar dan industri), inferensi yang hanya didasarkan pada *market model* menjadi tidak valid. Dengan demikian, koreksi terhadap pengaruh sektor diperlukan agar bagian *return* yang dikaitkan dengan berita tidak tercampur dengan pergerakan sektor.

Penelitian di Indonesia yang memanfaatkan berita untuk memahami pergerakan saham sejauh ini umumnya berfokus pada analisis sentimen. Attar (2024) menggunakan IndoBERT untuk mengklasifikasikan sentimen 2.857 berita saham dan memperoleh akurasi 0,78, kemudian mengukur korelasinya dengan pergerakan harga per sektor dengan korelasi Pearson tertinggi sebesar 0,389 pada sektor *basic materials*. Alamsyah dkk. (2025) menganalisis 192.582 berita keuangan Indonesia periode 2018 sampai 2023 dan menemukan bahwa korelasi sentimen dengan harga meningkat dari 0,26 pada tingkat perusahaan menjadi 0,30 pada tingkat industri dan 0,43 pada klaster emiten yang sering muncul bersama di berita. Kusuma dkk. (2026) menggabungkan sentimen IndoBERT dari 9.819 berita CNBC Indonesia dengan data harga untuk mengklasifikasikan tren harga lima emiten LQ45 menggunakan LSTM. Ketiga penelitian tersebut menunjukkan bahwa berita berbahasa Indonesia memiliki keterkaitan dengan pergerakan harga saham. Namun, informasi berita yang digunakan masih terbatas pada sentimen, sedangkan targetnya berupa harga atau tren harga mentah.

Penggunaan sentimen saja memiliki keterbatasan karena sentimen hanya menggambarkan nada berita, bukan jenis peristiwa yang terjadi. Berita mengenai direktur yang ditetapkan sebagai tersangka korupsi dan berita mengenai laba yang turun sesuai ekspektasi analis sama-sama bernada negatif, tetapi keduanya merupakan peristiwa yang berbeda. Zhou dkk. (2021) memandang peristiwa korporasi sebagai penggerak pergerakan saham dan membangun model deteksi peristiwa dari berita sebagai dasar strategi *trading*, berbeda dengan model yang langsung memanfaatkan fitur teks dan sentimen. Dolphin dkk. (2026) juga melakukan *event study* terhadap besar *abnormal return* tanpa memperhatikan arahnya pada laporan 8-K dan menunjukkan bahwa kategori peristiwa yang lebih rinci dapat membedakan peristiwa korporasi yang secara ekonomi berbeda. Selain itu, penggunaan harga mentah sebagai target membuat pengaruh berita bercampur dengan pengaruh pasar dan sektor. Akibatnya, model dapat mempelajari pola yang sebenarnya berasal dari pergerakan IHSG atau sektor, bukan dari berita.

Penelitian di Indonesia yang sudah menggunakan *abnormal return* juga masih memiliki keterbatasan. Elli (2025) menguji hubungan sentimen 23.406 *tweet* dengan *abnormal return* saham IDX30 pada periode Juli sampai Desember 2023 menggunakan uji kausalitas Granger. Sumber data yang digunakan berupa *tweet* dan analisisnya bersifat statistik, bukan model prediksi untuk setiap berita. Di sisi lain, beberapa *event study* di BEI meneliti satu atau dua jenis peristiwa yang ditentukan secara manual, misalnya *stock split* pada periode 2015 sampai 2019 (Fauzi & Mutasowifin,

2021) serta *right issue* dan *stock split* pada periode 2022 sampai 2024 (Sudirman dkk. 2026). Pada penelitian Sudirman dkk. (2026), *abnormal return* dihitung sebagai selisih *return* saham terhadap *return* IHSG, sehingga pengaruh sektor belum dikoreksi. Pendekatan tersebut juga belum dapat digunakan untuk menilai berita baru secara otomatis karena peristiwa dan tanggalnya harus ditentukan terlebih dahulu oleh peneliti.

Pada tingkat global, otomatisasi deteksi peristiwa dari teks dan pengukuran *abnormal return* sudah mulai dilakukan. Kargarzadeh dkk. (2026) menggunakan *large language model* (LLM) sebagai *teacher* yang kemudian didistilasi menjadi *classifier* untuk memberi 17 label peristiwa pada 4,57 juta artikel berita, lalu mengukur *abnormal return* yang disesuaikan dengan beta pada sekitar 3.000 saham Amerika Serikat. Dolphin dkk. (2026) juga memanfaatkan LLM untuk memberi label 119 jenis peristiwa pada sekitar 293.000 laporan 8-K. Kedua penelitian tersebut berfokus pada pasar Amerika Serikat, dan *abnormal return* pada penelitian Kargarzadeh dkk. (2026) hanya dikoreksi terhadap pengaruh pasar melalui beta. Penggunaan LLM juga memiliki risiko tersendiri. Gao dkk. (2025) menemukan bahwa LLM menunjukkan kecenderungan *look-ahead* yang tinggi pada periode data pelatihannya, tetapi kecenderungan tersebut hampir hilang setelah batas waktu data pelatihan. Hal ini menunjukkan bahwa kinerja prediksi LLM pada data historis dapat dipengaruhi oleh informasi mengenai hasil yang sebenarnya sudah terjadi.

Selain akurasi, keluaran model prediksi juga perlu dapat dijelaskan agar pengguna memahami faktor yang mendasari suatu prediksi. SHAP (*SHapley Additive exPlanations*) memberikan nilai kontribusi setiap fitur terhadap suatu prediksi tertentu (Lundberg & Lee, 2017), sehingga dapat digunakan untuk menjelaskan keluaran model berbasis pohon seperti XGBoost (Chen & Guestrin, 2016). Ruan dan Jiang (2025) telah menggabungkan sentimen FinBERT dengan indikator teknikal pada model XGBoost dan menggunakan SHAP untuk menjelaskan prediksi pergerakan harga jangka pendek saham S&P 500. Namun, fitur berita yang digunakan masih berupa sentimen dan targetnya masih berupa pergerakan harga, sehingga SHAP belum dapat memisahkan kontribusi berita dari kontribusi pasar. Di sisi lain, prediksi arah pergerakan harga dari berita memiliki tingkat kesulitan yang tinggi. Luss dan d'Aspremont (2015) menemukan bahwa pada prediksi *return* intrahari dari berita, arah *return* tidak dapat diprediksi menggunakan teks maupun *return* historis, tetapi besarnya pergerakan dapat diprediksi dan fitur teks memberikan kinerja yang lebih baik dibandingkan *return* historis saja. Oleh karena itu, model perlu dievaluasi tidak hanya dari ketepatan arah, tetapi juga dari estimasi besarnya *abnormal return*.

Berdasarkan kondisi tersebut, penelitian ini mengusulkan sistem yang menghubungkan berita, jenis peristiwa, emiten, dan pergerakan harga dalam satu *pipeline*. Sistem mendeteksi emiten yang disebutkan dalam berita menggunakan kamus kode, nama, dan alias emiten, kemudian mengklasifikasikan jenis peristiwa menggunakan IndoBERT yang di-*fine-tune* (Wilie dkk. 2020). Fitur berita, seperti jenis peristiwa, sentimen, keterlibatan emiten, intensitas, dan waktu terbit, digabungkan dengan fitur pasar yang tersedia sebelum berita terbit. Target yang diprediksi adalah *abnormal return* yang dikoreksi terhadap IHSG dan indeks sektor, sedangkan model yang digunakan adalah XGBoost untuk memprediksi arah dan besar *abnormal return*, dengan SHAP sebagai penjelasan setiap prediksi. Seluruh *pipeline* dirancang tanpa LLM generatif untuk menjaga *reproducibility*, menghindari risiko *look-ahead bias*, dan menjaga transparansi rantai penjelasan. Berdasarkan penelusuran literatur yang telah dilakukan, belum ditemukan penelitian yang secara bersamaan mendeteksi jenis peristiwa dari berita berbahasa Indonesia secara otomatis, mengestimasi *abnormal return* emiten BEI setelah mengendalikan IHSG dan indeks sektor, serta menjelaskan kontribusi setiap faktor pada tingkat berita.

## I.2 Rumusan Masalah

Penelitian yang memanfaatkan berita saham berbahasa Indonesia masih menggunakan sentimen sebagai satu-satunya informasi dari berita dan harga mentah sebagai target, sehingga dampak berita tidak dapat dipisahkan dari pengaruh pasar dan sektor. Sementara itu, pengukuran *abnormal return* di BEI masih dilakukan melalui *event study* dengan peristiwa yang ditentukan secara manual. Akibatnya, model yang dilatih dengan target harga mentah dapat mempelajari pola yang berasal dari pergerakan IHSG atau sektor, bukan dari berita, sehingga hasilnya dapat menyesatkan ketika digunakan untuk menilai dampak suatu berita. Berdasarkan penelusuran literatur yang telah dilakukan, belum ditemukan sistem yang memberikan estimasi terukur mengenai keterkaitan suatu berita berbahasa Indonesia dengan pergerakan emiten BEI setelah pengaruh IHSG dan sektor dikendalikan. Penelitian ini mengusulkan sistem berbasis klasifikasi jenis peristiwa, target *abnormal return* dua faktor, dan penjelasan SHAP untuk menjawab permasalahan tersebut. Berdasarkan uraian tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Sejauh mana jenis peristiwa yang diekstraksi secara otomatis dari berita berbahasa Indonesia memberikan informasi tambahan dibandingkan sentimen dalam memprediksi arah dan besar *abnormal return* emiten BEI?
2. Bagaimana perbedaan kinerja model dan pola kontribusi fitur yang dihasilkan SHAP ketika target yang digunakan adalah *abnormal return* yang dikoreksi IHSG dan indeks sektor dibandingkan dengan *return* mentah?

3. Seberapa baik *classifier* jenis peristiwa berbasis IndoBERT dibandingkan dengan aturan kata kunci serta TF-IDF dengan Logistic Regression atau SVM dalam mengklasifikasikan jenis peristiwa pada berita saham berbahasa Indonesia?
4. Faktor berita dan kondisi pasar apa saja yang memberikan kontribusi terbesar terhadap estimasi *abnormal return* berdasarkan analisis SHAP?

## I.3 Tujuan

Tujuan penelitian ini adalah sebagai berikut.

1. Membangun *pipeline* yang menerima teks atau URL berita dan menghasilkan emiten terdampak, jenis peristiwa, arah *abnormal return* beserta probabilitasnya, estimasi besar *abnormal return*, kandidat emiten yang berpotensi terkena *spillover*, serta penjelasan faktor penyumbang prediksi.
2. Menyusun dataset berita saham berbahasa Indonesia yang berlabel jenis peristiwa, termasuk *test set* emas yang dilabeli secara manual oleh dua anotator.
3. Membandingkan kinerja aturan kata kunci, TF-IDF dengan Logistic Regression atau SVM, dan IndoBERT dalam mengklasifikasikan jenis peristiwa.
4. Mengukur kontribusi jenis peristiwa terhadap prediksi *abnormal return* melalui *ablation study* yang membandingkan model dengan fitur sentimen saja, model dengan sentimen dan jenis peristiwa, serta model dengan seluruh fitur.
5. Membandingkan hasil pemodelan dengan target *abnormal return* dan target *return* mentah dari sisi kinerja prediksi dan pola kontribusi fitur.
6. Menyajikan penjelasan prediksi menggunakan SHAP, baik secara global maupun untuk setiap berita.

Keberhasilan penelitian ditentukan oleh beberapa kriteria. Pertama, *pipeline* dapat dijalankan secara utuh dari input berita hingga keluaran prediksi dan penjelasan SHAP melalui prototipe antarmuka web. Kedua, kualitas anotasi *test set* emas mencapai nilai Cohen's kappa sekurang-kurangnya 0,6. Ketiga, seluruh model dievaluasi pada data uji periode 2025 yang tidak digunakan dalam pelatihan maupun penyetelan, dan dibandingkan dengan model *baseline* menggunakan metrik yang telah ditetapkan. Keempat, *ablation study* dan perbandingan target dapat dilaporkan beserta uji signifikansi selisih kinerjanya. Hasil yang menunjukkan bahwa jenis peristiwa tidak menambah kinerja model tetap dianggap sebagai temuan yang sah dan dilaporkan apa adanya.

## I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah

Ruang lingkup penelitian ini mencakup emiten konstituen LQ45 atau IDX80 yang akan ditetapkan setelah audit ketersediaan data, dengan mengikuti daftar konstituen

pada setiap periode untuk menghindari *survivorship bias*. Periode data yang digunakan adalah 2021 sampai 2025, menyesuaikan dengan ketersediaan indeks sektoral IDX-IC sejak Januari 2021. Karena estimasi parameter *abnormal return* membutuhkan data historis sebelum berita, sampel berita direncanakan mulai sekitar Juli 2021. Data berita dikumpulkan dari dua sampai tiga portal berita keuangan nasional, sedangkan data harga saham, IHSG, dan indeks sektoral diperoleh dari sumber publik. Jenis peristiwa dibatasi pada enam kategori utama, yaitu hukum atau korupsi, laporan keuangan, pergantian direksi, kebijakan pemerintah, aksi korporasi, dan operasional, ditambah kategori pergerakan harga dan kategori lainnya.

Penelitian ini menggunakan beberapa asumsi. *Abnormal return* diasumsikan sebagai proksi dampak berita, yaitu bagian dari *return* emiten yang tidak dapat dijelaskan oleh pergerakan IHSG dan indeks sektornya. Waktu terbit berita diasumsikan tercatat dengan akurat hingga satuan menit, sehingga berita yang terbit setelah perdagangan ditutup sekitar pukul 16.00 WIB atau pada hari libur dapat dialokasikan ke hari bursa berikutnya. Data harga yang digunakan diasumsikan telah disesuaikan terhadap *stock split* dan dividen. Parameter *return* yang diharapkan diasumsikan dapat diestimasi dari data historis sebelum berita terbit.

Penelitian ini memiliki beberapa batasan. Sistem tidak dimaksudkan untuk menyatakan bahwa suatu berita secara mutlak menyebabkan perubahan harga, melainkan memberikan estimasi keterkaitan statistik berdasarkan pola historis. Berita yang hanya melaporkan pergerakan harga dikeluarkan dari data pelatihan model *abnormal return* untuk mencegah *data leakage*. Analisis *spillover* dibatasi pada relasi sektor, grup konglomerasi, dan kemunculan bersama di berita karena data relasi rantai pasok antaremiten di Indonesia terbatas. Untuk peristiwa berskala sektor, seperti kebijakan pemerintah yang berlaku pada satu sektor, *abnormal return* juga dihitung dengan koreksi IHSG saja karena koreksi sektor dapat menghapus dampak peristiwa tersebut. Sampel yang jatuh pada hari suspensi tidak digunakan, dan keterbatasan akibat mekanisme auto rejection juga dicatat sebagai batasan. Input berupa URL hanya didukung untuk portal yang sama dengan sumber dataset, dan seluruh *pipeline* tidak menggunakan LLM generatif.

### I.5 Hipotesis Tugas Akhir

Hipotesis penelitian ini disusun berdasarkan beberapa premis. Premis pertama, jenis peristiwa yang berbeda dapat diikuti oleh besar *abnormal return* yang berbeda (Dolphin dkk. 2026). Premis kedua, sentimen hanya menggambarkan nada berita sehingga berita dengan sentimen yang sama dapat berasal dari peristiwa yang berbe-

da. Premis ketiga, faktor industri menjelaskan sebagian variasi *return* yang tidak tertangkap oleh *market model* (Xiang, 1993). Premis keempat, arah *return* sulit diprediksi dari teks, sedangkan besarnya pergerakan lebih dapat diprediksi (Luss & d'Aspremont, 2015). Dengan premis tersebut, informasi jenis peristiwa diharapkan dapat menambah kemampuan model dalam memprediksi *abnormal return*, walaupun kinerja prediksi arah yang moderat tetap wajar dalam domain ini.

Hipotesis penelitian ini adalah sebagai berikut.

> **H1a:** Model yang menggunakan fitur sentimen dan jenis peristiwa menghasilkan F1-macro dan AUC yang lebih tinggi secara signifikan dibandingkan model yang hanya menggunakan fitur sentimen dalam memprediksi arah *abnormal return* pada data uji periode 2025. Signifikansi selisih diuji menggunakan uji McNemar atau *bootstrap*.

> **H1b:** Model yang menggunakan fitur sentimen dan jenis peristiwa menghasilkan MAE yang lebih rendah secara signifikan dibandingkan model yang hanya menggunakan fitur sentimen dalam memprediksi besar *abnormal return* pada data uji periode 2025. Signifikansi selisih diuji menggunakan *bootstrap*.

Hipotesis tambahan yang diuji adalah sebagai berikut.

> **H2:** *Classifier* IndoBERT yang melalui tahap pemanasan dengan dataset topik keuangan menghasilkan F1-macro yang lebih tinggi dibandingkan aturan kata kunci dalam mengklasifikasikan jenis peristiwa pada *test set* emas.

## I.6 Metodologi

Tahapan penelitian yang dilakukan adalah sebagai berikut.

1. **Investigasi masalah dan studi literatur.** Mengidentifikasi permasalahan serta mempelajari penelitian mengenai *event study*, *abnormal return*, analisis berita saham di Indonesia, deteksi peristiwa dari teks, IndoBERT, *gradient boosting*, dan SHAP. Penelusuran literatur dilakukan melalui mesin pencari web, OpenAlex, dan Garuda dengan kata kunci seperti *abnormal return* berita, IndoBERT saham, dan *news event abnormal return* Indonesia. Penelusuran melalui Google Scholar dan Digilib ITB akan dilengkapi secara manual.
2. **Analisis masalah dan kebutuhan.** Menganalisis kondisi penelitian saat ini berdasarkan hasil studi literatur, mengaudit ketersediaan dan kualitas data

berita serta data harga, dan menentukan kebutuhan sistem, kategori peristiwa, serta kriteria keberhasilan.

3. **Perancangan solusi.** Merancang arsitektur *pipeline* secara bertahap dari alur umum hingga komponen yang lebih rinci, meliputi alur data, pelabelan, perhitungan *abnormal return*, fitur, model, eksperimen, dan prototipe, menggunakan diagram alur dan diagram komponen.
4. **Pengumpulan data.** Menyusun tabel referensi emiten, alias, sektor IDX-IC, dan konstituen indeks per periode, kemudian mengumpulkan berita dari portal terpilih dan mengunduh data harga yang telah disesuaikan untuk emiten, IHSG, dan indeks sektoral.
5. **Prapemrosesan data.** Membersihkan teks berita, menghapus duplikat, mendeteksi emiten dengan kamus alias, menentukan hari peristiwa (H0) berdasarkan waktu terbit, serta membentuk sampel berupa pasangan berita dan emiten.
6. **Pelabelan jenis peristiwa.** Menyusun pedoman anotasi, membuat *test set* emas sebanyak 300 sampai 500 berita yang dilabeli dua anotator dengan target Cohen's kappa sekurang-kurangnya 0,6, serta menyusun data latih sebanyak 500 sampai 800 berita dari pra-label aturan kata kunci yang diperiksa dan dikoreksi secara manual.
7. **Perhitungan *abnormal return*.** Mengestimasi parameter $\alpha$, $\beta_1$, dan $\beta_2$ dengan regresi OLS pada jendela estimasi H-130 sampai H-11, kemudian menghitung *abnormal return* pada H0, *cumulative abnormal return* pada H0 sampai H+1, dan arah *abnormal return* berdasarkan ambang standar deviasi residual.
8. **Pengembangan model.** Melakukan *fine-tuning* IndoBERT secara dua tahap untuk klasifikasi jenis peristiwa, mengekstraksi fitur berita dan fitur pasar yang hanya menggunakan data sampai H-1, serta melatih XGBoost *classifier* untuk arah dan XGBoost *regressor* untuk besar *abnormal return*. Data dibagi secara kronologis, yaitu Juli 2021 sampai 2023 untuk pelatihan, 2024 untuk validasi, dan 2025 untuk pengujian.
9. **Eksperimen dan evaluasi.** Melakukan perbandingan metode klasifikasi jenis peristiwa, *ablation study* fitur, perbandingan target *abnormal return* dengan *return* mentah, serta perbandingan dengan model *baseline*. Evaluasi menggunakan accuracy dan F1-macro untuk klasifikasi jenis peristiwa, F1-macro dan AUC untuk arah, MAE dan RMSE untuk besar *abnormal return*, serta *bootstrap* atau uji McNemar untuk signifikansi selisih kinerja.
10. **Analisis interpretabilitas.** Menganalisis nilai SHAP secara global dan pada studi kasus per berita, kemudian memeriksa kesesuaiannya dengan intuisi domain.

11. **Pengembangan prototipe.** Membangun antarmuka web sederhana yang menerima teks atau URL berita dan menampilkan hasil prediksi beserta penjelasannya. Implementasi menggunakan bahasa Python dengan pustaka trafilatura untuk ekstraksi artikel, yfinance untuk data harga, statsmodels untuk regresi, model indobenchmark/indobert-base-p1 dari Hugging Face yang dilatih di Google Colab, XGBoost, SHAP, dan Streamlit untuk antarmuka.
12. **Penarikan kesimpulan.** Menyusun kesimpulan berdasarkan hasil evaluasi dan pengujian hipotesis, serta memberikan saran untuk penelitian selanjutnya.

## I.7 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini adalah sebagai berikut.

1. **Bab I Pendahuluan** berisi latar belakang, rumusan masalah, tujuan, ruang lingkup, asumsi, batasan masalah, hipotesis tugas akhir, metodologi, dan sistematika penulisan.
2. **Bab II Studi Literatur** berisi pembahasan mengenai *event study* dan *abnormal return*, model *return* yang diharapkan, analisis sentimen dan deteksi peristiwa dari berita, IndoBERT, *gradient boosting*, SHAP, serta penelitian terdahulu yang relevan.
3. **Bab III Analisis Masalah** berisi analisis kondisi penelitian saat ini, analisis kebutuhan sistem, analisis sumber data, serta analisis alternatif pendekatan, termasuk perbandingan pendekatan dengan dan tanpa LLM.
4. **Bab IV Desain Konsep Solusi** berisi rancangan *pipeline*, rancangan pelabelan, rancangan perhitungan *abnormal return*, rancangan fitur dan model, rancangan eksperimen, serta rancangan prototipe.
5. **Bab V Rencana Selanjutnya** berisi rencana pelaksanaan, jadwal kegiatan, kebutuhan yang perlu disiapkan, serta risiko dan mitigasinya.
6. **Daftar Pustaka** berisi seluruh referensi yang digunakan dalam penyusunan laporan tugas akhir.
7. **Lampiran** berisi dokumen pendukung, seperti pedoman anotasi, struktur dataset, konfigurasi eksperimen, dan hasil evaluasi tambahan.

# BAB II

# STUDI LITERATUR

Bab ini membahas landasan teori dan penelitian terdahulu yang digunakan untuk menyusun sistem atribusi dampak berita terhadap *abnormal return* emiten BEI. Pembahasan dimulai dari karakteristik pasar modal Indonesia yang menjadi objek kajian, kemudian dilanjutkan dengan teori efisiensi pasar dan *event study* sebagai dasar pengukuran dampak berita. Setelah itu, bab ini menjelaskan model *return* yang diharapkan, metode pemrosesan teks berita, IndoBERT, *gradient boosting*, SHAP, serta metrik evaluasi yang digunakan. Bagian terakhir meninjau penelitian terdahulu yang relevan untuk menunjukkan posisi penelitian ini terhadap solusi yang sudah ada.

## II.1 Pasar Modal Indonesia sebagai Objek Kajian

### II.1.1 IHSG dan Indeks LQ45

Bursa Efek Indonesia (BEI) menyediakan sejumlah indeks yang menggambarkan pergerakan harga saham secara agregat. Indeks Harga Saham Gabungan (IHSG) merupakan indeks yang paling umum digunakan sebagai gambaran kondisi pasar secara keseluruhan, sehingga dalam penelitian ini IHSG diperlakukan sebagai faktor pasar. Selain IHSG, BEI juga menyusun indeks dengan jumlah konstituen yang lebih kecil, seperti IDX80, LQ45, dan IDX30. Menurut panduan metodologi BEI, LQ45 mengukur kinerja harga dari 45 saham yang memiliki likuiditas tinggi dan kapitalisasi pasar *free float* besar, serta didukung oleh fundamental dan kepatuhan perusahaan yang baik (Bursa Efek Indonesia, 2024). Konstituen LQ45 dipilih dari konstituen IDX80, sedangkan konstituen IDX80 dipilih dari saham konstituen IHSG yang memenuhi kriteria umum, antara lain telah tercatat lebih dari enam bulan, termasuk dalam 150 saham dengan nilai transaksi terbesar di pasar reguler selama 12 bulan terakhir, dan memiliki rasio *free float* minimal 10%.

Daftar konstituen indeks tersebut tidak bersifat tetap. Panduan metodologi yang berlaku sejak Maret 2024 menetapkan evaluasi mayor pada bulan Januari, April, Juli, dan Oktober, dengan hari efektif pada hari bursa pertama bulan Februari, Mei,

Tabel II.1 Sektor dan kode indeks sektoral IDX-IC (Sidik, 2021)

| No | Sektor | Kode Indeks |
|---|---|---|
| 1 | Energi | IDXENERGY |
| 2 | Barang Baku | IDXBASIC |
| 3 | Perindustrian | IDXINDUST |
| 4 | Barang Konsumer Primer | IDXNONCYC |
| 5 | Barang Konsumer Non-Primer | IDXCYCLIC |
| 6 | Kesehatan | IDXHEALTH |
| 7 | Keuangan | IDXFINANCE |
| 8 | Properti dan Real Estat | IDXPROPERT |
| 9 | Teknologi | IDXTECHNO |
| 10 | Infrastruktur | IDXINFRA |
| 11 | Transportasi dan Logistik | IDXTRANS |

Agustus, dan November (Bursa Efek Indonesia, 2024). Selain evaluasi rutin, BEI juga dapat melakukan evaluasi insidental apabila terjadi perubahan jumlah saham yang signifikan, *delisting*, atau informasi penting lain mengenai konstituen. Bagi penelitian ini, perubahan konstituen tersebut berarti daftar emiten tidak dapat diambil dari satu periode saja. Apabila hanya daftar konstituen terbaru yang digunakan, sampel akan didominasi oleh emiten yang bertahan sampai akhir periode sehingga hasil analisis dapat mengandung *survivorship bias*. Oleh karena itu, cakupan emiten perlu mengikuti daftar konstituen pada setiap periode berita.

### II.1.2 Klasifikasi Sektor IDX-IC dan Indeks Sektoral

Sejak 25 Januari 2021, BEI menggunakan IDX Industrial Classification (IDX-IC) untuk mengelompokkan perusahaan tercatat dan sekaligus meluncurkan sebelas indeks sektoral (Sidik, 2021). IDX-IC menggantikan klasifikasi JASICA yang sebelumnya digunakan sejak 1996. Berbeda dengan JASICA yang mengelompokkan perusahaan berdasarkan kegiatan ekonominya, IDX-IC menggunakan prinsip eksposur pasar, dan setiap perusahaan diklasifikasikan secara unik ke dalam satu subindustri (Intan, 2021). Daftar sektor dan kode indeks sektoral IDX-IC ditunjukkan pada Tabel II.1.

Keberadaan indeks sektoral memungkinkan setiap emiten dipasangkan dengan indeks sektor tempat emiten tersebut diklasifikasikan. Dengan pasangan ini, pergerakan harga emiten dapat dibandingkan tidak hanya dengan pergerakan pasar secara umum, tetapi juga dengan pergerakan sektornya. Hal ini relevan karena emiten dalam satu sektor sering terpapar faktor yang sama, misalnya harga komoditas untuk sektor energi dan barang baku. Karena indeks sektoral IDX-IC baru tersedia sejak awal 2021, data sektor sebelum tanggal tersebut tidak dapat digunakan secara kon-

sisten. Kondisi ini menjadi dasar pemilihan periode data 2021 sampai 2025 pada penelitian ini.

### II.1.3 Batas Auto Rejection dan Suspensi Perdagangan

BEI menerapkan mekanisme *auto rejection*, yaitu pengamanan yang membatasi kenaikan maupun penurunan harga saham yang terlalu tajam dalam satu hari perdagangan (Shaid, 2025). Saat harga mencapai batas atas, terjadi *auto rejection* atas (ARA), sedangkan saat harga mencapai batas bawah, terjadi *auto rejection* bawah (ARB). Pesanan dengan harga di luar batas tersebut ditolak secara otomatis oleh sistem perdagangan. Besaran batas ini tidak selalu sama sepanjang waktu. Sebagai contoh, pada 8 April 2025 batas ARB diseragamkan menjadi 15% untuk seluruh rentang harga, sedangkan sebelumnya batas tersebut bervariasi menurut rentang harga saham (Shaid, 2025).

Mekanisme ini berpengaruh terhadap pengukuran dampak berita. Apabila suatu berita sangat negatif dan saham emiten langsung terkena ARB, *return* pada hari tersebut tertahan pada batas bawah sehingga dampak yang sebenarnya belum seluruhnya tercermin pada hari yang sama. Sisa reaksi harga kemudian dapat muncul pada hari bursa berikutnya. Kondisi serupa dapat terjadi ketika saham emiten dihentikan sementara perdagangannya (suspensi), karena harga pada hari tersebut tidak terbentuk melalui transaksi normal. Oleh karena itu, pengukuran dampak berita pada penelitian ini tidak hanya menggunakan *abnormal return* pada hari peristiwa, tetapi juga akumulasinya sampai hari berikutnya, serta mengeluarkan sampel yang jatuh pada hari suspensi.

### II.1.4 Berita sebagai Sumber Informasi bagi Pasar

Berita merupakan salah satu saluran utama yang membawa informasi baru kepada investor. Tetlock (2007) mengukur isi kolom harian *Wall Street Journal* dan menemukan bahwa tingkat pesimisme media yang tinggi diikuti oleh tekanan turun pada harga pasar, kemudian harga kembali ke nilai fundamentalnya. Penelitian tersebut juga menemukan bahwa pesimisme yang sangat tinggi atau sangat rendah diikuti oleh volume perdagangan yang tinggi. Pada tingkat saham individual, Chan (2003) membandingkan saham yang memiliki berita publik dengan saham yang mengalami pergerakan harga serupa tanpa berita. Hasilnya menunjukkan adanya *drift* setelah berita, terutama setelah berita buruk, sedangkan pergerakan harga ekstrem tanpa berita cenderung berbalik arah.

Kedua temuan tersebut menunjukkan bahwa keberadaan dan isi berita berkaitan dengan cara harga saham bereaksi. Namun, berita yang beredar di portal keuangan tidak

semuanya membawa informasi baru mengenai emiten. Sebagian berita hanya melaporkan pergerakan harga yang sudah terjadi, misalnya berita mengenai saham yang melonjak atau menjadi pemberat IHSG pada hari tertentu. Berita seperti ini tidak menjelaskan peristiwa yang mendasari pergerakan harga, tetapi justru memuat hasil pergerakan itu sendiri. Apabila berita seperti ini digunakan untuk melatih model, model dapat mempelajari informasi yang seharusnya belum tersedia saat prediksi dilakukan. Karena itu, pembedaan antara berita yang memuat peristiwa dan berita yang hanya melaporkan harga menjadi bagian penting dalam penyusunan data penelitian ini.

## II.2 Efisiensi Pasar dan *Event Study*

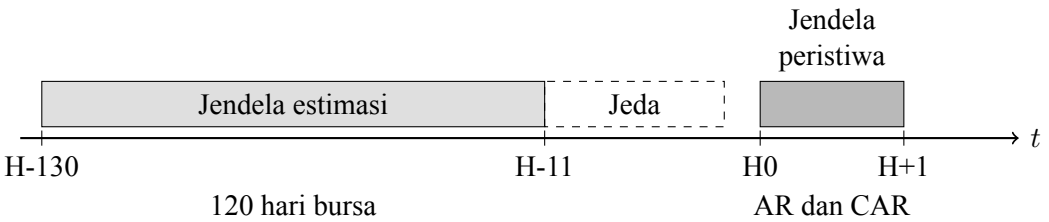
### II.2.1 Hipotesis Pasar Efisien

Dasar teoretis pengukuran dampak berita terhadap harga saham adalah hipotesis pasar efisien. Fama (1970) mendefinisikan pasar yang efisien sebagai pasar yang harganya selalu mencerminkan seluruh informasi yang tersedia. Fama membagi pengujian efisiensi pasar menjadi tiga bentuk, yaitu bentuk lemah yang berkaitan dengan informasi harga historis, bentuk setengah kuat yang berkaitan dengan kecepatan penyesuaian harga terhadap informasi publik, dan bentuk kuat yang berkaitan dengan informasi yang hanya dimiliki kelompok tertentu. Pengujian bentuk setengah kuat inilah yang paling dekat dengan penelitian ini, karena berita merupakan informasi publik yang diterima pasar pada waktu tertentu.

Pengujian bentuk setengah kuat umumnya dilakukan dengan mengamati perilaku harga di sekitar suatu peristiwa. Fama dkk. (1969) meneliti penyesuaian harga saham terhadap pengumuman *stock split*, sedangkan Ball dan Brown (1968) meneliti reaksi harga terhadap pengumuman laba akuntansi. Kedua penelitian tersebut menjadi dasar berkembangnya metode *event study*. Bagi penelitian ini, hipotesis pasar efisien memberikan alasan mengapa reaksi harga yang tidak dapat dijelaskan oleh kondisi pasar dapat dikaitkan dengan informasi baru. Meskipun demikian, penelitian ini tidak menguji apakah BEI efisien atau tidak, melainkan memanfaatkan reaksi harga tersebut sebagai proksi dampak berita.

### II.2.2 Tahapan *Event Study*

*Event study* merupakan metode untuk mengukur pengaruh suatu peristiwa ekonomi terhadap nilai perusahaan dengan memanfaatkan data harga saham di sekitar peristiwa tersebut (MacKinlay, 1997). Metode ini bertumpu pada asumsi bahwa pasar bersikap rasional, sehingga pengaruh suatu peristiwa akan segera tercermin pada harga saham. Menurut MacKinlay (1997), *event study* secara umum diawali




Gambar II.1 Linimasa jendela estimasi dan jendela peristiwa yang digunakan dalam penelitian ini

dengan mendefinisikan peristiwa yang diteliti dan periode pengamatannya, kemudian menentukan kriteria pemilihan sampel. Setelah itu, peneliti memilih model *return* normal, mengestimasi parameternya, menghitung *abnormal return*, menguji signifikansinya, dan menginterpretasikan hasilnya.

Dalam *event study*, terdapat dua periode yang perlu dibedakan, yaitu jendela estimasi dan jendela peristiwa. Jendela estimasi merupakan periode sebelum peristiwa yang digunakan untuk mengestimasi parameter model *return* normal, sedangkan jendela peristiwa merupakan periode di sekitar peristiwa tempat *abnormal return* diukur. Kedua jendela tersebut sebaiknya tidak saling tumpang tindih agar parameter model tidak dipengaruhi oleh peristiwa yang sedang diteliti (MacKinlay, 1997). Pada penelitian ini, hari peristiwa (H0) ditentukan dari waktu terbit berita, jendela estimasi ditetapkan pada H-130 sampai H-11, dan jendela peristiwa difokuskan pada H0 sampai H+1. Jeda antara akhir jendela estimasi dan hari peristiwa dimaksudkan agar parameter tidak terpengaruh oleh kebocoran informasi menjelang berita terbit. Hubungan antarperiode tersebut ditunjukkan pada Gambar II.1.

### II.2.3 *Return*, *Abnormal Return*, dan *Cumulative Abnormal Return*

*Return* harian emiten $i$ pada hari $t$ dihitung dari perubahan harga penutupan terhadap hari bursa sebelumnya, seperti pada Persamaan II.1. Harga $P_{i,t}$ yang digunakan merupakan harga yang telah disesuaikan terhadap *stock split* dan dividen, sehingga peristiwa tersebut tidak terbaca sebagai lonjakan *return*.

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}} \tag{II.1}$$

*Abnormal return* merupakan selisih antara *return* aktual dan *return* normal, yaitu *return* yang diharapkan apabila peristiwa tidak terjadi (MacKinlay, 1997). Secara umum, *abnormal return* dirumuskan pada Persamaan II.2, dengan $X_t$ menyatakan informasi yang digunakan oleh model *return* normal, misalnya *return* pasar pada

hari yang sama.

$$AR_{i,t} = R_{i,t} - E\left(R_{i,t} \mid X_t\right) \tag{II.2}$$

Reaksi harga terhadap suatu peristiwa tidak selalu selesai dalam satu hari. Untuk menangkap reaksi yang berlangsung selama beberapa hari, *abnormal return* dijumlahkan sepanjang jendela peristiwa menjadi *cumulative abnormal return* (CAR) seperti pada Persamaan II.3. CAR yang digunakan pada penelitian ini adalah $CAR_i[0, +1]$, yaitu jumlah *abnormal return* pada H0 dan H+1. Pilihan ini juga mempertimbangkan berita yang terbit menjelang penutupan pasar dan kasus ARB yang membuat reaksi harga baru selesai pada hari berikutnya.

$$CAR_i[\tau_1, \tau_2] = \sum_{t=\tau_1}^{\tau_2} AR_{i,t} \tag{II.3}$$

Dalam *event study* klasik, signifikansi *abnormal return* diuji dengan membandingkannya terhadap simpangan baku residual model pada jendela estimasi (MacKinlay, 1997). Penelitian ini tidak menggunakan uji tersebut untuk menyimpulkan dampak satu jenis peristiwa, tetapi memakai gagasan yang sama untuk menentukan arah *abnormal return*. Arah *abnormal return* dikategorikan positif apabila nilainya lebih besar dari satu simpangan baku residual, negatif apabila lebih kecil dari negatif satu simpangan baku residual, dan netral untuk nilai di antaranya, seperti pada Persamaan II.4. Dengan cara ini, ambang arah menyesuaikan dengan tingkat volatilitas masing-masing emiten. Emiten yang biasanya bergerak tajam memerlukan *abnormal return* yang lebih besar untuk dikategorikan positif atau negatif dibandingkan emiten yang pergerakannya stabil.

$$d_{i,t} = \begin{cases} \text{positif}, & AR_{i,t} > \hat{\sigma}_{\varepsilon_i} \\ \text{negatif}, & AR_{i,t} < -\hat{\sigma}_{\varepsilon_i} \\ \text{netral}, & \text{lainnya} \end{cases} \tag{II.4}$$

## II.3 Model *Return* yang Diharapkan

Nilai *abnormal return* sangat bergantung pada model yang digunakan untuk menghitung *return* yang diharapkan. Semakin baik model menjelaskan pergerakan normal saham, semakin kecil varians *abnormal return*, sehingga dampak suatu peristiwa lebih mudah dideteksi (MacKinlay, 1997). Subbab ini membahas beberapa model

yang umum digunakan, mulai dari yang paling sederhana sampai model dua faktor yang digunakan dalam penelitian ini.

### II.3.1 Model Rata-Rata Konstan dan Model *Market-Adjusted*

Model rata-rata konstan mengasumsikan bahwa *return* normal suatu saham sama dengan rata-rata *return* saham tersebut pada jendela estimasi (MacKinlay, 1997). Model ini sederhana, tetapi tidak memperhitungkan kondisi pasar pada hari peristiwa. Akibatnya, ketika pasar sedang turun tajam, hampir seluruh saham akan terlihat memiliki *abnormal return* negatif walaupun tidak ada peristiwa khusus. Model *market-adjusted* mengatasi sebagian masalah tersebut dengan mengurangkan *return* pasar secara langsung dari *return* saham, seperti pada Persamaan II.5.

$$AR_{i,t} = R_{i,t} - R_{m,t} \tag{II.5}$$

Model *market-adjusted* tidak memerlukan jendela estimasi karena secara implisit mengasumsikan $\alpha = 0$ dan $\beta = 1$ untuk setiap saham. Brown dan Warner (1985) menunjukkan bahwa pada kasus tertentu, metode yang sederhana seperti ini juga dapat bekerja dengan baik. Model ini digunakan oleh Sudirman dkk. (2026) dalam *event study* di BEI dengan IHSG sebagai *return* pasar. Kelemahannya, asumsi $\beta = 1$ tidak sesuai untuk saham yang bergerak jauh lebih tajam atau jauh lebih lambat daripada pasar. Selain itu, model ini sama sekali tidak memperhitungkan pengaruh sektor.

### II.3.2 *Market Model*

*Market model* menghubungkan *return* saham dengan *return* pasar melalui regresi linear, seperti pada Persamaan II.6 (MacKinlay, 1997). Parameter $\alpha_i$ dan $\beta_i$ diestimasi menggunakan *ordinary least squares* (OLS) pada jendela estimasi, kemudian digunakan untuk menghitung *return* yang diharapkan pada jendela peristiwa. Nilai $\beta_i$ menunjukkan sensitivitas saham terhadap pergerakan pasar, sehingga saham yang biasanya bergerak lebih tajam daripada IHSG akan memiliki $\beta_i$ lebih besar dari satu.

$$R_{i,t} = \alpha_i + \beta_i R_{m,t} + \varepsilon_{i,t}, \quad E(\varepsilon_{i,t}) = 0, \quad \text{Var}(\varepsilon_{i,t}) = \sigma^2_{\varepsilon_i} \tag{II.6}$$

Brown dan Warner (1980) membandingkan beberapa metode pengukuran kinerja harga saham menggunakan data bulanan. Kajian serupa kemudian dilakukan oleh

Brown dan Warner (1985) menggunakan data harian. Hasil kajian dengan data harian menunjukkan bahwa metode berbasis *market model* yang sederhana sudah cukup tepat spesifikasinya dan memiliki kekuatan uji yang relatif baik pada berbagai kondisi. Temuan ini menjadikan *market model* sebagai model standar dalam banyak *event study*. Namun, *market model* hanya menggunakan satu faktor, yaitu pasar. Apabila sebagian pergerakan saham sebenarnya berasal dari sektornya, bagian tersebut akan tertinggal di dalam residual dan ikut terhitung sebagai *abnormal return*.

### II.3.3 Model Indeks Dua Faktor

MacKinlay (1997) menjelaskan bahwa model *return* normal dapat diperluas menjadi model multifaktor dengan tujuan mengurangi varians *abnormal return*, walaupun dalam banyak *event study* manfaat tambahan faktor tersebut terbatas. Besarnya manfaat itu bergantung pada seberapa besar faktor tambahan dapat menjelaskan pergerakan saham yang tidak tertangkap oleh faktor pasar. Untuk faktor industri, bukti empiris diberikan oleh Xiang (1993). Penelitian tersebut membandingkan pilihan model pembangkit *return* dalam *event study* dan menemukan bahwa faktor industri menjelaskan rata-rata 6,7% variasi residual *market model* pada data harian dan 11,5% pada data mingguan. Penelitian tersebut juga menyimpulkan bahwa apabila *return* saham sebenarnya mengikuti model dua faktor, inferensi yang hanya didasarkan pada *market model* menjadi tidak valid. Berdasarkan temuan tersebut, penelitian ini menggunakan model dua faktor seperti pada Persamaan II.7, dengan $R_{m,t}$ menyatakan *return* IHSG dan $R_{s,t}$ menyatakan *return* indeks sektoral IDX-IC tempat emiten diklasifikasikan.

$$R_{i,t} = \alpha_i + \beta_{1,i} R_{m,t} + \beta_{2,i} R_{s,t} + \varepsilon_{i,t} \tag{II.7}$$

Parameter $\alpha_i$, $\beta_{1,i}$, dan $\beta_{2,i}$ diestimasi dengan OLS pada jendela estimasi. *Abnormal return* pada hari peristiwa kemudian dihitung sebagai selisih antara *return* aktual dan *return* yang diharapkan menurut parameter tersebut, seperti pada Persamaan II.8. Ambang arah pada Persamaan II.4, yaitu simpangan baku residual $\hat{\sigma}_{\varepsilon_i}$, dihitung dari residual model pada jendela estimasi, seperti pada Persamaan II.9, dengan $L$ menyatakan jumlah hari bursa pada jendela estimasi.

$$AR_{i,t} = R_{i,t} - \left(\hat{\alpha}_i + \hat{\beta}_{1,i} R_{m,t} + \hat{\beta}_{2,i} R_{s,t}\right) \tag{II.8}$$

Tabel II.2 Perbandingan model *return* yang diharapkan

| **Model** | ***Return* yang diharapkan** | **Keterbatasan** |
|---|---|---|
| Rata-rata konstan | Rata-rata *return* saham pada jendela estimasi | Tidak memperhitungkan kondisi pasar pada hari peristiwa |
| *Market-adjusted* | *Return* pasar pada hari yang sama | Mengasumsikan $\beta = 1$ dan tidak memperhitungkan sektor |
| *Market model* | $\hat{\alpha}_i + \hat{\beta}_i R_{m,t}$ | Pergerakan sektor tertinggal di dalam *abnormal return* |
| Dua faktor | $\hat{\alpha}_i + \hat{\beta}_{1,i} R_{m,t} + \hat{\beta}_{2,i} R_{s,t}$ | Estimasi $\beta$ dapat tidak stabil akibat kolinearitas, dan dapat menghapus dampak peristiwa berskala sektor |

$$\hat{\sigma}_{\varepsilon_i} = \sqrt{\frac{1}{L-3} \sum_{t \in \text{estimasi}} \hat{\varepsilon}_{i,t}^2} \tag{II.9}$$

Penggunaan bobot hasil regresi berbeda dengan sekadar mengurangkan *return* IHSG dan *return* sektor secara langsung. Indeks sektoral pada dasarnya juga ikut bergerak bersama IHSG, sehingga apabila keduanya dikurangkan secara penuh, pengaruh pasar akan terhitung dua kali. Sebagai ilustrasi, apabila IHSG turun 2%, sektor turun 2%, dan saham turun 3%, pengurangan langsung menghasilkan $-3\% - (-2\%) - (-2\%) = +1\%$, seolah-olah saham tersebut mengungguli pasar padahal penurunannya paling dalam. Melalui regresi, besarnya keterikatan saham terhadap pasar dan sektor ditentukan dari data historis, sehingga masalah tersebut dapat dihindari. Perbandingan model-model yang telah dibahas dirangkum pada Tabel II.2.

Model dua faktor juga memiliki beberapa keterbatasan yang perlu diperhatikan. Pertama, *return* IHSG dan *return* indeks sektoral umumnya berkorelasi tinggi, terutama untuk sektor yang bobotnya besar di IHSG. Kolinearitas ini dapat membuat estimasi $\beta_{1,i}$ dan $\beta_{2,i}$ tidak stabil, walaupun nilai *return* yang diharapkan secara keseluruhan masih dapat diestimasi. Salah satu cara untuk mengatasinya adalah meregresikan *return* sektor terhadap *return* IHSG terlebih dahulu, kemudian menggunakan residualnya sebagai faktor sektor, sehingga $\beta_{2,i}$ hanya menangkap pergerakan sektor di luar pergerakan pasar. Kedua, untuk peristiwa yang memengaruhi satu sektor secara keseluruhan, seperti perubahan regulasi pada suatu industri, koreksi sektor justru dapat menghapus dampak peristiwa tersebut karena seluruh emiten dalam sektor bergerak bersama. Oleh karena itu, untuk peristiwa berskala sektor, penelitian ini

juga menghitung *abnormal return* yang hanya dikoreksi oleh IHSG.

## II.4 Pemrosesan Teks Berita untuk Analisis Saham

### II.4.1 Sentimen dan Jenis Peristiwa

Informasi dari teks berita dapat diekstraksi dalam berbagai bentuk. Bentuk yang paling banyak digunakan dalam penelitian keuangan adalah sentimen, yaitu ukuran nada positif atau negatif suatu teks. Kearney dan Liu (2014) merangkum berbagai metode dan model yang digunakan untuk mengukur sentimen tekstual di bidang keuangan, mulai dari pendekatan berbasis kamus kata sampai pendekatan berbasis *machine learning*. Sentimen mudah diinterpretasikan dan dapat dihitung untuk hampir semua jenis teks. Namun, sentimen hanya menggambarkan nada berita, bukan peristiwa yang terjadi. Berita mengenai direktur yang ditetapkan sebagai tersangka korupsi dan berita mengenai laba yang turun sesuai ekspektasi analis sama-sama bernada negatif, tetapi keduanya merupakan peristiwa yang berbeda dan dapat diikuti reaksi harga yang berbeda pula.

Pendekatan lain adalah merepresentasikan berita berdasarkan peristiwa yang dikandungnya. Ding dkk. (2015) mengekstraksi peristiwa dari teks berita dan merepresentasikannya sebagai vektor padat, kemudian menggunakan *convolutional neural network* untuk memodelkan pengaruh jangka pendek dan jangka panjang peristiwa terhadap pergerakan harga. Model tersebut menghasilkan peningkatan sekitar 6% dibandingkan metode pembanding pada prediksi indeks S&P 500 dan saham individual. Zhou dkk. (2021) memandang peristiwa korporasi sebagai penggerak pergerakan saham dan membangun detektor peristiwa dua tingkat, yaitu pada tingkat token dan tingkat artikel. Kedua penelitian tersebut menunjukkan bahwa jenis peristiwa dapat dijadikan representasi berita yang lebih spesifik dibandingkan sentimen. Pada penelitian ini, jenis peristiwa direpresentasikan sebagai label kategori yang dapat dibaca langsung, seperti hukum atau korupsi, laporan keuangan, dan pergantian direksi, sehingga kontribusinya terhadap prediksi dapat dijelaskan.

### II.4.2 Klasifikasi Berbasis Aturan dan Supervisi Lemah

Cara paling sederhana untuk mengklasifikasikan jenis peristiwa adalah menggunakan aturan kata kunci. Misalnya, berita yang memuat kata “tersangka”, “KPK”, atau “Kejagung” diberi label hukum atau korupsi. Pendekatan ini mudah dibuat dan hasilnya transparan, tetapi tidak dapat menangani berita yang menggambarkan peristiwa yang sama dengan kata-kata berbeda. Selain itu, aturan kata kunci tidak memahami konteks, sehingga kata yang sama dapat muncul pada berita dengan peristiwa yang berbeda.

Walaupun kurang akurat jika digunakan sebagai *classifier* akhir, aturan kata kunci dapat dimanfaatkan untuk mempercepat penyusunan data latih. Ratner dkk. (2017) memperkenalkan Snorkel, yaitu sistem yang memungkinkan pengguna menulis fungsi pelabelan berupa aturan atau heuristik untuk menghasilkan label data latih tanpa melabeli setiap data secara manual. Pendekatan ini dikenal sebagai supervisi lemah karena label yang dihasilkan masih mengandung kesalahan. Pada penelitian ini, gagasan tersebut digunakan dalam bentuk yang lebih sederhana, yaitu aturan kata kunci menghasilkan pra-label yang kemudian diperiksa dan dikoreksi secara manual. Aturan kata kunci juga digunakan sebagai *baseline* untuk menilai seberapa besar peningkatan yang diberikan oleh model berbasis *machine learning*.

### II.4.3 TF-IDF dengan Logistic Regression dan SVM

Pendekatan klasik untuk klasifikasi teks adalah merepresentasikan dokumen sebagai vektor bobot kata, kemudian melatih *classifier* linear di atas vektor tersebut. Salah satu skema pembobotan yang paling umum adalah TF-IDF (*term frequency-inverse document frequency*). Bobot ini memberikan nilai tinggi kepada kata yang sering muncul pada suatu dokumen tetapi jarang muncul pada dokumen lain. Gagasan bahwa kata yang muncul di banyak dokumen memiliki daya pembeda yang lebih rendah diperkenalkan oleh Spärck Jones (1972). Bobot TF-IDF kata $w$ pada dokumen $d$ dihitung seperti pada Persamaan II.10, dengan $\text{tf}(w, d)$ menyatakan frekuensi kata $w$ pada dokumen $d$, $N$ menyatakan jumlah dokumen, dan $\text{df}(w)$ menyatakan jumlah dokumen yang memuat kata $w$.

$$\text{tf-idf}(w, d) = \text{tf}(w, d) \cdot \log \frac{N}{\text{df}(w)} \tag{II.10}$$

Vektor TF-IDF umumnya berdimensi tinggi dan bersifat jarang. Joachims (1998) menunjukkan bahwa *support vector machine* (SVM) cocok untuk klasifikasi teks karena mampu menangani ruang fitur berdimensi tinggi dengan banyak fitur yang relevan. *Logistic regression* juga sering digunakan sebagai pembanding karena sederhana dan menghasilkan probabilitas kelas. Kelemahan pendekatan ini adalah setiap kata diperlakukan secara terpisah, sehingga urutan kata dan konteks kalimat tidak tertangkap. Meskipun demikian, kombinasi TF-IDF dengan SVM atau *logistic regression* tetap menjadi *baseline* yang kuat dan murah secara komputasi, sehingga digunakan sebagai pembanding IndoBERT dalam penelitian ini.

### II.4.4 Transformer, BERT, dan IndoBERT

Transformer merupakan arsitektur jaringan saraf yang sepenuhnya menggunakan mekanisme *attention* untuk memodelkan hubungan antartoken dalam suatu urutan (Vaswani dkk. 2017). Mekanisme *self-attention* memungkinkan representasi setiap token dihitung dengan mempertimbangkan seluruh token lain dalam kalimat. Berdasarkan arsitektur tersebut, Devlin dkk. (2019) memperkenalkan BERT (*Bidirectional Encoder Representations from Transformers*), yaitu model *encoder* yang dilatih awal pada korpus teks besar menggunakan tugas *masked language modeling* dan *next sentence prediction*. Representasi yang dihasilkan bersifat dua arah, karena setiap token dipahami berdasarkan konteks di sebelah kiri dan kanannya. Setelah dilatih awal, BERT dapat disesuaikan untuk tugas tertentu melalui *fine-tuning*, yaitu dengan menambahkan lapisan klasifikasi dan melatih ulang model menggunakan data berlabel dalam jumlah yang relatif kecil.

Untuk bahasa Indonesia, Wilie dkk. (2020) merilis IndoNLU, yaitu kumpulan dua belas tugas pemahaman bahasa Indonesia beserta model IndoBERT yang dilatih awal pada korpus Indo4B. Korpus tersebut dikumpulkan dari sumber publik seperti media sosial, blog, berita, dan situs web. Model `indobenchmark/indobert-base-p1` yang digunakan dalam penelitian ini merupakan salah satu varian IndoBERT tersebut. Pada waktu yang hampir bersamaan, Koto dkk. (2020) juga merilis model IndoBERT lain beserta tolok ukur IndoLEM, sehingga nama IndoBERT dalam literatur dapat merujuk pada dua model yang berbeda. Untuk domain keuangan, Maharani dkk. (2023) melakukan *post-training* model bahasa pada korpus keuangan Indonesia dan menyusun dataset analisis sentimen serta klasifikasi topik keuangan berbahasa Indonesia. Penelitian tersebut menemukan bahwa *post-training* pada domain keuangan meningkatkan kinerja model ketika di-*fine-tune* untuk tugas pada domain yang sama.

Perlu dibedakan bahwa IndoBERT merupakan model *encoder* yang di-*fine-tune* untuk tugas klasifikasi, bukan model bahasa generatif. Model ini menghasilkan probabilitas untuk setiap kelas yang telah ditentukan dan tidak menghasilkan teks baru. Dengan bobot model yang tetap setelah pelatihan, keluaran IndoBERT untuk masukan yang sama akan selalu sama. Sifat ini mendukung kebutuhan penelitian ini akan *pipeline* yang dapat direproduksi.

### II.4.5 Anotasi dan Kesepakatan Antaranotator

Model klasifikasi jenis peristiwa memerlukan data berlabel, dan kualitas label perlu diukur sebelum data digunakan untuk evaluasi. Apabila dua anotator melabeli

data yang sama, kesepakatan antara keduanya dapat diukur dengan Cohen's kappa (Cohen, 1960). Berbeda dengan persentase kesepakatan biasa, kappa mengoreksi kesepakatan yang dapat terjadi secara kebetulan, seperti pada Persamaan II.11. Pada persamaan tersebut, $p_o$ menyatakan proporsi data yang labelnya sama di antara kedua anotator, sedangkan $p_e$ menyatakan proporsi kesepakatan yang diharapkan secara kebetulan berdasarkan distribusi label masing-masing anotator.

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{II.11}$$

Landis dan Koch (1977) mengusulkan interpretasi nilai kappa ke dalam beberapa tingkat. Nilai 0,41 sampai 0,60 dikategorikan sebagai kesepakatan sedang (*moderate*), nilai 0,61 sampai 0,80 sebagai kesepakatan substansial (*substantial*), dan nilai di atas 0,80 sebagai kesepakatan hampir sempurna (*almost perfect*). Berdasarkan interpretasi tersebut, target kappa sekurang-kurangnya 0,6 pada penelitian ini berada pada batas antara kesepakatan sedang dan substansial. Nilai kappa yang lebih rendah dari target menunjukkan bahwa definisi kategori dalam pedoman anotasi belum cukup jelas, sehingga pedoman perlu diperbaiki sebelum pelabelan dilanjutkan.

## II.5 *Gradient Boosting* dan XGBoost

*Gradient boosting* merupakan metode yang membangun model prediksi secara bertahap dengan menambahkan model lemah satu per satu. Friedman (2001) merumuskan metode ini sebagai optimasi numerik dalam ruang fungsi, yaitu setiap model baru ditambahkan ke arah gradien negatif dari fungsi kerugian. Dalam praktiknya, model lemah yang digunakan umumnya berupa pohon keputusan, sehingga hasil akhirnya merupakan jumlah dari banyak pohon. Untuk data tabular dengan fitur campuran, seperti kategori jenis peristiwa dan nilai numerik kondisi pasar, model berbasis pohon dapat menangkap interaksi antarfitur tanpa perlu menentukan bentuk hubungannya secara eksplisit.

XGBoost merupakan implementasi *tree boosting* yang dirancang agar dapat diskalakan dan efisien (Chen & Guestrin, 2016). Prediksi XGBoost untuk data ke-$i$ merupakan jumlah keluaran $K$ pohon, seperti pada Persamaan II.12. Model dilatih dengan meminimalkan fungsi objektif yang terdiri dari fungsi kerugian $l$ dan suku regularisasi $\Omega$, seperti pada Persamaan II.13. Pada suku regularisasi, $T$ menyatakan jumlah daun pada pohon, $w$ menyatakan bobot daun, sedangkan $\gamma$ dan $\lambda$ merupakan

parameter yang mengatur besarnya penalti kompleksitas pohon.

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i) \tag{II.12}$$

$$\mathcal{L} = \sum_i l\left(y_i, \hat{y}_i\right) + \sum_k \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2 \tag{II.13}$$

Selain regularisasi, Chen dan Guestrin (2016) juga mengusulkan algoritma yang memperhitungkan data jarang dan metode *weighted quantile sketch* untuk pencarian titik pemisah secara aproksimatif. XGBoost dapat digunakan untuk klasifikasi maupun regresi dengan mengganti fungsi kerugiannya. Pada penelitian ini, XGBoost *classifier* digunakan untuk memprediksi arah *abnormal return*, sedangkan XGBoost *regressor* digunakan untuk memprediksi besarnya. Pemilihan model berbasis pohon juga berkaitan dengan tahap interpretasi, karena struktur pohon memungkinkan nilai SHAP dihitung secara efisien.

### II.6 SHAP sebagai Metode Penjelasan Prediksi

Model seperti XGBoost dapat menghasilkan prediksi yang akurat, tetapi alasan di balik setiap prediksinya tidak dapat dibaca secara langsung. SHAP (*SHapley Additive exPlanations*) merupakan kerangka yang memberikan nilai kepentingan setiap fitur untuk suatu prediksi tertentu (Lundberg & Lee, 2017). SHAP termasuk dalam kelompok metode atribusi fitur aditif, yaitu metode yang menjelaskan prediksi sebagai jumlah dari nilai dasar dan kontribusi setiap fitur, seperti pada Persamaan II.14. Pada persamaan tersebut, $\phi_0$ merupakan nilai dasar yang setara dengan rata-rata prediksi model, $M$ merupakan jumlah fitur, $z'_j$ menyatakan ada atau tidaknya fitur $j$, dan $\phi_j$ merupakan kontribusi fitur $j$.

$$g(z') = \phi_0 + \sum_{j=1}^{M} \phi_j z'_j \tag{II.14}$$

Nilai $\phi_j$ dihitung berdasarkan nilai Shapley dari teori permainan kooperatif (Shapley, 1953). Dalam konteks ini, setiap fitur diperlakukan sebagai pemain, dan prediksi model diperlakukan sebagai hasil yang dibagikan kepada para pemain. Nilai Shapley fitur $j$ merupakan rata-rata kontribusi marginal fitur tersebut terhadap seluruh kemungkinan subhimpunan fitur lain, seperti pada Persamaan II.15, dengan $F$ menyatakan himpunan seluruh fitur dan $f_x(S)$ menyatakan prediksi model ketika hanya

fitur dalam subhimpunan $S$ yang diketahui.

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\ (|F| - |S| - 1)!}{|F|!} \left[ f_x\left(S \cup \{j\}\right) - f_x(S) \right] \tag{II.15}$$

Lundberg dan Lee (2017) menunjukkan bahwa dalam kelompok metode atribusi aditif terdapat satu solusi unik yang memenuhi sifat akurasi lokal, *missingness*, dan konsistensi, dan solusi tersebut adalah nilai Shapley. Akurasi lokal berarti jumlah nilai dasar dan seluruh kontribusi fitur sama dengan prediksi model untuk data tersebut. Masalahnya, perhitungan Persamaan II.15 secara langsung memerlukan evaluasi pada seluruh subhimpunan fitur, sehingga waktu komputasinya tumbuh secara eksponensial terhadap jumlah fitur. Lundberg dkk. (2020) kemudian mengusulkan TreeSHAP, yaitu algoritma yang menghitung nilai SHAP secara tepat untuk model berbasis pohon dalam waktu polinomial. Penelitian tersebut juga menunjukkan bahwa penjelasan lokal untuk setiap prediksi dapat digabungkan untuk memahami perilaku model secara global.

Bagi penelitian ini, SHAP digunakan pada dua tingkat. Pada tingkat global, rata-rata nilai SHAP absolut menunjukkan fitur yang paling berpengaruh terhadap prediksi *abnormal return* secara keseluruhan. Pada tingkat berita, nilai SHAP menunjukkan seberapa besar jenis peristiwa, sentimen, keterlibatan emiten, dan kondisi pasar menaikkan atau menurunkan estimasi *abnormal return* untuk berita tertentu. Karena target yang dijelaskan adalah *abnormal return* dan bukan *return* mentah, kontribusi yang ditampilkan tidak lagi bercampur dengan pergerakan IHSG dan sektor pada hari yang sama. Penjelasan dari XGBoost *regressor* dinyatakan dalam satuan yang sama dengan targetnya, yaitu persen *abnormal return*, sehingga lebih mudah dibaca dibandingkan penjelasan dari *classifier* yang dinyatakan dalam satuan *log-odds*.

## II.7 Metrik Evaluasi dan Uji Signifikansi

### II.7.1 Metrik Klasifikasi

Kinerja klasifikasi jenis peristiwa dan arah *abnormal return* diukur menggunakan accuracy, F1-macro, dan AUC. Accuracy menyatakan proporsi prediksi yang benar, tetapi nilainya dapat menyesatkan ketika distribusi kelas tidak seimbang. Pada data *abnormal return*, kelas netral diperkirakan mendominasi, sehingga model yang selalu menebak netral dapat memperoleh accuracy tinggi tanpa benar-benar membedakan arah. Untuk itu, digunakan F1-macro, yaitu rata-rata F1 dari setiap kelas tanpa pembobotan berdasarkan jumlah data (Sokolova & Lapalme, 2009). F1 untuk

kelas $c$ merupakan rata-rata harmonik dari *precision* $P_c$ dan *recall* $R_c$, seperti pada Persamaan II.16, dengan $C$ menyatakan jumlah kelas.

$$F1_c = \frac{2P_cR_c}{P_c + R_c}, \qquad \text{F1-macro} = \frac{1}{C}\sum_{c=1}^{C} F1_c \tag{II.16}$$

AUC (*area under the ROC curve*) mengukur kemampuan model dalam mengurutkan data positif di atas data negatif pada berbagai ambang probabilitas (Fawcett, 2006). Nilai AUC sebesar 0,5 setara dengan tebakan acak, sedangkan nilai 1 menunjukkan pemisahan yang sempurna. Metrik ini berguna karena keluaran sistem tidak hanya berupa kelas arah, tetapi juga probabilitasnya. Untuk masalah dengan lebih dari dua kelas, AUC dihitung untuk setiap kelas terhadap kelas lainnya kemudian dirata-ratakan.

### II.7.2 Metrik Regresi

Kinerja prediksi besar *abnormal return* diukur menggunakan *mean absolute error* (MAE) dan *root mean squared error* (RMSE), seperti pada Persamaan II.17 dan Persamaan II.18, dengan $n$ menyatakan jumlah data uji. MAE menyatakan rata-rata besar kesalahan dalam satuan yang sama dengan target, sehingga mudah diinterpretasikan sebagai rata-rata selisih persen antara *abnormal return* prediksi dan aktual. Willmott dan Matsuura (2005) berpendapat bahwa MAE merupakan ukuran rata-rata kesalahan yang lebih alami dibandingkan RMSE, karena RMSE juga dipengaruhi oleh sebaran besarnya kesalahan. Meskipun demikian, RMSE tetap dilaporkan karena memberikan penalti lebih besar terhadap kesalahan yang besar. Hal ini relevan karena *abnormal return* dapat memiliki nilai ekstrem, misalnya pada berita kasus hukum besar.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n} |y_i - \hat{y}_i| \tag{II.17}$$

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n} (y_i - \hat{y}_i)^2} \tag{II.18}$$

### II.7.3 Uji Signifikansi Selisih Kinerja

Selisih metrik antara dua model pada satu data uji belum tentu menunjukkan perbedaan yang nyata, karena selisih tersebut dapat muncul akibat variasi sampel. Untuk membandingkan dua *classifier* pada data uji yang sama, dapat digunakan uji Mc-

Nemar (McNemar, 1947). Dietterich (1998) membandingkan beberapa uji statistik untuk membandingkan algoritma pembelajaran dan merekomendasikan uji McNemar untuk kondisi ketika model hanya dapat dilatih dan diuji satu kali. Statistik uji McNemar dengan koreksi kontinuitas ditunjukkan pada Persamaan II.19, dengan $n_{01}$ menyatakan jumlah data yang salah diklasifikasikan oleh model pertama tetapi benar oleh model kedua, dan $n_{10}$ menyatakan kebalikannya. Statistik ini mengikuti distribusi $\chi^2$ dengan satu derajat kebebasan.

$$\chi^2 = \frac{(|n_{01} - n_{10}| - 1)^2}{n_{01} + n_{10}} \tag{II.19}$$

Uji McNemar hanya berlaku untuk perbandingan benar atau salah pada klasifikasi, sehingga tidak dapat digunakan untuk metrik seperti F1-macro, AUC, atau MAE secara langsung. Untuk metrik tersebut, digunakan metode *bootstrap* (Efron, 1979). Pada metode ini, data uji diambil ulang secara acak dengan pengembalian sebanyak ratusan sampai ribuan kali, kemudian selisih metrik kedua model dihitung pada setiap sampel ulang. Distribusi selisih yang diperoleh digunakan untuk menyusun selang kepercayaan. Apabila selang kepercayaan tersebut tidak memuat nol, selisih kinerja kedua model dapat dianggap signifikan pada tingkat kepercayaan yang digunakan.

## II.8 Penelitian Terkait

Penelitian terkait pada subbab ini dikelompokkan menjadi empat, yaitu penelitian berbasis berita di Indonesia, *event study* di BEI, penelitian yang menghubungkan peristiwa dari teks dengan *abnormal return*, serta penelitian yang menggunakan *explainable machine learning* untuk prediksi saham. Pengelompokan ini digunakan untuk melihat komponen apa saja yang sudah dikerjakan oleh penelitian sebelumnya dan komponen apa yang belum.

### II.8.1 Penelitian Berbasis Berita di Indonesia

Attar (2024) menggunakan IndoBERT untuk mengklasifikasikan sentimen 2.857 berita saham dan memperoleh akurasi 0,78. Hasil klasifikasi tersebut kemudian dikorelasikan dengan pergerakan harga per sektor, dengan korelasi Pearson tertinggi sebesar 0,389 pada sektor *basic materials*. Alamsyah dkk. (2025) menganalisis 192.582 berita keuangan Indonesia periode 2018 sampai 2023, mendeteksi perusahaan yang disebutkan dalam berita, dan menyusun jaringan kemunculan bersama antarperusahaan. Penelitian tersebut menemukan bahwa korelasi sentimen dengan

harga meningkat dari 0,26 pada tingkat perusahaan menjadi 0,30 pada tingkat industri dan 0,43 pada klaster perusahaan yang sering muncul bersama dalam berita. Temuan ini menunjukkan bahwa pengelompokan berdasarkan industri dan kemunculan bersama dapat memperjelas hubungan antara berita dan harga.

Kusuma dkk. (2026) menggabungkan sentimen IndoBERT dari 9.819 berita CNBC Indonesia dengan data harga untuk mengklasifikasikan tren harga lima emiten LQ45 menggunakan LSTM. Berbeda dengan dua penelitian sebelumnya yang bersifat korelasional, penelitian ini sudah berbentuk model prediksi. Sementara itu, Elli (2025) menguji hubungan sentimen 23.406 *tweet* dengan *abnormal return* saham IDX30 pada periode Juli sampai Desember 2023 menggunakan uji kausalitas Granger. Penelitian tersebut sudah menggunakan *abnormal return* sebagai target, tetapi sumber datanya berupa *tweet* dan analisisnya bersifat statistik agregat. Secara umum, keempat penelitian tersebut masih menggunakan sentimen sebagai satu-satunya informasi dari teks, dan belum ada yang mengoreksi pengaruh sektor maupun menjelaskan kontribusi fitur pada tingkat berita.

### II.8.2 *Event Study* di Bursa Efek Indonesia

*Event study* di BEI umumnya meneliti satu atau dua jenis peristiwa yang ditentukan oleh peneliti. Fauzi dan Mutasowifin (2021) meneliti dampak *stock split* terhadap *abnormal return* pada 34 emiten periode 2015 sampai 2019 menggunakan uji-t. Penelitian tersebut menemukan bahwa pada sampel gabungan terdapat tiga dari sebelas hari pengamatan yang memiliki *abnormal return* signifikan, dan bahwa pengaruhnya berbeda antarsektor industri. Sudirman dkk. (2026) meneliti pengumuman *right issue* dan *stock split* pada periode 2022 sampai 2024, dengan *abnormal return* dihitung sebagai selisih *return* saham terhadap *return* IHSG.

Penelitian *event study* tersebut memberikan bukti bahwa peristiwa korporasi tertentu dapat diikuti oleh *abnormal return* di BEI. Namun, peristiwa dan tanggalnya ditentukan secara manual, sehingga pendekatan tersebut tidak dapat langsung digunakan untuk menilai berita baru. Model *return* normal yang digunakan juga belum mengoreksi pengaruh sektor, padahal temuan Fauzi dan Mutasowifin (2021) menunjukkan bahwa reaksi harga dapat berbeda antarsektor. Selain itu, setiap penelitian hanya membahas jenis peristiwa yang sangat terbatas, sehingga perbandingan dampak antarjenis peristiwa belum dapat dilakukan dalam satu kerangka yang sama.

### II.8.3 Peristiwa dari Teks dan *Abnormal Return*

Luss dan d'Aspremont (2015) memprediksi *return* intrahari dari berita menggunakan klasifikasi teks dengan *multiple kernel learning* yang menggabungkan teks

dan *return* historis. *Abnormal return* pada penelitian tersebut didefinisikan sebagai *return* yang nilai absolutnya melewati ambang tertentu, bukan *return* yang dikoreksi pasar. Temuannya menunjukkan bahwa arah *return* tidak dapat diprediksi menggunakan teks maupun *return* historis, tetapi besarnya pergerakan dapat diprediksi, dan fitur teks memberikan kinerja yang lebih baik dibandingkan *return* historis saja. Temuan ini menjadi dasar penelitian ini untuk mengevaluasi model tidak hanya dari ketepatan arah, tetapi juga dari estimasi besar *abnormal return*.

Zhou dkk. (2021) menyusun dataset EDT yang berisi 9.721 artikel berita dengan label peristiwa pada tingkat token serta 303.893 artikel berita dengan stempel waktu hingga menit dan label harga saham. Strategi *trading* yang dibangun dari detektor peristiwa mereka mengungguli seluruh pembanding dari sisi *winning rate*, *excess return* terhadap pasar, dan rata-rata *return* per transaksi. Dogra dkk. (2022) mengklasifikasikan berita perbankan dan pemerintah India secara otomatis menggunakan *embedding* DistilBERT dengan Random Forest dan memperoleh akurasi 94%, kemudian menghitung CAR untuk kelompok bank swasta dan bank pemerintah. Penelitian tersebut menemukan bahwa berita negatif berpengaruh terhadap bank swasta selama satu bulan dan terhadap bank pemerintah selama dua bulan. Namun, kelas yang digunakan masih berupa sentimen, dan CAR dihitung per kelompok, bukan diprediksi per berita.

Penelitian yang lebih baru memanfaatkan *large language model* (LLM) untuk memberi label peristiwa dalam skala besar. Kargarzadeh dkk. (2026) menggunakan LLM yang didistilasi menjadi *classifier* untuk memberi 17 label peristiwa dan lima atribut pada 4,57 juta artikel berita mengenai sekitar 3.000 saham Amerika Serikat periode 2023 sampai 2026. Hasilnya menunjukkan bahwa pergerakan harga terkonsentrasi sebelum dan pada saat publikasi berita, serta pasar bereaksi kurang terhadap berita fundamental yang terkuantifikasi seperti laba dan panduan kinerja. Dolphin dkk. (2026) memberi label 119 jenis peristiwa pada 292.984 laporan 8-K periode 2022 sampai 2026 dan menunjukkan bahwa taksonomi yang lebih rinci dapat membedakan peristiwa yang secara ekonomi berbeda walaupun berada pada kode item yang sama. Kedua penelitian tersebut mendukung premis bahwa jenis peristiwa berkaitan dengan besar *abnormal return*. Di sisi lain, Gao dkk. (2025) menemukan bahwa akurasi prediksi LLM dapat meningkat secara semu karena model sudah mengetahui hasil yang terjadi pada periode data pelatihannya, dan kecenderungan tersebut hampir hilang setelah batas waktu data pelatihan. Risiko ini menjadi salah satu pertimbangan penelitian ini untuk tidak menggunakan LLM generatif.

### II.8.4 *Explainable Machine Learning* untuk Prediksi Saham

Ruan dan Jiang (2025) menggabungkan sentimen dari judul berita yang diekstraksi menggunakan FinBERT dengan indikator teknikal dan statistik, kemudian menggunakan XGBoost untuk memprediksi pergerakan harga jangka pendek saham S&P 500 periode 2018 sampai 2023. Model tersebut mengungguli *baseline* yang hanya menggunakan indikator teknikal maupun sentimen berbasis kamus dari sisi AUC, F1, dan simulasi profitabilitas *trading*. SHAP digunakan untuk menguraikan setiap prediksi menjadi kontribusi fitur. Penelitian ini menunjukkan bahwa kombinasi fitur berita, XGBoost, dan SHAP dapat diterapkan pada prediksi saham. Namun, fitur berita yang digunakan masih berupa sentimen dan targetnya masih berupa pergerakan harga, sehingga kontribusi berita yang ditampilkan SHAP tidak dapat dipisahkan dari kontribusi pergerakan pasar.

### II.8.5 Posisi Penelitian

Perbandingan komponen penelitian terdahulu dengan penelitian ini dirangkum pada Tabel II.3. Kolom pada tabel tersebut menunjukkan apakah penelitian menggunakan data pasar Indonesia, mengekstraksi jenis peristiwa secara otomatis, menggunakan *abnormal return* sebagai target, mengoreksi pengaruh sektor, berupa model prediksi dan bukan analisis korelasi atau uji statistik agregat, serta menyediakan penjelasan dengan SHAP.

Tabel II.3 Perbandingan komponen penelitian terdahulu dengan penelitian ini

| **Penelitian** | **IDN** | **JP** | **AR** | **KS** | **PB** | **SHAP** |
|---|---|---|---|---|---|---|
| Attar (2024) | ✓ | – | – | – | – | – |
| Alamsyah dkk. (2025) | ✓ | – | – | – | – | – |
| Kusuma dkk. (2026) | ✓ | – | – | – | ✓ | – |
| Elli (2025) | ✓ | – | ✓ | – | – | – |
| Fauzi & Mutasowifin (2021) | ✓ | – | ✓ | – | – | – |
| Sudirman dkk. (2026) | ✓ | – | ✓ | – | – | – |
| Dogra dkk. (2022) | – | – | ✓ | – | – | – |
| Luss & d'Aspremont (2015) | – | – | – | – | ✓ | – |
| Ding dkk. (2015) | – | ✓ | – | – | ✓ | – |
| Zhou dkk. (2021) | – | ✓ | – | – | ✓ | – |
| Kargarzadeh dkk. (2026) | – | ✓ | ✓ | – | – | – |
| Dolphin dkk. (2026) | – | ✓ | ✓ | – | – | – |
| Ruan & Jiang (2025) | – | – | – | – | ✓ | ✓ |
| Penelitian ini | ✓ | ✓ | ✓ | ✓ | ✓ | ✓ |

IDN: pasar atau berita Indonesia; JP: jenis peristiwa diekstraksi otomatis dari teks; AR: target berupa *abnormal return* yang dikoreksi pasar; KS: koreksi indeks sektor; PB: berupa model prediksi, bukan analisis korelasi atau uji statistik agregat; SHAP: penjelasan prediksi dengan SHAP.

Berdasarkan Tabel II.3, penelitian di Indonesia sudah mencakup deteksi emiten

dari berita, analisis sentimen, dan pengukuran *abnormal return*, tetapi komponen-komponen tersebut belum digabungkan dalam satu sistem. Penelitian yang memanfaatkan berita masih berfokus pada sentimen dengan target harga, sedangkan penelitian yang mengukur *abnormal return* masih menentukan peristiwa secara manual atau menggunakan *tweet* sebagai sumber data. Penelitian global sudah mengekstraksi jenis peristiwa secara otomatis dan mengukur *abnormal return*, tetapi berfokus pada pasar Amerika Serikat, sebagian besar memanfaatkan LLM, dan tidak mengoreksi pengaruh sektor. Sementara itu, penelitian yang menggunakan SHAP masih menjelaskan model dengan fitur sentimen dan target harga.

Penelitian ini mengisi celah tersebut dengan menggabungkan tiga komponen untuk berita berbahasa Indonesia dan emiten BEI. Komponen pertama adalah target *abnormal return* yang dikoreksi IHSG dan indeks sektoral IDX-IC berdasarkan model dua faktor. Komponen kedua adalah fitur jenis peristiwa yang diekstraksi secara otomatis menggunakan IndoBERT, di samping sentimen dan kondisi pasar sebelum berita terbit. Komponen ketiga adalah penjelasan SHAP yang menunjukkan kontribusi setiap faktor pada tingkat berita. SHAP sendiri bukan merupakan kebaruan, tetapi berfungsi agar dua komponen sebelumnya dapat diinterpretasikan oleh pengguna. Dengan kombinasi tersebut, sistem yang diusulkan dapat memberikan estimasi terukur mengenai keterkaitan suatu berita dengan pergerakan emiten setelah pengaruh pasar dan sektor dikendalikan.

# BAB III

# ANALISIS MASALAH

## III.1 Analisis Kondisi Saat Ini

Menurut Laudon dan Laudon (2020), gambarkan terlebih dahulu model konseptual sistem yang ada saat ini. Model konseptual ini berisi berbagai komponen atau subsitem dan interaksi antarsubsistem tersebut. Setelah itu, berikan penjelasan tentang masalah yang ada pada sistem tersebut. Paragraf berikut berisi contoh penjabaran masalah sistem informasi fasilitas kesehatan untuk pasien (Pressman, 2019).

## III.2 Analisis Kebutuhan

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

### III.2.1 Identifikasi Masalah Pengguna

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

### III.2.2 Kebutuhan Fungsional

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie

non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

### III.2.3 Kebutuhan Nonfungsional

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

## III.3 Analisis Pemilihan Solusi

### III.3.1 Alternatif Solusi

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetuer at, consectetuer sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

### III.3.2 Analisis Penentuan Solusi

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetuer a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetuer. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit

ipsum dolor sed augue. Nulla nec lacus.

# BAB IV

# DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before* and *after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

# BAB V

# RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.

# DAFTAR PUSTAKA


Alamsyah, A., Ramadhani, D. P., Kristanti, F. T., Nasution, A. H., Mohamad, M. S. b., Sokkalingam, R., Widiyanesti, S., & Saputra, M. A. A. (2025). Deciphering news sentiment and stock price relationships in Indonesian companies: An AI-based exploration of industry affiliation and news co-occurrence. *Discover Artificial Intelligence*, *5*(1), Article 87. https://doi.org/10.1007/s44163-025-00350-5

Attar, R. N. (2024). *Penggunaan IndoBERT untuk klasifikasi sentimen berita saham dan analisis korelasi dengan pergerakan harga di Bursa Efek Indonesia* [Tugas Akhir]. Institut Teknologi Bandung. https://digilib.itb.ac.id/gdl/view_data/penggunaan-indobert-untuk-klasifikasi-sentimen-berita-saham-dan-analisis-korelasi-dengan-pergerakan-harga-di-bursa-efek-indonesia

Ball, R., & Brown, P. (1968). An empirical evaluation of accounting income numbers. *Journal of Accounting Research*, *6*(2), 159–178. https://doi.org/10.2307/2490232

Brown, S. J., & Warner, J. B. (1980). Measuring security price performance. *Journal of Financial Economics*, *8*(3), 205–258. https://doi.org/10.1016/0304-405X(80)90002-1

Brown, S. J., & Warner, J. B. (1985). Using daily stock returns: The case of event studies. *Journal of Financial Economics*, *14*(1), 3–31. https://doi.org/10.1016/0304-405X(85)90042-X

Bursa Efek Indonesia. (2024, March 27). *Panduan dan metodologi indeks IDX80, LQ45 dan IDX30 (lampiran pengumuman BEI no. peng-00058/BEI.POP/03-2024)*. Retrieved October 16, 2026, from https://www.idx.id/media/3lvd1yk1/lampiran-panduan-metodologi-indeks-idx80-lq45-dan-idx30.pdf

Chan, W. S. (2003). Stock price reaction to news and no-news: Drift and reversal after headlines. *Journal of Financial Economics*, *70*(2), 223–260. https://doi.org/10.1016/S0304-405X(03)00146-6

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. https://doi.org/10.18653/v1/N19-1423

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, *10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Ding, X., Zhang, Y., Liu, T., & Duan, J. (2015). Deep learning for event-driven stock prediction. *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI 2015)*, 2327–2333. https://www.ijcai.org/Proceedings/15/Papers/329.pdf

Dogra, V., Alharithi, F. S., Álvarez, R. M., Singh, A., & Qahtani, A. M. (2022). NLP-based application for analyzing private and public banks stocks reaction to news events in the Indian stock exchange. *Systems*, *10*(6), Article 233. https://doi.org/10.3390/systems10060233

Dolphin, R., Dursun, J., Blankenship, J., Adams, K., & Pike, Q. (2026). Grounded event extraction from SEC 8-K filings with a fine-grained taxonomy. https://doi.org/10.48550/arXiv.2607.08346

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, *7*(1), 1–26. https://doi.org/10.1214/aos/1176344552

Elli, F. G. (2025). Impact Twitter (X) sentiment to abnormal return IDX30 stocks. *Quantitative Economics and Management Studies*, *6*(3), 470–482. https://doi.org/10.35877/454RI.qems4003

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, *25*(2), 383–417. https://doi.org/10.2307/2325486

Fama, E. F., Fisher, L., Jensen, M. C., & Roll, R. (1969). The adjustment of stock prices to new information. *International Economic Review*, *10*(1), 1–21. https://doi.org/10.2307/2525569

Fauzi, A. A., & Mutasowifin, A. (2021). Dampak stock split terhadap abnormal return pada emiten terdaftar di Bursa Efek Indonesia. *Jurnal Dinamika Ekonomi Pembangunan*, *4*(2), 75–83. https://doi.org/10.33005/jdep.v4i2.302

Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, *27*(8), 861–874. https://doi.org/10.1016/j.patrec.2005.10.010

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, *29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Gao, Z., Jiang, W., & Yan, Y. (2025). Detecting lookahead bias in LLM forecasts. https://doi.org/10.48550/arXiv.2512.23847

Intan, K. (2021, January 21). *Mengenal klasifikasi indeks sektoral berdasarkan IDX-IC*. Kontan.co.id. Retrieved October 16, 2026, from https://investasi.kontan.co.id/news/mengenal-klasifikasi-indeks-sektoral-berdasarkan-idx-ic

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. *Machine Learning: ECML-98*, *1398*, 137–142. https://doi.org/10.1007/BFb0026683

Kargarzadeh, A., Khaledian, N., Parvini, N., Ghatak, S., & Khaledian, A. (2026). Buy the rumor, sell the news: When is news priced in? https://doi.org/10.48550/arXiv.2608.14014

Kearney, C., & Liu, S. (2014). Textual sentiment in finance: A survey of methods and models. *International Review of Financial Analysis*, *33*, 171–185. https://doi.org/10.1016/j.irfa.2014.02.006

Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. *Proceedings of the 28th International Conference on Computational Linguistics*, 757–770. https://doi.org/10.18653/v1/2020.coling-main.66

Kusuma, F. W., Kusumadinata, A. A., & Putra, H. A. A. (2026). Analisis sentimen berita keuangan berbahasa Indonesia menggunakan IndoBERT dan LSTM untuk klasifikasi tren harga saham pada lima emiten blue chip LQ45. *Jurnal Ilmu Komputer dan Sistem Informasi*, *5*(2), 462–473. https://doi.org/10.70340/jirsi.v5i2.407

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159–174. https://doi.org/10.2307/2529310

Laudon, K. C., & Laudon, J. P. (2020). *Sistem informasi manajemen*. Pearson Education.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, *2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30*, 4765–4774.

Luss, R., & d'Aspremont, A. (2015). Predicting abnormal returns from news using text classification. *Quantitative Finance*, *15*(6), 999–1012. https://doi.org/10.1080/14697688.2012.672762

MacKinlay, A. C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, *35*(1), 13–39.

Maharani, N. P. I., Yustiawan, Y., Rochim, F. C., & Purwarianti, A. (2023). Domain-specific language model post-training for Indonesian financial NLP. *2023 International Conference on Electrical Engineering and Informatics (ICEEI)*, 1–6. https://doi.org/10.1109/ICEEI59426.2023.10346625

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, *12*(2), 153–157. https://doi.org/10.1007/BF02295996

Pressman, R. S. (2019). *Rekayasa perangkat lunak: Pendekatan praktisi*. McGraw-Hill Education.

Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S., & Ré, C. (2017). Snorkel: Rapid training data creation with weak supervision. *Proceedings of the VLDB Endowment*, *11*(3), 269–282. https://doi.org/10.14778/3157794.3157797

Ruan, L., & Jiang, H. (2025). Stock price prediction using FinBERT-enhanced sentiment with SHAP explainability and differential privacy. *Mathematics*, *13*(17), Article 2747. https://doi.org/10.3390/math13172747

Shaid, N. J. (2025, April 14). *Apa itu auto rejection: Penjelasan ARA dan ARB di Bursa Efek Indonesia*. Kompas.com. Retrieved October 16, 2026, from https://money.kompas.com/read/2025/04/14/225136426/apa-itu-auto-rejection-penjelasan-ara-dan-arb-di-bursa-efek-indonesia

Shapley, L. S. (1953). A value for n-person games. Dalam H. W. Kuhn & A. W. Tucker (Penyunting), *Contributions to the theory of games, volume II* (pp. 307–317). Princeton University Press. https://doi.org/10.1515/9781400881970-018

Sidik, S. (2021, January 25). *Wow! saat ini bursa ri punya indeks techno*. CNBC Indonesia. Retrieved October 16, 2026, from https://www.cnbcindonesia.com/market/20210125161826-17-218577/wow-saat-ini-bursa-ri-punya-indeks-techno

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, *45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, *28*(1), 11–21. https://doi.org/10.1108/eb026526

Sudirman, M. D., Choiriyah, U., & Rizkia, A. A. (2026). Analisis pengaruh pengumuman right issue dan stock split terhadap abnormal return saham periode 2022–2024. *Journal of Economic, Bussines and Accounting (COSTING)*, *9*(1). https://doi.org/10.31539/3gct5f07

Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, *62*(3), 1139–1168. https://doi.org/10.1111/j.1540-6261.2007.01232.x

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems 30*, 5998–6008.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, 843–857. https://doi.org/10.18653/v1/2020.aacl-main.85

Willmott, C. J., & Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, *30*, 79–82. https://doi.org/10.3354/cr030079

Xiang, B. (1993). The choice of return-generating models and cross-sectional dependence in event studies. *Contemporary Accounting Research*, *9*(2), 365–394. https://doi.org/10.1111/j.1911-3846.1993.tb00887.x

Zhou, Z., Ma, L., & Liu, H. (2021). Trade the event: Corporate events detection for news-based event-driven trading. *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 2114–2124. https://doi.org/10.18653/v1/2021.findings-acl.186

# LAMPIRAN A

# *SOURCE CODE*

## A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

*Listing* A.1 Binary search code

```
% -- Example of pseudocode and source code listing --
% -- Gunakan minipage agar listing tidak terpotong ke halaman berikutnya --



\begin{minipage}{\textwidth}
\begin{lstlisting}[caption={Iterative binary search in Python}, label={lst:binary_iter}, frame=single, captionpos=t, language=Python]
def binary_search(arr, target):
    """
    Performs binary search on a sorted array.

    Args:
        arr: A sorted list of elements
        target: The element to search for

    Returns:
        Index of target if found, -1 otherwise
    """
    left = 0
    right = len(arr) - 1

    while left <= right:
        mid = (left + right) // 2

        if arr[mid] == target:
            return mid
        elif arr[mid] < target:
            left = mid + 1
        else:
```

```
            right = mid - 1

    return -1


\end{lstlisting}
\end{minipage}
```

## A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas