Perbandingan Model *Machine Learning* dan Metode *Explainable AI* untuk Prediksi *Cumulative Abnormal Return* Emiten IDX80 Berdasarkan Jenis Peristiwa pada Berita Berbahasa Indonesia

Proposal Tugas Akhir

Oleh

SEBASTIAN ALBERN NUGROHO
18223074



PROGRAM STUDI SISTEM DAN TEKNOLOGI INFORMASI
SEKOLAH TEKNIK ELEKTRO DAN INFORMATIKA
INSTITUT TEKNOLOGI BANDUNG

30 Oktober 2026

LEMBAR PENGESAHAN

Perbandingan Model *Machine Learning* dan Metode *Explainable AI* untuk Prediksi *Cumulative Abnormal Return* Emiten IDX80 Berdasarkan Jenis Peristiwa pada Berita Berbahasa Indonesia

Proposal Tugas Akhir

Oleh

SEBASTIAN ALBERN NUGROHO
18223074

Program Studi Sistem dan Teknologi Informasi
Sekolah Teknik Elektro dan Informatika
Institut Teknologi Bandung

Proposal Tugas Akhir ini telah disetujui dan disahkan
di Bandung, pada tanggal 30 Oktober 2026

Pembimbing

Dr. Nur Ulfa Maulidevi, S.T., M.Sc.

NIP. 197603092008012010

PERNYATAAN ORISINALITAS

Saya yang bertanda tangan di bawah ini menyatakan dengan sesungguhnya bahwa:

1. Proposal Tugas Akhir ini adalah hasil karya saya sendiri yang dibuat dengan sebenar-benarnya sesuai dengan kaidah ilmiah dan etika akademik.
2. Semua sumber rujukan dan data yang saya gunakan dalam penyusunan laporan ini, baik yang berupa kutipan langsung maupun tidak langsung, telah saya cantumkan sumbernya dengan baik dan benar sesuai dengan ketentuan penulisan Proposal Tugas Akhir.
3. Isi proposal ini belum pernah diajukan pada program pendidikan di institusi mana pun.

Apabila di kemudian hari terbukti bahwa dokumen laporan ini melanggar hal-hal di atas, saya bersedia menerima sanksi sesuai dengan peraturan yang berlaku di Institut Teknologi Bandung.

Bandung, 30 Oktober 2026

SEBASTIAN ALBERN NUGROHO
NIM: 18223074

PERNYATAAN PENGGUNAAN AI

Saya yang bertanda tangan di bawah ini menyatakan bahwa dalam penulisan Proposal Tugas Akhir ini, saya telah menggunakan alat bantu kecerdasan artifisial (AI) untuk beberapa aspek tertentu. Berikut adalah rincian penggunaan AI dalam penulisan tesis ini.

No.	Jenis	Alat Bantu	Tingkat	Tempat
1	Memeriksa ejaan dan tata bahasa	Grammarly	Tinggi	Semua bab
2	Pembuatan teks	Microsoft Copilot	Sedang	Bab II dan Sub-bab III.2 hal. 34
3	Pembuatan grafik, gambar, atau ilustrasi	Tidak ada	Tidak ada	Tidak ada
4	Pencarian informasi atau referensi	…	…	…
5	Menjelaskan definisi, konsep, gambar, tabel, atau topik tertentu	…	…	…
6	Penyusunan kode program	…	…	…
7	Penyusunan formula atau perhitungan matematis	…	…	…
8	Analisis data	…	…	…
9	Penyusunan kesimpulan atau rekomendasi	…	…	…
10	Lainnya (jelaskan)	…	…	…

Bandung, 30 Oktober 2026

SEBASTIAN ALBERN NUGROHO
NIM: 18223074

DAFTAR ISI

LEMBAR PENGESAHAN iii
PERNYATAAN ORISINALITAS v
PERNYATAAN PENGGUNAAN AI vii
DAFTAR ISI ix
DAFTAR GAMBAR xi
DAFTAR TABEL xiii
DAFTAR PERSAMAAN xv
DAFTAR ALGORITMA xvii
DAFTAR KODE PROGRAM xix
DAFTAR SINGKATAN xxi
DAFTAR SIMBOL xxiii

BAB I PENDAHULUAN **1**
I.1 Latar Belakang 1
I.2 Rumusan Masalah 4
I.3 Tujuan 5
I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah 6
I.5 Hipotesis Tugas Akhir 7
I.6 Metodologi 8
I.7 Sistematika Penulisan 9

BAB II STUDI LITERATUR **11**
II.1 Pasar Modal Indonesia sebagai Objek Kajian 11
II.1.1 IHSG dan Indeks IDX80 11
II.1.2 Klasifikasi Sektor IDX-IC dan Indeks Sektoral 12
II.1.3 Batas Auto Rejection dan Suspensi Perdagangan 13
II.1.4 Berita sebagai Sumber Informasi bagi Pasar 13
II.2 Efisiensi Pasar dan *Event Study* 14
II.2.1 Hipotesis Pasar Efisien 14
II.2.2 Tahapan *Event Study* 15
II.2.3 *Return*, *Abnormal Return*, dan *Cumulative Abnormal Return* 15
II.3 Model *Return* yang Diharapkan 17
II.3.1 Model Rata-Rata Konstan dan Model *Market-Adjusted* . . 17
II.3.2 *Market Model* 18
II.3.3 Model Indeks Dua Faktor 18
II.4 Pemrosesan Teks Berita untuk Analisis Saham 20
II.4.1 Sentimen dan Jenis Peristiwa 20
II.4.2 Klasifikasi Berbasis Aturan dan Supervisi Lemah 21
II.4.3 TF-IDF dengan Logistic Regression dan SVM 21
II.4.4 Transformer, BERT, dan IndoBERT 22
II.4.5 Anotasi dan Kesepakatan Antaranotator 23
II.5 Model Regresi untuk Prediksi CAR 23
II.5.1 Linear Regression 24
II.5.2 Random Forest 24

II.5.3 *Gradient Boosting* dan XGBoost . . . 25
II.5.4 LightGBM . . . 26
II.5.5 Model Berbasis Pohon pada Data Tabular . . . 26
II.6 Metode *Explainable AI* . . . 27
II.6.1 SHAP . . . 27
II.6.2 LIME . . . 28
II.6.3 *Permutation Importance* . . . 29
II.6.4 Kriteria Perbandingan Metode XAI . . . 29
II.7 Metrik Evaluasi dan Uji Signifikansi . . . 30
II.7.1 Metrik Regresi . . . 30
II.7.2 Ketepatan Arah dengan Zona Netral . . . 30
II.7.3 Metrik Klasifikasi Jenis Peristiwa . . . 31
II.7.4 Uji Signifikansi Selisih Kinerja . . . 31
II.8 Penelitian Terkait . . . 32
II.8.1 Penelitian Berbasis Berita di Indonesia . . . 32
II.8.2 *Event Study* di Bursa Efek Indonesia . . . 33
II.8.3 Peristiwa dari Teks dan *Abnormal Return* . . . 33
II.8.4 Perbandingan Model untuk Prediksi *Return* . . . 34
II.8.5 *Explainable AI* untuk Prediksi Saham . . . 35
II.8.6 Posisi Penelitian . . . 35

BAB III ANALISIS MASALAH . . . 39
III.1 Analisis Kondisi Saat Ini . . . 39
III.2 Analisis Kebutuhan . . . 39
III.2.1 Identifikasi Masalah Pengguna . . . 39
III.2.2 Kebutuhan Fungsional . . . 39
III.2.3 Kebutuhan Nonfungsional . . . 40
III.3 Analisis Pemilihan Solusi . . . 40
III.3.1 Alternatif Solusi . . . 40
III.3.2 Analisis Penentuan Solusi . . . 40

BAB IV DESAIN KONSEP SOLUSI . . . 43

BAB V RENCANA SELANJUTNYA . . . 45

DAFTAR PUSTAKA . . . 47

Lampiran A *SOURCE CODE* . . . 55
A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik . . . 55
A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak . . . 56

Daftar Gambar

II.1 Linimasa jendela estimasi dan jendela peristiwa yang digunakan dalam penelitian ini 15

Daftar Tabel

II.1 Sektor dan kode indeks sektoral IDX-IC 12
II.2 Perbandingan model *return* yang diharapkan 20
II.3 Perbandingan karakteristik metode XAI yang digunakan 30
II.4 Perbandingan komponen penelitian terdahulu dengan penelitian ini . 36

DAFTAR PERSAMAAN

II.1 *Return* harian emiten 16
II.2 *Abnormal return* 16
II.3 *Cumulative abnormal return* 16
II.4 Arah CAR aktual dengan zona netral 17
II.5 *Abnormal return* model *market-adjusted* 17
II.6 *Market model* 18
II.7 Model indeks dua faktor 19
II.8 *Abnormal return* model dua faktor 19
II.9 Simpangan baku residual pada jendela estimasi 19
II.10 Bobot TF-IDF 22
II.11 Cohen's kappa 23
II.12 Linear Regression 24
II.13 Prediksi Random Forest 25
II.14 Prediksi XGBoost 25
II.15 Fungsi objektif XGBoost 25
II.16 Model penjelasan aditif SHAP 27
II.17 Nilai Shapley 28
II.18 Objektif LIME 28
II.19 *Permutation importance* 29
II.20 *Mean absolute error* 30
II.21 *Root mean squared error* 30
II.22 Ketepatan arah dengan zona netral 31
II.23 F1 per kelas dan F1-macro 31
II.24 Statistik uji McNemar 32

DAFTAR ALGORITMA

DAFTAR *LISTING*

A.1 Binary search code 55

DAFTAR SINGKATAN

Singkatan	Deskripsi	Pemakaian pertama kali
AI	*Artificial Intelligence*	1
CNN	*Convolutional Neural Network*	2
GPU	*Graphics Processing Unit*	14

DAFTAR SIMBOL

Notasi	Deskripsi	Pemakaian pertama kali
α	Koefisien bobot untuk *loss function*, tingkat signifikansi statistik	75
β	Koefisien bobot untuk *Binary Cross-Entropy loss*	75
λ	Koefisien bobot untuk CTC *loss*, parameter regularisasi	75
θ	Parameter model *neural network*	75
σ	Deviasi standar	75
μ	Rata-rata (*mean*)	75
ϵ	*Token blank*/kosong dalam CTC, konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	*Alignment path* dalam CTC	75
π_t	*Token* pada *timestep* t dalam *alignment path*	76
∇ atau ∂	Operator gradien atau turunan parsial	75
$\sum$	Operator penjumlahan	75
$\prod$	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi *loss* (kerugian)	75
$\mathcal{L}_{total}$	Total *loss function*	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	*Adversarial loss*	75
$\mathcal{L}_{reconstruction}$	*Reconstruction loss*	75
$\mathcal{L}_{L1}$	L1 *loss* (*Mean Absolute Error*)	75
$\mathcal{L}_{L2}$	L2 *loss* (*Mean Squared Error*)	75
$\mathcal{L}_{CTC}$	CTC (*Connectionist Temporal Classification*) *loss*	75
$\mathcal{L}_{perceptual}$	*Perceptual loss*	75

$\mathcal{L}_{pixel}$	*Pixel-wise loss*	75
$\mathcal{L}_{BCE}$	*Binary Cross-Entropy loss*	75
$\mathcal{L}_{GAN}$	GAN *loss*	75
$\mathcal{L}_{cycle}$	*Cycle consistency loss*	75
G	*Generator* dalam GAN	75
D	*Discriminator* dalam GAN	75
$G(z)$	*Output* dari *generator* dengan *input* z	75
$D(x)$	*Output* dari *discriminator* dengan *input* x	75
$G_{A \to B}$	*Generator* dari domain A ke B	75
$G_{B \to A}$	*Generator* dari domain B ke A	75
$V(D, G)$	Fungsi nilai (*value function*) dalam GAN	75
x	Sampel data asli, *input* citra	75
y	Label atau *ground truth*, kondisi dalam *conditional GAN*	75
z	*Noise vector* atau representasi laten	
$\mathbb{E}$	Ekspektasi atau nilai harapan	75
p_{data}	Distribusi data asli	75
p_z	Distribusi *prior* (*noise*)	75
$p(y\|x)$	Probabilitas bersyarat *output* y *given input* x	75
$p_t(\pi_t\|x)$	Probabilitas *token* pada *timestep* t	
$\mathcal{B}$	Fungsi penciutan (*collapse function*) dalam CTC	75
$\mathcal{B}^{-1}$	Fungsi invers penciutan dalam CTC	75
T	Jumlah *timestep* atau panjang *sequence*	
$\|x - G(y)\|_1$	L1 *distance* antara *ground truth* dan *generated image*	75
$\|x - G(y)\|_2$	L2 *distance* antara *ground truth* dan *generated image*	75
$N \times N$	Ukuran *patch* dalam PatchGAN	
d	Cohen's d (*effect size*)	75
n	Jumlah sampel	75
p	*p-value* (nilai probabilitas statistik)	75

r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

BAB I

PENDAHULUAN

I.1 Latar Belakang

Pergerakan harga saham suatu emiten di Bursa Efek Indonesia (BEI) tidak selalu disebabkan oleh berita yang berkaitan langsung dengan perusahaan tersebut. Harga suatu emiten dapat turun karena Indeks Harga Saham Gabungan (IHSG) sedang melemah, karena sektor industrinya sedang tertekan, atau karena terdapat berita yang secara khusus menyangkut perusahaan, seperti kasus hukum, pergantian direksi, atau rilis laporan keuangan. Dalam kajian keuangan, dampak suatu peristiwa terhadap nilai perusahaan umumnya diukur melalui *event study*. Pendekatan ini memanfaatkan asumsi bahwa informasi baru akan tercermin pada harga saham, sehingga dampaknya dapat diukur dari *abnormal return*, yaitu selisih antara *return* aktual dan *return* yang diharapkan berdasarkan kondisi pasar (Brown & Warner, 1985; MacKinlay, 1997). Bagi investor dan analis, pemisahan antara pengaruh pasar, pengaruh sektor, dan pengaruh berita menjadi penting karena menentukan bagaimana suatu informasi seharusnya ditanggapi.

Selain pengaruh pasar secara umum, pergerakan sektor juga perlu diperhitungkan dalam menghitung *return* yang diharapkan. Sejak 25 Januari 2021, BEI menerapkan klasifikasi IDX Industrial Classification (IDX-IC) yang menggantikan JASICA dan menyediakan sebelas indeks sektoral, seperti IDXENERGY, IDXBASIC, IDXFINANCE, dan IDXTECHNO (Sidik, 2021). Ketersediaan indeks sektoral ini memungkinkan *return* yang diharapkan dihitung tidak hanya dari pergerakan IHSG, tetapi juga dari pergerakan sektor emiten. Xiang (1993) menunjukkan bahwa faktor industri menjelaskan rata-rata 6,7% variasi residual *market model* pada data harian dan 11,5% pada data mingguan. Penelitian tersebut juga menyimpulkan bahwa apabila *return* saham sebenarnya mengikuti model dua faktor (pasar dan industri), inferensi yang hanya didasarkan pada *market model* menjadi tidak valid. Dengan demikian, koreksi terhadap pengaruh sektor diperlukan agar bagian *return* yang dikaitkan dengan berita tidak tercampur dengan pergerakan sektor.

Penelitian di Indonesia yang memanfaatkan berita untuk memahami pergerakan saham sejauh ini umumnya berfokus pada analisis sentimen. Attar (2024) menggunakan IndoBERT untuk mengklasifikasikan sentimen 2.857 berita saham dan memperoleh akurasi 0,78, kemudian mengukur korelasinya dengan pergerakan harga per sektor dengan korelasi Pearson tertinggi sebesar 0,389 pada sektor *basic materials*. Alamsyah dkk. (2025) menganalisis 192.582 berita keuangan Indonesia periode 2018 sampai 2023 dan menemukan bahwa korelasi sentimen dengan harga meningkat dari 0,26 pada tingkat perusahaan menjadi 0,30 pada tingkat industri dan 0,43 pada klaster emiten yang sering muncul bersama di berita. Kusuma dkk. (2026) menggabungkan sentimen IndoBERT dari 9.819 berita CNBC Indonesia dengan data harga untuk mengklasifikasikan tren harga lima emiten LQ45 menggunakan LSTM. Ketiga penelitian tersebut menunjukkan bahwa berita berbahasa Indonesia memiliki keterkaitan dengan pergerakan harga saham. Namun, informasi berita yang digunakan masih terbatas pada sentimen, sedangkan targetnya berupa harga atau tren harga mentah.

Penggunaan sentimen saja memiliki keterbatasan karena sentimen hanya menggambarkan nada berita, bukan jenis peristiwa yang terjadi. Berita mengenai direktur yang ditetapkan sebagai tersangka korupsi dan berita mengenai laba yang turun sesuai ekspektasi analis sama-sama bernada negatif, tetapi keduanya merupakan peristiwa yang berbeda. Zhou dkk. (2021) memandang peristiwa korporasi sebagai penggerak pergerakan saham dan membangun model deteksi peristiwa dari berita sebagai dasar strategi *trading*, berbeda dengan model yang langsung memanfaatkan fitur teks dan sentimen. Dolphin dkk. (2026) juga melakukan *event study* terhadap besar *abnormal return* tanpa memperhatikan arahnya pada laporan 8-K dan menunjukkan bahwa kategori peristiwa yang lebih rinci dapat membedakan peristiwa korporasi yang secara ekonomi berbeda. Selain itu, penggunaan harga mentah sebagai target membuat pengaruh berita bercampur dengan pengaruh pasar dan sektor. Akibatnya, model dapat mempelajari pola yang sebenarnya berasal dari pergerakan IHSG atau sektor, bukan dari berita.

Penelitian di Indonesia yang sudah menggunakan *abnormal return* juga masih memiliki keterbatasan. Elli (2025) menguji hubungan sentimen 23.406 *tweet* dengan *abnormal return* saham IDX30 pada periode Juli sampai Desember 2023 menggunakan uji kausalitas Granger. Sumber data yang digunakan berupa *tweet* dan analisisnya bersifat statistik, bukan model prediksi untuk setiap berita. Di sisi lain, beberapa *event study* di BEI meneliti satu atau dua jenis peristiwa yang ditentukan secara manual, misalnya *stock split* pada periode 2015 sampai 2019 (Fauzi & Mutasowifin,

2021) serta *right issue* dan *stock split* pada periode 2022 sampai 2024 (Sudirman dkk. 2026). Pada penelitian Sudirman dkk. (2026), *abnormal return* dihitung sebagai selisih *return* saham terhadap *return* IHSG, sehingga pengaruh sektor belum dikoreksi. Pendekatan tersebut juga belum dapat digunakan untuk menilai berita baru secara otomatis karena peristiwa dan tanggalnya harus ditentukan terlebih dahulu oleh peneliti.

Pada tingkat global, otomatisasi deteksi peristiwa dari teks dan pengukuran *abnormal return* sudah mulai dilakukan. Kargarzadeh dkk. (2026) menggunakan *large language model* (LLM) sebagai *teacher* yang kemudian didistilasi menjadi *classifier* untuk memberi 17 label peristiwa pada 4,57 juta artikel berita, lalu mengukur *abnormal return* yang disesuaikan dengan beta pada sekitar 3.000 saham Amerika Serikat. Dolphin dkk. (2026) juga memanfaatkan LLM untuk memberi label 119 jenis peristiwa pada sekitar 293.000 laporan 8-K. Kedua penelitian tersebut berfokus pada pasar Amerika Serikat, dan *abnormal return* pada penelitian Kargarzadeh dkk. (2026) hanya dikoreksi terhadap pengaruh pasar melalui beta. Penggunaan LLM juga memiliki risiko tersendiri. Gao dkk. (2025) menemukan bahwa LLM menunjukkan kecenderungan *look-ahead* yang tinggi pada periode data pelatihannya, tetapi kecenderungan tersebut hampir hilang setelah batas waktu data pelatihan. Hal ini menunjukkan bahwa kinerja prediksi LLM pada data historis dapat dipengaruhi oleh informasi mengenai hasil yang sebenarnya sudah terjadi.

Selain pilihan target, kinerja prediksi juga bergantung pada model yang digunakan. Gu dkk. (2020) membandingkan model linear, model berbasis pohon, dan *neural network* untuk memprediksi *return* saham Amerika Serikat dan menemukan bahwa model berbasis pohon dan *neural network* memberikan hasil terbaik karena mampu menangkap interaksi nonlinear antarprediktor. Pada data tabular secara umum, Grinsztajn dkk. (2022) menunjukkan bahwa model berbasis pohon masih mengungguli model *deep learning* pada dataset berukuran sedang. Penelitian yang paling dekat dengan prediksi *abnormal return*, yaitu Amel-Zadeh dkk. (2020), memprediksi tanda dan besar *abnormal return* di sekitar pengumuman laba dan menemukan bahwa Random Forest dan *recurrent neural network* mengungguli *deep neural network* serta model linear seperti OLS dan Lasso. Di sisi lain, prediksi arah pergerakan dari berita memiliki tingkat kesulitan yang tinggi. Luss dan d'Aspremont (2015) menemukan bahwa arah *return* intrahari tidak dapat diprediksi menggunakan teks maupun *return* historis, tetapi besarnya pergerakan dapat diprediksi. Temuan-temuan tersebut menunjukkan bahwa pemilihan model perlu dibuktikan melalui perbandingan, dan evaluasinya perlu mencakup besar serta arah *abnormal return*.

Keluaran model prediksi juga perlu dapat dijelaskan agar faktor yang mendasari suatu prediksi dapat dipahami. Tinjauan sistematis terhadap 138 artikel menunjukkan bahwa *feature importance*, SHAP, dan metode berbasis aturan merupakan pendekatan *explainable AI* (XAI) yang paling banyak digunakan di bidang keuangan (Černevičienė & Kabašinskas, 2024). Ruan dan Jiang (2025) menggunakan SHAP untuk menjelaskan prediksi XGBoost dengan fitur sentimen FinBERT pada saham S&P 500, sedangkan Gite dkk. (2021) menggunakan LIME untuk menjelaskan prediksi harga saham dari berita. Namun, setiap metode XAI memiliki cara kerja yang berbeda dan dapat menghasilkan penjelasan yang berbeda pula. Alvarez-Melis dan Jaakkola (2018) menunjukkan bahwa metode yang berbasis perturbasi, seperti LIME, dapat menghasilkan penjelasan yang tidak stabil terhadap perubahan kecil pada input. Penelitian yang memakai satu metode XAI saja belum dapat menunjukkan apakah penjelasan yang dihasilkan konsisten apabila metode lain digunakan.

Berdasarkan kondisi tersebut, penelitian ini membandingkan empat model regresi dan tiga metode XAI untuk memprediksi *cumulative abnormal return* (CAR) emiten IDX80 berdasarkan berita berbahasa Indonesia. Target yang diprediksi adalah $CAR[0, +1]$, yaitu jumlah *abnormal return* pada hari terbitnya berita dan hari bursa berikutnya, yang dihitung dengan model dua faktor menggunakan IHSG dan indeks sektoral IDX-IC. Fitur utama dari berita adalah jenis peristiwa, ditambah sentimen, keterlibatan emiten, intensitas, dan waktu terbit, yang digabungkan dengan kondisi pasar yang tersedia sebelum berita terbit. Model yang dibandingkan adalah Linear Regression, Random Forest (Breiman, 2001), XGBoost (Chen & Guestrin, 2016), dan LightGBM (Ke dkk. 2017), sedangkan metode XAI yang dibandingkan adalah SHAP (Lundberg & Lee, 2017), LIME (Ribeiro dkk. 2016), dan *permutation importance* (Fisher dkk. 2019). Seluruh *pipeline* dirancang tanpa LLM generatif untuk menjaga *reproducibility*, menghindari risiko *look-ahead bias*, dan menjaga transparansi rantai penjelasan. Berdasarkan penelusuran literatur yang telah dilakukan, belum ditemukan penelitian yang membandingkan model prediksi dan metode XAI untuk memprediksi *abnormal return* emiten BEI yang dikoreksi IHSG dan indeks sektor berdasarkan jenis peristiwa dari berita berbahasa Indonesia.

I.2 Rumusan Masalah

Penelitian yang memanfaatkan berita saham berbahasa Indonesia masih menggunakan sentimen sebagai satu-satunya informasi dari berita dan harga mentah sebagai target, sehingga dampak berita tidak dapat dipisahkan dari pengaruh pasar dan sektor. Sementara itu, pengukuran *abnormal return* di BEI masih dilakukan melalui

event study dengan peristiwa yang ditentukan secara manual. Di tingkat global, perbandingan model untuk memprediksi *return* umumnya memakai fitur keuangan atau harga, bukan jenis peristiwa dari berita, sedangkan penelitian prediksi saham yang paling dekat, seperti Ruan dan Jiang (2025) dan Gite dkk. (2021), masing-masing hanya memakai satu metode XAI tanpa membandingkannya dengan metode lain. Akibatnya, belum diketahui model mana yang paling sesuai untuk memprediksi *abnormal return* emiten BEI dari jenis peristiwa berita, serta metode XAI mana yang menghasilkan penjelasan paling andal untuk model tersebut. Berdasarkan uraian tersebut, rumusan masalah dalam penelitian ini adalah sebagai berikut.

1. Bagaimana perbandingan kinerja Linear Regression, Random Forest, XGBoost, dan LightGBM dalam memprediksi besar dan arah $CAR[0, +1]$ emiten IDX80 berdasarkan fitur jenis peristiwa dari berita berbahasa Indonesia dan kondisi pasar sebelum berita terbit?
2. Model mana yang menghasilkan kinerja terbaik, dan apakah selisih kinerjanya dengan model lain signifikan secara statistik?
3. Bagaimana perbandingan SHAP, LIME, dan *permutation importance* dalam menjelaskan prediksi model, ditinjau dari kestabilan penjelasan, kesepakatan antarmetode, dan waktu komputasi?
4. Faktor berita dan kondisi pasar apa saja yang memberikan kontribusi terbesar terhadap prediksi $CAR[0, +1]$ berdasarkan metode XAI tersebut?

I.3 Tujuan

Tujuan penelitian ini adalah sebagai berikut.

1. Menyusun dataset pasangan berita dan emiten IDX80 periode 2021 sampai 2025 dengan target $CAR[0, +1]$ yang dikoreksi IHSG dan indeks sektoral IDX-IC.
2. Menyusun dataset berita saham berbahasa Indonesia yang berlabel jenis peristiwa, termasuk *test set* emas yang dilabeli secara manual oleh dua anotator.
3. Membandingkan kinerja Linear Regression, Random Forest, XGBoost, dan LightGBM dalam memprediksi besar dan arah $CAR[0, +1]$.
4. Membandingkan SHAP, LIME, dan *permutation importance* dari sisi kestabilan penjelasan, kesepakatan antarmetode, dan waktu komputasi.
5. Mengidentifikasi faktor berita dan kondisi pasar yang paling berkontribusi terhadap prediksi $CAR[0, +1]$, baik secara global maupun pada tingkat berita.

Keberhasilan penelitian ditentukan oleh beberapa kriteria. Pertama, *pipeline* penelitian dapat dijalankan secara utuh dan dapat direproduksi, mulai dari pengumpulan data sampai penjelasan prediksi. Kedua, kualitas anotasi *test set* emas mencapai

nilai Cohen's kappa sekurang-kurangnya 0,6. Ketiga, keempat model dievaluasi pada data uji periode 2025 yang tidak digunakan dalam pelatihan maupun penyetelan, dengan sampel yang sama dan kesempatan penyetelan yang setara. Keempat, selisih kinerja antarmodel dilaporkan beserta uji signifikansinya, dan perbandingan ketiga metode XAI dilaporkan menggunakan kriteria yang telah ditetapkan. Hasil yang menunjukkan bahwa model berbasis pohon tidak lebih baik daripada model linear tetap dianggap sebagai temuan yang sah dan dilaporkan apa adanya.

I.4 Ruang Lingkup, Asumsi, dan Batasan Masalah

Ruang lingkup penelitian ini mencakup emiten konstituen IDX80 dengan mengikuti daftar konstituen yang berlaku pada setiap periode. Pasangan berita dan emiten hanya dimasukkan ke dalam dataset apabila emiten tersebut termasuk konstituen IDX80 pada tanggal berita terbit, sehingga sampel tidak hanya berisi emiten yang bertahan sampai akhir periode dan risiko *survivorship bias* dapat dikurangi. Periode data yang digunakan adalah 2021 sampai 2025, menyesuaikan dengan ketersediaan indeks sektoral IDX-IC sejak Januari 2021. Karena estimasi parameter *abnormal return* membutuhkan data historis sebelum berita, sampel berita direncanakan mulai sekitar Juli 2021. Data berita dikumpulkan dari CNBC Indonesia, Detik Finance, dan CNN Indonesia bagian ekonomi, sedangkan data harga saham, IHSG, dan indeks sektoral diperoleh dari sumber publik. Jenis peristiwa dibatasi pada enam kategori utama, yaitu hukum atau korupsi, laporan keuangan, pergantian direksi, kebijakan pemerintah, aksi korporasi, dan operasional, ditambah kategori pergerakan harga dan kategori lainnya.

Penelitian ini menggunakan beberapa asumsi. *Abnormal return* diasumsikan sebagai proksi dampak berita, yaitu bagian dari *return* emiten yang tidak dapat dijelaskan oleh pergerakan IHSG dan indeks sektornya. Waktu terbit berita diasumsikan tercatat dengan akurat hingga satuan menit, sehingga berita yang terbit setelah perdagangan ditutup sekitar pukul 16.00 WIB atau pada hari libur dapat dialokasikan ke hari bursa berikutnya. Data harga yang digunakan diasumsikan telah disesuaikan terhadap *stock split* dan dividen. Parameter *return* yang diharapkan diasumsikan dapat diestimasi dari data historis sebelum berita terbit.

Penelitian ini memiliki beberapa batasan. Penelitian tidak dimaksudkan untuk menyatakan bahwa suatu berita secara mutlak menyebabkan perubahan harga, melainkan memberikan estimasi keterkaitan statistik berdasarkan pola historis. Data harga yang digunakan merupakan data harian, sehingga hasil penelitian tidak ditujukan sebagai alat *trading* harian. Berita yang hanya melaporkan pergerakan harga dikelu-

arkan dari data model untuk mencegah *data leakage*. Untuk peristiwa berskala sektor, seperti kebijakan pemerintah yang berlaku pada satu sektor, *abnormal return* juga dihitung dengan koreksi IHSG saja karena koreksi sektor dapat menghapus dampak peristiwa tersebut. Sampel yang jatuh pada hari suspensi tidak digunakan, keterbatasan akibat mekanisme *auto rejection* dicatat sebagai batasan, dan emiten yang data harganya tidak tersedia secara memadai dikeluarkan dengan jumlah yang dilaporkan. *Classifier* jenis peristiwa tidak dibandingkan melalui eksperimen, melainkan dipilih berdasarkan kajian literatur pada Bab III. Seluruh *pipeline* tidak menggunakan LLM generatif.

I.5 Hipotesis Tugas Akhir

Hipotesis penelitian ini disusun berdasarkan beberapa premis. Premis pertama, model berbasis pohon mampu menangkap interaksi nonlinear antarfitur dan cenderung mengungguli model linear pada data tabular (Grinsztajn dkk. 2022) maupun pada prediksi *return* saham (Gu dkk. 2020). Premis kedua, pada prediksi *abnormal return* di sekitar pengumuman laba, Random Forest mengungguli model linear (Amel-Zadeh dkk. 2020). Premis ketiga, arah *return* sulit diprediksi dari teks, sedangkan besarnya pergerakan lebih dapat diprediksi (Luss & d'Aspremont, 2015), sehingga ketepatan arah yang moderat tetap wajar dalam domain ini. Premis keempat, TreeSHAP menghitung nilai SHAP secara tepat untuk model berbasis pohon tanpa pengambilan sampel acak (Lundberg dkk. 2020), sedangkan LIME bergantung pada sampel acak di sekitar data sehingga penjelasannya dapat berubah ketika dijalankan ulang (Zhang dkk. 2019).

Hipotesis penelitian ini adalah sebagai berikut.

> **H1:** Model regresi berbasis pohon, yaitu Random Forest, XGBoost, dan LightGBM, menghasilkan MAE yang lebih rendah dan ketepatan arah yang lebih tinggi secara signifikan dibandingkan Linear Regression dalam memprediksi $CAR[0, +1]$ pada data uji periode 2025. Ketepatan arah dihitung dengan zona netral. Signifikansi selisih MAE diuji menggunakan *bootstrap*, sedangkan selisih ketepatan arah diuji menggunakan uji McNemar. H1 dianggap terdukung apabila setiap model berbasis pohon mengungguli Linear Regression secara signifikan.

> **H2:** SHAP menghasilkan penjelasan yang lebih stabil dibandingkan LIME ketika dijalankan berulang pada data yang sama.

I.6 Metodologi

Tahapan penelitian yang dilakukan adalah sebagai berikut.

1. **Investigasi masalah dan studi literatur.** Mengidentifikasi permasalahan serta mempelajari penelitian mengenai *event study*, *abnormal return*, analisis berita saham di Indonesia, deteksi peristiwa dari teks, model regresi berbasis pohon, dan metode XAI. Penelusuran literatur dilakukan melalui mesin pencari web, OpenAlex, dan Garuda dengan kata kunci seperti *abnormal return* berita, IndoBERT saham, dan *news event abnormal return* Indonesia. Penelusuran melalui Google Scholar dan Digilib ITB akan dilengkapi secara manual.
2. **Analisis masalah dan kebutuhan.** Menganalisis kondisi penelitian saat ini, mengaudit ketersediaan dan kualitas data berita serta data harga, menentukan kategori peristiwa dan kriteria keberhasilan, serta memilih *classifier* jenis peristiwa berdasarkan kajian literatur.
3. **Perancangan penelitian.** Merancang *pipeline* penelitian dari alur umum hingga komponen yang lebih rinci, meliputi alur data, pelabelan, perhitungan CAR, fitur, model, dan rancangan eksperimen, menggunakan diagram alur dan diagram komponen.
4. **Pengumpulan data.** Menyusun tabel referensi emiten, alias, sektor IDX-IC, dan konstituen IDX80 per periode, kemudian mengumpulkan berita dari portal terpilih serta mengunduh data harga yang telah disesuaikan untuk emiten, IHSG, dan indeks sektoral.
5. **Prapemrosesan data.** Membersihkan teks berita, menghapus duplikat, mendeteksi emiten dengan kamus alias, menentukan hari peristiwa (H0) berdasarkan waktu terbit, menyaring emiten berdasarkan konstituen IDX80 pada tanggal berita, serta membentuk sampel berupa pasangan berita dan emiten.
6. **Pelabelan jenis peristiwa.** Menyusun pedoman anotasi, membuat *test set* emas sebanyak 300 sampai 500 berita yang dilabeli dua anotator dengan target Cohen's kappa sekurang-kurangnya 0,6, serta menyusun data latih sebanyak 500 sampai 800 berita dari pra-label aturan kata kunci yang diperiksa dan dikoreksi secara manual.
7. **Perhitungan *cumulative abnormal return*.** Mengestimasi parameter α, β_1, dan β_2 dengan regresi OLS pada jendela estimasi H-130 sampai H-11, kemudian menghitung $CAR[0, +1]$ serta simpangan baku residual yang digunakan sebagai dasar zona netral untuk evaluasi arah.
8. **Pengembangan model.** Melatih *classifier* jenis peristiwa terpilih dan men-

erapkannya pada seluruh berita, mengekstraksi fitur berita serta fitur pasar yang hanya menggunakan data sampai H-1, lalu melatih Linear Regression, Random Forest, XGBoost, dan LightGBM untuk memprediksi $CAR[0, +1]$. Data dibagi secara kronologis, yaitu Juli 2021 sampai 2023 untuk pelatihan, 2024 untuk validasi dan penyetelan, dan 2025 untuk pengujian.

9. **Eksperimen dan evaluasi.** Membandingkan keempat model pada data uji 2025 menggunakan MAE dan RMSE untuk besar CAR serta ketepatan arah dengan zona netral untuk arah CAR. Signifikansi selisih MAE diuji menggunakan *bootstrap*, sedangkan selisih ketepatan arah diuji menggunakan uji McNemar.
10. **Analisis XAI.** Menerapkan SHAP, LIME, dan *permutation importance* pada model yang dibandingkan, kemudian menilai kestabilan penjelasan, kesepakatan antarmetode, dan waktu komputasi, serta memeriksa kesesuaian faktor penting dengan intuisi domain, baik secara global maupun pada studi kasus per berita.
11. **Penarikan kesimpulan.** Menyusun kesimpulan berdasarkan hasil evaluasi dan pengujian hipotesis, serta memberikan saran untuk penelitian selanjutnya.

Implementasi menggunakan bahasa Python dengan pustaka trafilatura untuk ekstraksi artikel, yfinance untuk data harga, statsmodels untuk regresi model dua faktor, Hugging Face Transformers dan Google Colab untuk pelatihan model bahasa apabila diperlukan, scikit-learn untuk Linear Regression dan Random Forest, pustaka XGBoost dan LightGBM, serta pustaka SHAP dan LIME untuk analisis XAI.

I.7 Sistematika Penulisan

Sistematika penulisan laporan tugas akhir ini adalah sebagai berikut.

1. **Bab I Pendahuluan** berisi latar belakang, rumusan masalah, tujuan, ruang lingkup, asumsi, batasan masalah, hipotesis tugas akhir, metodologi, dan sistematika penulisan.
2. **Bab II Studi Literatur** berisi pembahasan mengenai pasar modal Indonesia, *event study* dan *abnormal return*, model *return* yang diharapkan, pemrosesan teks berita dan *classifier* jenis peristiwa, model regresi, metode XAI, metrik evaluasi, serta penelitian terdahulu yang relevan.
3. **Bab III Analisis Masalah** berisi analisis kondisi penelitian saat ini, analisis kebutuhan, analisis sumber data, serta analisis pemilihan solusi, termasuk perbandingan *classifier* jenis peristiwa berdasarkan studi literatur dan pertimbangan penggunaan LLM.
4. **Bab IV Desain Konsep Solusi** berisi rancangan *pipeline* penelitian, rancangan pelabelan, rancangan perhitungan CAR, rancangan fitur dan model, serta

rancangan eksperimen perbandingan model dan metode XAI.

5. **Bab V Rencana Selanjutnya** berisi rencana pelaksanaan, jadwal kegiatan, kebutuhan yang perlu disiapkan, serta risiko dan mitigasinya.
6. **Daftar Pustaka** berisi seluruh referensi yang digunakan dalam penyusunan laporan tugas akhir.
7. **Lampiran** berisi dokumen pendukung, seperti pedoman anotasi, struktur dataset, konfigurasi eksperimen, dan hasil evaluasi tambahan.

BAB II

STUDI LITERATUR

Bab ini membahas landasan teori dan penelitian terdahulu yang digunakan untuk membandingkan model prediksi dan metode *explainable AI* (XAI) dalam memprediksi *cumulative abnormal return* emiten IDX80 berdasarkan berita. Pembahasan dimulai dari karakteristik pasar modal Indonesia yang menjadi objek kajian, kemudian dilanjutkan dengan teori efisiensi pasar dan *event study* sebagai dasar pengukuran dampak berita. Setelah itu, bab ini menjelaskan model *return* yang diharapkan, pemrosesan teks berita dan *classifier* jenis peristiwa, model regresi, metode XAI, serta metrik evaluasi yang digunakan. Bagian terakhir meninjau penelitian terdahulu yang relevan untuk menunjukkan posisi penelitian ini terhadap solusi yang sudah ada.

II.1 Pasar Modal Indonesia sebagai Objek Kajian

II.1.1 IHSG dan Indeks IDX80

Bursa Efek Indonesia (BEI) menyediakan sejumlah indeks yang menggambarkan pergerakan harga saham secara agregat. Indeks Harga Saham Gabungan (IHSG) merupakan indeks yang paling umum digunakan sebagai gambaran kondisi pasar secara keseluruhan, sehingga dalam penelitian ini IHSG diperlakukan sebagai faktor pasar. Selain IHSG, BEI juga menyusun indeks dengan jumlah konstituen yang lebih kecil, seperti IDX80, LQ45, dan IDX30. Menurut panduan metodologi BEI, IDX80 mengukur kinerja harga dari 80 saham yang memiliki likuiditas tinggi dan kapitalisasi pasar *free float* besar, serta didukung oleh fundamental dan kepatuhan perusahaan yang baik (Bursa Efek Indonesia, 2024). Konstituen IDX80 dipilih dari saham konstituen IHSG yang memenuhi kriteria umum, antara lain telah tercatat lebih dari enam bulan, termasuk dalam 150 saham dengan nilai transaksi terbesar di pasar reguler selama 12 bulan terakhir, dan memiliki rasio *free float* minimal 10%. Konstituen IDX80 kemudian menjadi semesta pemilihan LQ45, dan konstituen LQ45 menjadi semesta pemilihan IDX30. Penelitian ini menggunakan IDX80 karena jumlah konstituennya paling banyak di antara ketiga indeks tersebut, sehingga sampel berita dan variasi sektor yang dapat dianalisis lebih luas.

Tabel II.1 Sektor dan kode indeks sektoral IDX-IC (Sidik, 2021)

No	Sektor	Kode Indeks
1	Energi	IDXENERGY
2	Barang Baku	IDXBASIC
3	Perindustrian	IDXINDUST
4	Barang Konsumer Primer	IDXNONCYC
5	Barang Konsumer Non-Primer	IDXCYCLIC
6	Kesehatan	IDXHEALTH
7	Keuangan	IDXFINANCE
8	Properti dan Real Estat	IDXPROPERT
9	Teknologi	IDXTECHNO
10	Infrastruktur	IDXINFRA
11	Transportasi dan Logistik	IDXTRANS

Daftar konstituen indeks tersebut tidak bersifat tetap. Panduan metodologi yang berlaku sejak Maret 2024 menetapkan evaluasi mayor pada bulan Januari, April, Juli, dan Oktober, dengan hari efektif pada hari bursa pertama bulan Februari, Mei, Agustus, dan November (Bursa Efek Indonesia, 2024). Selain evaluasi rutin, BEI juga dapat melakukan evaluasi insidental apabila terjadi perubahan jumlah saham yang signifikan, *delisting*, atau informasi penting lain mengenai konstituen. Bagi penelitian ini, perubahan konstituen tersebut berarti daftar emiten tidak dapat diambil dari satu periode saja. Apabila hanya daftar konstituen terbaru yang digunakan, sampel akan didominasi oleh emiten yang bertahan sampai akhir periode sehingga hasil analisis dapat mengandung *survivorship bias*. Oleh karena itu, penelitian ini menggunakan daftar konstituen yang berlaku pada tanggal setiap berita terbit. Pasangan berita dan emiten hanya dimasukkan ke dalam dataset apabila emiten tersebut termasuk konstituen IDX80 pada tanggal tersebut.

II.1.2 Klasifikasi Sektor IDX-IC dan Indeks Sektoral

Sejak 25 Januari 2021, BEI menggunakan IDX Industrial Classification (IDX-IC) untuk mengelompokkan perusahaan tercatat dan sekaligus meluncurkan sebelas indeks sektoral (Sidik, 2021). IDX-IC menggantikan klasifikasi JASICA yang sebelumnya digunakan sejak 1996. Berbeda dengan JASICA yang mengelompokkan perusahaan berdasarkan kegiatan ekonominya, IDX-IC menggunakan prinsip eksposur pasar, dan setiap perusahaan diklasifikasikan secara unik ke dalam satu subindustri (Intan, 2021). Daftar sektor dan kode indeks sektoral IDX-IC ditunjukkan pada Tabel II.1.

Keberadaan indeks sektoral memungkinkan setiap emiten dipasangkan dengan indeks sektor tempat emiten tersebut diklasifikasikan. Dengan pasangan ini, perg-

erakan harga emiten dapat dibandingkan tidak hanya dengan pergerakan pasar secara umum, tetapi juga dengan pergerakan sektornya. Hal ini relevan karena emiten dalam satu sektor sering terpapar faktor yang sama, misalnya harga komoditas untuk sektor energi dan barang baku. Karena indeks sektoral IDX-IC baru tersedia sejak awal 2021, data sektor sebelum tanggal tersebut tidak dapat digunakan secara konsisten. Kondisi ini menjadi dasar pemilihan periode data 2021 sampai 2025 pada penelitian ini.

II.1.3 Batas Auto Rejection dan Suspensi Perdagangan

BEI menerapkan mekanisme *auto rejection*, yaitu pengamanan yang membatasi kenaikan maupun penurunan harga saham yang terlalu tajam dalam satu hari perdagangan (Shaid, 2025). Saat harga mencapai batas atas, terjadi *auto rejection* atas (ARA), sedangkan saat harga mencapai batas bawah, terjadi *auto rejection* bawah (ARB). Pesanan dengan harga di luar batas tersebut ditolak secara otomatis oleh sistem perdagangan. Besaran batas ini tidak selalu sama sepanjang waktu. Sebagai contoh, pada 8 April 2025 batas ARB diseragamkan menjadi 15% untuk seluruh rentang harga, sedangkan sebelumnya batas tersebut bervariasi menurut rentang harga saham (Shaid, 2025).

Mekanisme ini berpengaruh terhadap pengukuran dampak berita. Apabila suatu berita sangat negatif dan saham emiten langsung terkena ARB, *return* pada hari tersebut tertahan pada batas bawah sehingga dampak yang sebenarnya belum seluruhnya tercermin pada hari yang sama. Sisa reaksi harga kemudian dapat muncul pada hari bursa berikutnya. Kondisi serupa dapat terjadi ketika saham emiten dihentikan sementara perdagangannya (suspensi), karena harga pada hari tersebut tidak terbentuk melalui transaksi normal. Oleh karena itu, dampak berita pada penelitian ini diukur dari akumulasi *abnormal return* pada hari peristiwa dan hari bursa berikutnya, sedangkan sampel yang jatuh pada hari suspensi dikeluarkan.

II.1.4 Berita sebagai Sumber Informasi bagi Pasar

Berita merupakan salah satu saluran utama yang membawa informasi baru kepada investor. Tetlock (2007) mengukur isi kolom harian *Wall Street Journal* dan menemukan bahwa tingkat pesimisme media yang tinggi diikuti oleh tekanan turun pada harga pasar, kemudian harga kembali ke nilai fundamentalnya. Penelitian tersebut juga menemukan bahwa pesimisme yang sangat tinggi atau sangat rendah diikuti oleh volume perdagangan yang tinggi. Pada tingkat saham individual, Chan (2003) membandingkan saham yang memiliki berita publik dengan saham yang mengalami pergerakan harga serupa tanpa berita. Hasilnya menunjukkan adanya *drift* setelah

berita, terutama setelah berita buruk, sedangkan pergerakan harga ekstrem tanpa berita cenderung berbalik arah.

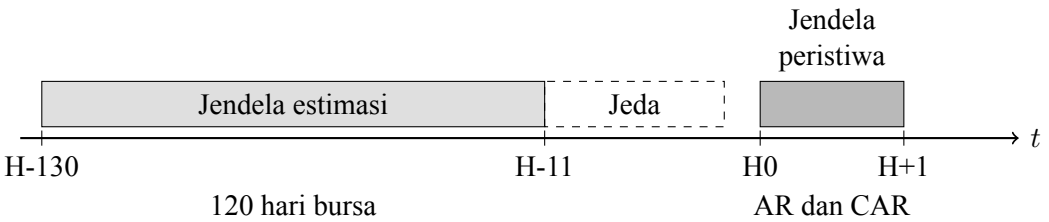
Kedua temuan tersebut menunjukkan bahwa keberadaan dan isi berita berkaitan dengan cara harga saham bereaksi. Namun, berita yang beredar di portal keuangan tidak semuanya membawa informasi baru mengenai emiten. Sebagian berita hanya melaporkan pergerakan harga yang sudah terjadi, misalnya berita mengenai saham yang melonjak atau menjadi pemberat IHSG pada hari tertentu. Berita seperti ini tidak menjelaskan peristiwa yang mendasari pergerakan harga, tetapi justru memuat hasil pergerakan itu sendiri. Apabila berita seperti ini digunakan untuk melatih model, model dapat mempelajari informasi yang seharusnya belum tersedia saat prediksi dilakukan. Karena itu, pembedaan antara berita yang memuat peristiwa dan berita yang hanya melaporkan harga menjadi bagian penting dalam penyusunan data penelitian ini.

II.2 Efisiensi Pasar dan *Event Study*

II.2.1 Hipotesis Pasar Efisien

Dasar teoretis pengukuran dampak berita terhadap harga saham adalah hipotesis pasar efisien. Fama (1970) mendefinisikan pasar yang efisien sebagai pasar yang harganya selalu mencerminkan seluruh informasi yang tersedia. Fama membagi pengujian efisiensi pasar menjadi tiga bentuk, yaitu bentuk lemah yang berkaitan dengan informasi harga historis, bentuk setengah kuat yang berkaitan dengan kecepatan penyesuaian harga terhadap informasi publik, dan bentuk kuat yang berkaitan dengan informasi yang hanya dimiliki kelompok tertentu. Pengujian bentuk setengah kuat inilah yang paling dekat dengan penelitian ini, karena berita merupakan informasi publik yang diterima pasar pada waktu tertentu.

Pengujian bentuk setengah kuat umumnya dilakukan dengan mengamati perilaku harga di sekitar suatu peristiwa. Fama dkk. (1969) meneliti penyesuaian harga saham terhadap pengumuman *stock split*, sedangkan Ball dan Brown (1968) meneliti reaksi harga terhadap pengumuman laba akuntansi. Kedua penelitian tersebut menjadi dasar berkembangnya metode *event study*. Bagi penelitian ini, hipotesis pasar efisien memberikan alasan mengapa reaksi harga yang tidak dapat dijelaskan oleh kondisi pasar dapat dikaitkan dengan informasi baru. Meskipun demikian, penelitian ini tidak menguji apakah BEI efisien atau tidak, melainkan memanfaatkan reaksi harga tersebut sebagai proksi dampak berita.



Gambar II.1 Linimasa jendela estimasi dan jendela peristiwa yang digunakan dalam penelitian ini

II.2.2 Tahapan *Event Study*

Event study merupakan metode untuk mengukur pengaruh suatu peristiwa ekonomi terhadap nilai perusahaan dengan memanfaatkan data harga saham di sekitar peristiwa tersebut (MacKinlay, 1997). Metode ini bertumpu pada asumsi bahwa pasar bersikap rasional, sehingga pengaruh suatu peristiwa akan segera tercermin pada harga saham. Menurut MacKinlay (1997), *event study* secara umum diawali dengan mendefinisikan peristiwa yang diteliti dan periode pengamatannya, kemudian menentukan kriteria pemilihan sampel. Setelah itu, peneliti memilih model *return* normal, mengestimasi parameternya, menghitung *abnormal return*, menguji signifikansinya, dan menginterpretasikan hasilnya.

Dalam *event study*, terdapat dua periode yang perlu dibedakan, yaitu jendela estimasi dan jendela peristiwa. Jendela estimasi merupakan periode sebelum peristiwa yang digunakan untuk mengestimasi parameter model *return* normal, sedangkan jendela peristiwa merupakan periode di sekitar peristiwa tempat *abnormal return* diukur. Kedua jendela tersebut sebaiknya tidak saling tumpang tindih agar parameter model tidak dipengaruhi oleh peristiwa yang sedang diteliti (MacKinlay, 1997). Pada penelitian ini, hari peristiwa (H0) ditentukan dari waktu terbit berita, jendela estimasi ditetapkan pada H-130 sampai H-11, dan jendela peristiwa difokuskan pada H0 sampai H+1. Jeda antara akhir jendela estimasi dan hari peristiwa dimaksudkan agar parameter tidak terpengaruh oleh kebocoran informasi menjelang berita terbit. Hubungan antarperiode tersebut ditunjukkan pada Gambar II.1.

II.2.3 *Return*, *Abnormal Return*, dan *Cumulative Abnormal Return*

Return harian emiten i pada hari t dihitung dari perubahan harga penutupan terhadap hari bursa sebelumnya, seperti pada Persamaan II.1. Harga $P_{i,t}$ yang digunakan merupakan harga yang telah disesuaikan terhadap *stock split* dan dividen, sehingga

peristiwa tersebut tidak terbaca sebagai lonjakan *return*.

$$R_{i,t} = \frac{P_{i,t} - P_{i,t-1}}{P_{i,t-1}} \tag{II.1}$$

Abnormal return merupakan selisih antara *return* aktual dan *return* normal, yaitu *return* yang diharapkan apabila peristiwa tidak terjadi (MacKinlay, 1997). Secara umum, *abnormal return* dirumuskan pada Persamaan II.2, dengan X_t menyatakan informasi yang digunakan oleh model *return* normal, misalnya *return* pasar pada hari yang sama.

$$AR_{i,t} = R_{i,t} - E\left(R_{i,t} \mid X_t\right) \tag{II.2}$$

Reaksi harga terhadap suatu peristiwa tidak selalu selesai dalam satu hari. Untuk menangkap reaksi yang berlangsung selama beberapa hari, *abnormal return* dijumlahkan sepanjang jendela peristiwa menjadi *cumulative abnormal return* (CAR) seperti pada Persamaan II.3. Target yang diprediksi dalam penelitian ini adalah $CAR_i[0, +1]$, yaitu jumlah *abnormal return* pada H0 dan H+1. Pilihan ini sejalan dengan MacKinlay (1997), yang menyarankan jendela peristiwa setidaknya mencakup hari pengumuman dan hari setelahnya untuk menangkap pengumuman yang terjadi setelah pasar tutup. Pilihan ini juga mempertimbangkan kasus ARB yang membuat reaksi harga baru selesai pada hari berikutnya. Jendela yang mencakup H-1 tidak digunakan karena data H-1 juga menjadi bagian dari fitur model.

$$CAR_i[\tau_1, \tau_2] = \sum_{t=\tau_1}^{\tau_2} AR_{i,t} \tag{II.3}$$

Dalam *event study* klasik, signifikansi *abnormal return* diuji dengan membandingkannya terhadap simpangan baku residual model pada jendela estimasi (MacKinlay, 1997). Penelitian ini tidak menggunakan uji tersebut untuk menyimpulkan dampak satu jenis peristiwa, tetapi memakai gagasan yang sama untuk menentukan arah CAR aktual pada tahap evaluasi. Karena $CAR_i[0, +1]$ merupakan jumlah dua *abnormal return* harian, variansnya merupakan jumlah varians kedua hari tersebut (MacKinlay, 1997). Apabila *abnormal return* harian dianggap saling bebas dengan varians yang sama, simpangan baku CAR dua hari menjadi $\hat{\sigma}_{\varepsilon_i}\sqrt{2}$. Arah CAR aktual dikategorikan positif apabila nilainya lebih besar dari batas tersebut, negatif

apabila lebih kecil dari batas negatifnya, dan netral untuk nilai di antaranya, seperti pada Persamaan II.4. Dengan cara ini, zona netral menyesuaikan dengan tingkat volatilitas masing-masing emiten, sehingga emiten yang biasanya bergerak tajam memerlukan CAR yang lebih besar untuk dikategorikan positif atau negatif. Zona netral ini hanya digunakan untuk evaluasi, sedangkan model memprediksi besar CAR dan arah prediksinya dibaca dari tanda nilai yang diprediksi.

$$d_i = \begin{cases} \text{positif}, & CAR_i[0,+1] > \hat{\sigma}_{\varepsilon_i}\sqrt{2} \\ \text{negatif}, & CAR_i[0,+1] < -\hat{\sigma}_{\varepsilon_i}\sqrt{2} \\ \text{netral}, & \text{lainnya} \end{cases} \tag{II.4}$$

II.3 Model *Return* yang Diharapkan

Nilai *abnormal return* sangat bergantung pada model yang digunakan untuk menghitung *return* yang diharapkan. Semakin baik model menjelaskan pergerakan normal saham, semakin kecil varians *abnormal return*, sehingga dampak suatu peristiwa lebih mudah dideteksi (MacKinlay, 1997). Subbab ini membahas beberapa model yang umum digunakan, mulai dari yang paling sederhana sampai model dua faktor yang digunakan dalam penelitian ini.

II.3.1 Model Rata-Rata Konstan dan Model *Market-Adjusted*

Model rata-rata konstan mengasumsikan bahwa *return* normal suatu saham sama dengan rata-rata *return* saham tersebut pada jendela estimasi (MacKinlay, 1997). Model ini sederhana, tetapi tidak memperhitungkan kondisi pasar pada hari peristiwa. Akibatnya, ketika pasar sedang turun tajam, hampir seluruh saham akan terlihat memiliki *abnormal return* negatif walaupun tidak ada peristiwa khusus. Model *market-adjusted* mengatasi sebagian masalah tersebut dengan mengurangkan *return* pasar secara langsung dari *return* saham, seperti pada Persamaan II.5.

$$AR_{i,t} = R_{i,t} - R_{m,t} \tag{II.5}$$

Model *market-adjusted* tidak memerlukan jendela estimasi karena secara implisit mengasumsikan $\alpha = 0$ dan $\beta = 1$ untuk setiap saham. Brown dan Warner (1985) menunjukkan bahwa pada kasus tertentu, metode yang sederhana seperti ini juga dapat bekerja dengan baik. Model ini digunakan oleh Sudirman dkk. (2026) dalam *event study* di BEI dengan IHSG sebagai *return* pasar. Kelemahannya, asumsi $\beta = 1$

tidak sesuai untuk saham yang bergerak jauh lebih tajam atau jauh lebih lambat daripada pasar. Selain itu, model ini sama sekali tidak memperhitungkan pengaruh sektor.

II.3.2 *Market Model*

Market model menghubungkan *return* saham dengan *return* pasar melalui regresi linear, seperti pada Persamaan II.6 (MacKinlay, 1997). Parameter α_i dan β_i diestimasi menggunakan *ordinary least squares* (OLS) pada jendela estimasi, kemudian digunakan untuk menghitung *return* yang diharapkan pada jendela peristiwa. Nilai β_i menunjukkan sensitivitas saham terhadap pergerakan pasar, sehingga saham yang biasanya bergerak lebih tajam daripada IHSG akan memiliki β_i lebih besar dari satu.

$$R_{i,t} = \alpha_i + \beta_i R_{m,t} + \varepsilon_{i,t}, \quad E(\varepsilon_{i,t}) = 0, \quad \text{Var}(\varepsilon_{i,t}) = \sigma^2_{\varepsilon_i} \tag{II.6}$$

Brown dan Warner (1980) membandingkan beberapa metode pengukuran kinerja harga saham menggunakan data bulanan. Kajian serupa kemudian dilakukan oleh Brown dan Warner (1985) menggunakan data harian. Hasil kajian dengan data harian menunjukkan bahwa metode berbasis *market model* yang sederhana sudah cukup tepat spesifikasinya dan memiliki kekuatan uji yang relatif baik pada berbagai kondisi. Temuan ini menjadikan *market model* sebagai model standar dalam banyak *event study*. Namun, *market model* hanya menggunakan satu faktor, yaitu pasar. Apabila sebagian pergerakan saham sebenarnya berasal dari sektornya, bagian tersebut akan tertinggal di dalam residual dan ikut terhitung sebagai *abnormal return*.

II.3.3 Model Indeks Dua Faktor

MacKinlay (1997) menjelaskan bahwa model *return* normal dapat diperluas menjadi model multifaktor dengan tujuan mengurangi varians *abnormal return*, walaupun dalam banyak *event study* manfaat tambahan faktor tersebut terbatas. Besarnya manfaat itu bergantung pada seberapa besar faktor tambahan dapat menjelaskan pergerakan saham yang tidak tertangkap oleh faktor pasar. Untuk faktor industri, bukti empiris diberikan oleh Xiang (1993). Penelitian tersebut membandingkan pilihan model pembangkit *return* dalam *event study* dan menemukan bahwa faktor industri menjelaskan rata-rata 6,7% variasi residual *market model* pada data harian dan 11,5% pada data mingguan. Penelitian tersebut juga menyimpulkan bahwa apabila *return* saham sebenarnya mengikuti model dua faktor, inferensi yang hanya didasarkan pada *market model* menjadi tidak valid. Berdasarkan temuan tersebut, penelitian ini menggunakan model dua faktor seperti pada Persamaan II.7, dengan

$R_{m,t}$ menyatakan *return* IHSG dan $R_{s,t}$ menyatakan *return* indeks sektoral IDX-IC tempat emiten diklasifikasikan.

$$R_{i,t} = \alpha_i + \beta_{1,i} R_{m,t} + \beta_{2,i} R_{s,t} + \varepsilon_{i,t} \tag{II.7}$$

Parameter α_i, $\beta_{1,i}$, dan $\beta_{2,i}$ diestimasi dengan OLS pada jendela estimasi. *Abnormal return* pada hari peristiwa kemudian dihitung sebagai selisih antara *return* aktual dan *return* yang diharapkan menurut parameter tersebut, seperti pada Persamaan II.8. Simpangan baku residual $\hat{\sigma}_{\varepsilon_i}$ yang digunakan untuk menentukan zona netral pada Persamaan II.4 dihitung dari residual model pada jendela estimasi, seperti pada Persamaan II.9, dengan L menyatakan jumlah hari bursa pada jendela estimasi.

$$AR_{i,t} = R_{i,t} - \left(\hat{\alpha}_i + \hat{\beta}_{1,i} R_{m,t} + \hat{\beta}_{2,i} R_{s,t}\right) \tag{II.8}$$

$$\hat{\sigma}_{\varepsilon_i} = \sqrt{\frac{1}{L-3} \sum_{t \in \text{estimasi}} \hat{\varepsilon}_{i,t}^2} \tag{II.9}$$

Penggunaan bobot hasil regresi berbeda dengan sekadar mengurangkan *return* IHSG dan *return* sektor secara langsung. Indeks sektoral pada dasarnya juga ikut bergerak bersama IHSG, sehingga apabila keduanya dikurangkan secara penuh, pengaruh pasar akan terhitung dua kali. Sebagai ilustrasi, apabila IHSG turun 2%, sektor turun 2%, dan saham turun 3%, pengurangan langsung menghasilkan $-3\% - (-2\%) - (-2\%) = +1\%$, seolah-olah saham tersebut mengungguli pasar padahal penurunannya paling dalam. Melalui regresi, besarnya keterikatan saham terhadap pasar dan sektor ditentukan dari data historis, sehingga masalah tersebut dapat dihindari. Perbandingan model-model yang telah dibahas dirangkum pada Tabel II.2.

Model dua faktor juga memiliki beberapa keterbatasan yang perlu diperhatikan. Pertama, *return* IHSG dan *return* indeks sektoral umumnya berkorelasi tinggi, terutama untuk sektor yang bobotnya besar di IHSG. Kolinearitas ini dapat membuat estimasi $\beta_{1,i}$ dan $\beta_{2,i}$ tidak stabil, walaupun nilai *return* yang diharapkan secara keseluruhan masih dapat diestimasi. Salah satu cara untuk mengatasinya adalah meregresikan *return* sektor terhadap *return* IHSG terlebih dahulu, kemudian menggunakan residualnya sebagai faktor sektor, sehingga $\beta_{2,i}$ hanya menangkap pergerakan sektor di luar pergerakan pasar. Kedua, untuk peristiwa yang memengaruhi satu sektor secara keseluruhan, seperti perubahan regulasi pada suatu industri, koreksi sektor jus-

Tabel II.2 Perbandingan model *return* yang diharapkan

Model	***Return* yang diharapkan**	**Keterbatasan**
Rata-rata konstan	Rata-rata *return* saham pada jendela estimasi	Tidak memperhitungkan kondisi pasar pada hari peristiwa
Market-adjusted	*Return* pasar pada hari yang sama	Mengasumsikan $\beta = 1$ dan tidak memperhitungkan sektor
Market model	$\hat{\alpha}_i + \hat{\beta}_i R_{m,t}$	Pergerakan sektor tertinggal di dalam *abnormal return*
Dua faktor	$\hat{\alpha}_i + \hat{\beta}_{1,i} R_{m,t} + \hat{\beta}_{2,i} R_{s,t}$	Estimasi β dapat tidak stabil akibat kolinearitas, dan dapat menghapus dampak peristiwa berskala sektor

tru dapat menghapus dampak peristiwa tersebut karena seluruh emiten dalam sektor bergerak bersama. Oleh karena itu, untuk peristiwa berskala sektor, penelitian ini juga menghitung *abnormal return* yang hanya dikoreksi oleh IHSG.

II.4 Pemrosesan Teks Berita untuk Analisis Saham

II.4.1 Sentimen dan Jenis Peristiwa

Informasi dari teks berita dapat diekstraksi dalam berbagai bentuk. Bentuk yang paling banyak digunakan dalam penelitian keuangan adalah sentimen, yaitu ukuran nada positif atau negatif suatu teks. Kearney dan Liu (2014) merangkum berbagai metode dan model yang digunakan untuk mengukur sentimen tekstual di bidang keuangan, mulai dari pendekatan berbasis kamus kata sampai pendekatan berbasis *machine learning*. Sentimen mudah diinterpretasikan dan dapat dihitung untuk hampir semua jenis teks. Namun, sentimen hanya menggambarkan nada berita, bukan peristiwa yang terjadi. Berita mengenai direktur yang ditetapkan sebagai tersangka korupsi dan berita mengenai laba yang turun sesuai ekspektasi analis sama-sama bernada negatif, tetapi keduanya merupakan peristiwa yang berbeda dan dapat diikuti reaksi harga yang berbeda pula.

Pendekatan lain adalah merepresentasikan berita berdasarkan peristiwa yang dikandungnya. Ding dkk. (2015) mengekstraksi peristiwa dari teks berita dan merepresentasikannya sebagai vektor padat, kemudian menggunakan *convolutional neural network* untuk memodelkan pengaruh jangka pendek dan jangka panjang peristiwa terhadap pergerakan harga. Model tersebut menghasilkan peningkatan sekitar 6% dibandingkan metode pembanding pada prediksi indeks S&P 500 dan saham individual. Zhou dkk. (2021) memandang peristiwa korporasi sebagai penggerak perg-

erakan saham dan membangun detektor peristiwa dua tingkat, yaitu pada tingkat token dan tingkat artikel. Kedua penelitian tersebut menunjukkan bahwa jenis peristiwa dapat dijadikan representasi berita yang lebih spesifik dibandingkan sentimen. Pada penelitian ini, jenis peristiwa direpresentasikan sebagai label kategori yang dapat dibaca langsung, seperti hukum atau korupsi, laporan keuangan, dan pergantian direksi, sehingga kontribusinya terhadap prediksi dapat dijelaskan.

II.4.2 Klasifikasi Berbasis Aturan dan Supervisi Lemah

Cara paling sederhana untuk mengklasifikasikan jenis peristiwa adalah menggunakan aturan kata kunci. Misalnya, berita yang memuat kata "tersangka", "KPK", atau "Kejagung" diberi label hukum atau korupsi. Pendekatan ini mudah dibuat dan hasilnya transparan, tetapi tidak dapat menangani berita yang menggambarkan peristiwa yang sama dengan kata-kata berbeda. Selain itu, aturan kata kunci tidak memahami konteks, sehingga kata yang sama dapat muncul pada berita dengan peristiwa yang berbeda.

Walaupun kurang akurat jika digunakan sebagai *classifier* akhir, aturan kata kunci dapat dimanfaatkan untuk mempercepat penyusunan data latih. Ratner dkk. (2017) memperkenalkan Snorkel, yaitu sistem yang memungkinkan pengguna menulis fungsi pelabelan berupa aturan atau heuristik untuk menghasilkan label data latih tanpa melabeli setiap data secara manual. Pendekatan ini dikenal sebagai supervisi lemah karena label yang dihasilkan masih mengandung kesalahan. Pada penelitian ini, gagasan tersebut digunakan dalam bentuk yang lebih sederhana, yaitu aturan kata kunci menghasilkan pra-label yang kemudian diperiksa dan dikoreksi secara manual.

II.4.3 TF-IDF dengan Logistic Regression dan SVM

Pendekatan klasik untuk klasifikasi teks adalah merepresentasikan dokumen sebagai vektor bobot kata, kemudian melatih *classifier* linear di atas vektor tersebut. Salah satu skema pembobotan yang paling umum adalah TF-IDF (*term frequency-inverse document frequency*). Bobot ini memberikan nilai tinggi kepada kata yang sering muncul pada suatu dokumen tetapi jarang muncul pada dokumen lain. Gagasan bahwa kata yang muncul di banyak dokumen memiliki daya pembeda yang lebih rendah diperkenalkan oleh Spärck Jones (1972). Bobot TF-IDF kata w pada dokumen d dihitung seperti pada Persamaan II.10, dengan $\text{tf}(w, d)$ menyatakan frekuensi kata w pada dokumen d, N menyatakan jumlah dokumen, dan $\text{df}(w)$ menyatakan jumlah

dokumen yang memuat kata w.

$$\text{tf-idf}(w, d) = \text{tf}(w, d) \cdot \log \frac{N}{\text{df}(w)} \tag{II.10}$$

Vektor TF-IDF umumnya berdimensi tinggi dan bersifat jarang. Joachims (1998) menunjukkan bahwa *support vector machine* (SVM) cocok untuk klasifikasi teks karena mampu menangani ruang fitur berdimensi tinggi dengan banyak fitur yang relevan. *Logistic regression* juga sering digunakan karena sederhana dan menghasilkan probabilitas kelas. Kelemahan pendekatan ini adalah setiap kata diperlakukan secara terpisah, sehingga urutan kata dan konteks kalimat tidak tertangkap. Meskipun demikian, kombinasi TF-IDF dengan SVM atau *logistic regression* tetap menjadi pendekatan yang kuat dan murah secara komputasi untuk klasifikasi teks.

II.4.4 Transformer, BERT, dan IndoBERT

Transformer merupakan arsitektur jaringan saraf yang sepenuhnya menggunakan mekanisme *attention* untuk memodelkan hubungan antartoken dalam suatu urutan (Vaswani dkk. 2017). Mekanisme *self-attention* memungkinkan representasi setiap token dihitung dengan mempertimbangkan seluruh token lain dalam kalimat. Berdasarkan arsitektur tersebut, Devlin dkk. (2019) memperkenalkan BERT (*Bidirectional Encoder Representations from Transformers*), yaitu model *encoder* yang dilatih awal pada korpus teks besar menggunakan tugas *masked language modeling* dan *next sentence prediction*. Representasi yang dihasilkan bersifat dua arah, karena setiap token dipahami berdasarkan konteks di sebelah kiri dan kanannya. Setelah dilatih awal, BERT dapat disesuaikan untuk tugas tertentu melalui *fine-tuning*, yaitu dengan menambahkan lapisan klasifikasi dan melatih ulang model menggunakan data berlabel dalam jumlah yang relatif kecil.

Untuk bahasa Indonesia, Wilie dkk. (2020) merilis IndoNLU, yaitu kumpulan dua belas tugas pemahaman bahasa Indonesia beserta model IndoBERT yang dilatih awal pada korpus Indo4B. Korpus tersebut dikumpulkan dari sumber publik seperti media sosial, blog, berita, dan situs web. Salah satu varian yang dirilis adalah `indobenchmark/indobert-base-p1`. Pada waktu yang hampir bersamaan, Koto dkk. (2020) juga merilis model IndoBERT lain beserta tolok ukur IndoLEM, sehingga nama IndoBERT dalam literatur dapat merujuk pada dua model yang berbeda. Untuk domain keuangan, Maharani dkk. (2023) melakukan *post-training* model bahasa pada korpus keuangan Indonesia dan menyusun dataset analisis sentimen serta klasifikasi topik keuangan berbahasa Indonesia. Penelitian tersebut menemukan

bahwa *post-training* pada domain keuangan meningkatkan kinerja model ketika di-*fine-tune* untuk tugas pada domain yang sama.

Perlu dibedakan bahwa IndoBERT merupakan model *encoder* yang di-*fine-tune* untuk tugas klasifikasi, bukan model bahasa generatif. Model ini menghasilkan probabilitas untuk setiap kelas yang telah ditentukan dan tidak menghasilkan teks baru. Dengan bobot model yang tetap setelah pelatihan, keluaran IndoBERT untuk masukan yang sama akan selalu sama. Sifat ini mendukung kebutuhan penelitian ini akan *pipeline* yang dapat direproduksi.

II.4.5 Anotasi dan Kesepakatan Antaranotator

Model klasifikasi jenis peristiwa memerlukan data berlabel, dan kualitas label perlu diukur sebelum data digunakan untuk evaluasi. Apabila dua anotator melabeli data yang sama, kesepakatan antara keduanya dapat diukur dengan Cohen's kappa (Cohen, 1960). Berbeda dengan persentase kesepakatan biasa, kappa mengoreksi kesepakatan yang dapat terjadi secara kebetulan, seperti pada Persamaan II.11. Pada persamaan tersebut, p_o menyatakan proporsi data yang labelnya sama di antara kedua anotator, sedangkan p_e menyatakan proporsi kesepakatan yang diharapkan secara kebetulan berdasarkan distribusi label masing-masing anotator.

$$\kappa = \frac{p_o - p_e}{1 - p_e} \tag{II.11}$$

Landis dan Koch (1977) mengusulkan interpretasi nilai kappa ke dalam beberapa tingkat. Nilai 0,41 sampai 0,60 dikategorikan sebagai kesepakatan sedang (*moderate*), nilai 0,61 sampai 0,80 sebagai kesepakatan substansial (*substantial*), dan nilai di atas 0,80 sebagai kesepakatan hampir sempurna (*almost perfect*). Berdasarkan interpretasi tersebut, target kappa sekurang-kurangnya 0,6 pada penelitian ini berada pada batas antara kesepakatan sedang dan substansial. Nilai kappa yang lebih rendah dari target menunjukkan bahwa definisi kategori dalam pedoman anotasi belum cukup jelas, sehingga pedoman perlu diperbaiki sebelum pelabelan dilanjutkan.

II.5 Model Regresi untuk Prediksi CAR

Prediksi besar $CAR[0, +1]$ merupakan masalah regresi, yaitu memetakan fitur berita dan kondisi pasar menjadi satu nilai numerik dalam satuan persen. Penelitian ini membandingkan empat model regresi, yaitu Linear Regression, Random Forest, XGBoost, dan LightGBM. Arah CAR tidak diprediksi dengan model klasifikasi terpisah, melainkan dibaca dari tanda nilai yang diprediksi. Pendekatan ini serupa

dengan Amel-Zadeh dkk. (2020), yang melatih model dalam bentuk regresi untuk memprediksi *abnormal return* di sekitar pengumuman laba, kemudian menilai ketepatan tanda prediksinya. Subbab ini membahas keempat model tersebut beserta alasan penggunaan model berbasis pohon untuk data tabular.

II.5.1 Linear Regression

Linear Regression memodelkan target sebagai kombinasi linear dari fitur, seperti pada Persamaan II.12, dengan $\hat{y}_i$ menyatakan prediksi untuk data ke-i, $x_{i,j}$ menyatakan nilai fitur ke-j, dan w_j menyatakan bobot fitur. Bobot diestimasi dengan meminimalkan jumlah kuadrat selisih antara target aktual dan prediksi, sama seperti OLS yang digunakan pada model *return* yang diharapkan. Kelebihan model ini adalah sederhana dan mudah diinterpretasikan, karena setiap bobot menunjukkan perubahan prediksi untuk setiap kenaikan satu satuan fitur. Kelemahannya, model ini mengasumsikan hubungan yang linear dan tidak menangkap interaksi antarfitur kecuali interaksi tersebut ditambahkan secara eksplisit. Model linear seperti OLS dan Lasso banyak digunakan sebagai pembanding dalam penelitian prediksi *return* (Amel-Zadeh dkk. 2020; Gu dkk. 2020), sehingga dalam penelitian ini Linear Regression berperan sebagai model pembanding yang paling sederhana.

$$\hat{y}_i = w_0 + \sum_{j=1}^{M} w_j x_{i,j} \tag{II.12}$$

II.5.2 Random Forest

Random Forest merupakan kumpulan pohon keputusan yang masing-masing dilatih pada sampel *bootstrap* dari data latih, dengan pemilihan subhimpunan fitur secara acak pada setiap pemisahan simpul (Breiman, 2001). Untuk regresi, prediksi akhir merupakan rata-rata keluaran seluruh pohon, seperti pada Persamaan II.13, dengan B menyatakan jumlah pohon dan T_b menyatakan pohon ke-b. Keacakan pada sampel dan fitur membuat setiap pohon berbeda, sehingga rata-ratanya lebih stabil dibandingkan satu pohon keputusan. Pada prediksi *abnormal return* di sekitar pengumuman laba, Amel-Zadeh dkk. (2020) menemukan bahwa Random Forest dan *recurrent neural network* mengungguli *deep neural network* serta model linear seperti OLS dan Lasso. Schnaubelt dan Seifert (2020) juga menemukan bahwa Random Forest menghasilkan *abnormal return* portofolio yang lebih tinggi dibandingkan tiga

model pembanding pada lebih dari 45.000 pengumuman laba.

$$\hat{y}_i = \frac{1}{B}\sum_{b=1}^{B} T_b(\mathbf{x}_i) \tag{II.13}$$

II.5.3 *Gradient Boosting* dan XGBoost

Berbeda dengan Random Forest yang membangun pohon secara paralel, *gradient boosting* membangun model secara bertahap dengan menambahkan model lemah satu per satu. Friedman (2001) merumuskan metode ini sebagai optimasi numerik dalam ruang fungsi, yaitu setiap model baru ditambahkan ke arah gradien negatif dari fungsi kerugian. Dalam praktiknya, model lemah yang digunakan umumnya berupa pohon keputusan, sehingga hasil akhirnya merupakan jumlah dari banyak pohon. Setiap pohon baru berfokus memperbaiki kesalahan yang masih tersisa dari pohon-pohon sebelumnya.

XGBoost merupakan implementasi *tree boosting* yang dirancang agar dapat diskalakan dan efisien (Chen & Guestrin, 2016). Prediksi XGBoost untuk data ke-i merupakan jumlah keluaran K pohon, seperti pada Persamaan II.14. Model dilatih dengan meminimalkan fungsi objektif yang terdiri dari fungsi kerugian l dan suku regularisasi Ω, seperti pada Persamaan II.15. Pada suku regularisasi, T menyatakan jumlah daun pada pohon, w menyatakan bobot daun, sedangkan γ dan λ merupakan parameter yang mengatur besarnya penalti kompleksitas pohon.

$$\hat{y}_i = \sum_{k=1}^{K} f_k(\mathbf{x}_i) \tag{II.14}$$

$$\mathcal{L} = \sum_i l\left(y_i, \hat{y}_i\right) + \sum_k \Omega(f_k), \quad \Omega(f) = \gamma T + \frac{1}{2}\lambda\|w\|^2 \tag{II.15}$$

Selain regularisasi, Chen dan Guestrin (2016) juga mengusulkan algoritma yang memperhitungkan data jarang dan metode *weighted quantile sketch* untuk pencarian titik pemisah secara aproksimatif. XGBoost dapat digunakan untuk klasifikasi maupun regresi dengan mengganti fungsi kerugiannya. Tinjauan sistematis Černevičienė dan Kabašinskas (2024) mencatat bahwa XGBoost termasuk tiga model *black-box* yang paling sering dijelaskan dengan metode XAI dalam penelitian keuangan, bersama *artificial neural network* dan Random Forest.

II.5.4 LightGBM

LightGBM merupakan implementasi *gradient boosting decision tree* yang dirancang untuk mempercepat pelatihan pada data dengan jumlah fitur dan jumlah data yang besar (Ke dkk. 2017). Ke dkk. (2017) mengusulkan dua teknik utama. Teknik pertama adalah *Gradient-based One-Side Sampling* (GOSS), yaitu mempertahankan data dengan gradien besar dan mengambil sampel acak dari data dengan gradien kecil, karena data dengan gradien besar lebih berpengaruh terhadap perhitungan perolehan informasi. Teknik kedua adalah *Exclusive Feature Bundling* (EFB), yaitu menggabungkan fitur-fitur yang jarang bernilai bukan nol secara bersamaan untuk mengurangi jumlah fitur. Dengan kedua teknik tersebut, LightGBM dapat mempercepat pelatihan *gradient boosting* konvensional hingga lebih dari 20 kali dengan akurasi yang hampir sama. Kecepatan ini relevan bagi penelitian ini karena penyetelan *hyperparameter* dilakukan untuk setiap model.

LightGBM juga telah digunakan dalam penelitian prediksi saham. Pagliaro (2026) menggunakan LightGBM untuk memprediksi arah *return* sepuluh hari ke depan pada 51 saham konstituen NASDAQ-100 periode 2015 sampai 2026 dan menemukan bahwa model tersebut mengungguli empat model pembanding. Penelitian tersebut memilih LightGBM karena keunggulannya pada data keuangan tabular dan kesesuaiannya dengan TreeSHAP, kemudian menggunakan SHAP untuk menjelaskan kontribusi fitur. Tian dkk. (2022) membandingkan model hibrida LSTM dengan LightGBM dan LSTM dengan XGBoost untuk memprediksi naik turunnya harga, dan menemukan bahwa versi yang menggunakan LightGBM memberikan hasil terbaik. Pada pasar negara berkembang, Guennioui dkk. (2024) menggunakan LightGBM untuk memprediksi harga saham di pasar Maroko selama periode volatilitas tinggi, termasuk analisis per sektor. Ketiga penelitian tersebut memprediksi harga atau arah *return* mentah, sehingga penggunaan LightGBM untuk memprediksi *abnormal return* yang dikoreksi pasar dan sektor masih perlu diuji.

II.5.5 Model Berbasis Pohon pada Data Tabular

Data yang digunakan dalam penelitian ini berbentuk tabular, yaitu satu baris untuk setiap pasangan berita dan emiten dengan fitur kategorikal dan numerik. Grinsztajn dkk. (2022) menguji model berbasis pohon dan model *deep learning* pada 45 dataset tabular dan menemukan bahwa model berbasis pohon tetap menjadi yang terbaik pada data berukuran sedang, sekitar 10.000 sampel. Shwartz-Ziv dan Armon (2022) juga menemukan bahwa XGBoost umumnya mengungguli model *deep learning* yang dirancang khusus untuk data tabular. Pada prediksi *return* saham, Gu dkk. (2020) menemukan bahwa model berbasis pohon dan *neural network* mem-

berikan hasil terbaik karena mampu menangkap interaksi nonlinear antarprediktor yang tidak tertangkap oleh model linear. Temuan-temuan tersebut menjadi dasar pemilihan tiga model berbasis pohon dalam penelitian ini, dengan Linear Regression sebagai pembanding. Model berbasis pohon juga memungkinkan nilai SHAP dihitung secara tepat dan efisien, seperti yang dibahas pada subbab berikutnya.

II.6 Metode *Explainable AI*

Model seperti Random Forest, XGBoost, dan LightGBM dapat menghasilkan prediksi yang akurat, tetapi alasan di balik setiap prediksinya tidak dapat dibaca secara langsung. Metode *explainable AI* (XAI) digunakan untuk menjelaskan kontribusi fitur terhadap prediksi tersebut. Metode XAI dapat dibedakan berdasarkan cakupannya, yaitu penjelasan lokal untuk satu prediksi dan penjelasan global untuk perilaku model secara keseluruhan, serta berdasarkan ketergantungannya pada jenis model, yaitu metode khusus untuk model tertentu dan metode yang dapat diterapkan pada model apa pun (*model-agnostic*). Arsenault dkk. (2025) juga menekankan pentingnya membedakan *explainability* dan *interpretability* dalam penerapan XAI untuk prediksi runtun waktu keuangan. Penelitian ini membandingkan tiga metode XAI yang mewakili pendekatan berbeda, yaitu SHAP, LIME, dan *permutation importance*.

II.6.1 SHAP

SHAP (*SHapley Additive exPlanations*) merupakan kerangka yang memberikan nilai kepentingan setiap fitur untuk suatu prediksi tertentu (Lundberg & Lee, 2017). SHAP termasuk dalam kelompok metode atribusi fitur aditif, yaitu metode yang menjelaskan prediksi sebagai jumlah dari nilai dasar dan kontribusi setiap fitur, seperti pada Persamaan II.16. Pada persamaan tersebut, ϕ_0 merupakan nilai dasar yang setara dengan rata-rata prediksi model, M merupakan jumlah fitur, z'_j menyatakan ada atau tidaknya fitur j, dan ϕ_j merupakan kontribusi fitur j.

$$g(z') = \phi_0 + \sum_{j=1}^{M} \phi_j z'_j \tag{II.16}$$

Nilai ϕ_j dihitung berdasarkan nilai Shapley dari teori permainan kooperatif (Shapley, 1953). Dalam konteks ini, setiap fitur diperlakukan sebagai pemain, dan prediksi model diperlakukan sebagai hasil yang dibagikan kepada para pemain. Nilai Shapley fitur j merupakan rata-rata kontribusi marginal fitur tersebut terhadap seluruh kemungkinan subhimpunan fitur lain, seperti pada Persamaan II.17, dengan F meny-

atakan himpunan seluruh fitur dan $f_x(S)$ menyatakan prediksi model ketika hanya fitur dalam subhimpunan S yang diketahui.

$$\phi_j = \sum_{S \subseteq F \setminus \{j\}} \frac{|S|!\ (|F| - |S| - 1)!}{|F|!} \left[f_x\left(S \cup \{j\}\right) - f_x(S) \right] \tag{II.17}$$

Lundberg dan Lee (2017) menunjukkan bahwa dalam kelompok metode atribusi aditif terdapat satu solusi unik yang memenuhi sifat akurasi lokal, *missingness*, dan konsistensi, dan solusi tersebut adalah nilai Shapley. Akurasi lokal berarti jumlah nilai dasar dan seluruh kontribusi fitur sama dengan prediksi model untuk data tersebut. Perhitungan Persamaan II.17 secara langsung memerlukan evaluasi pada seluruh subhimpunan fitur, sehingga waktu komputasinya tumbuh secara eksponensial terhadap jumlah fitur. Lundberg dkk. (2020) kemudian mengusulkan TreeSHAP, yaitu algoritma yang menghitung nilai SHAP secara tepat untuk model berbasis pohon dalam waktu polinomial, serta menunjukkan bahwa penjelasan lokal dapat digabungkan untuk memahami perilaku model secara global. Karena target penelitian ini adalah besar CAR, nilai SHAP dinyatakan dalam satuan yang sama dengan target, yaitu persen CAR, sehingga kontribusi setiap fitur dapat dibaca langsung.

II.6.2 LIME

LIME (*Local Interpretable Model-agnostic Explanations*) menjelaskan satu prediksi dengan membangun model sederhana yang dapat diinterpretasikan di sekitar data yang dijelaskan (Ribeiro dkk. 2016). LIME membuat sejumlah sampel tiruan dengan mengubah nilai fitur di sekitar data tersebut, meminta prediksi model untuk setiap sampel, kemudian melatih model sederhana seperti regresi linear dengan bobot yang lebih besar untuk sampel yang lebih dekat dengan data asli. Secara formal, penjelasan $\xi(x)$ diperoleh dari Persamaan II.18, dengan f menyatakan model yang dijelaskan, g menyatakan model sederhana dari kelompok model G, π_x menyatakan ukuran kedekatan terhadap data x, $\mathcal{L}$ menyatakan seberapa jauh g menyimpang dari f di sekitar x, dan $\Omega(g)$ menyatakan kompleksitas model sederhana tersebut.

$$\xi(x) = \underset{g \in G}{\arg\min}\ \mathcal{L}\left(f, g, \pi_x\right) + \Omega(g) \tag{II.18}$$

Karena hanya membutuhkan masukan dan keluaran model, LIME dapat diterapkan pada model apa pun. Gite dkk. (2021) menggunakan LIME untuk menjelaskan prediksi harga saham berbasis LSTM yang memanfaatkan sentimen berita. Kelema-

hannya, sampel tiruan dibuat secara acak, sehingga penjelasan untuk data yang sama dapat berbeda apabila dijalankan ulang (Zhang dkk. 2019). Selain itu, Alvarez-Melis dan Jaakkola (2018) menunjukkan bahwa metode populer seperti LIME dan SHAP dapat menghasilkan penjelasan yang berubah cukup besar akibat perubahan kecil pada input, dan metode yang berbasis perturbasi cenderung lebih rentan terhadap masalah ini.

II.6.3 *Permutation Importance*

Permutation importance mengukur kepentingan suatu fitur dari seberapa besar kinerja model menurun ketika nilai fitur tersebut diacak. Gagasan ini diperkenalkan oleh Breiman (2001) pada Random Forest dan dikembangkan oleh Fisher dkk. (2019) menjadi ukuran yang dapat diterapkan pada model apa pun. Kepentingan fitur j dihitung seperti pada Persamaan II.19, dengan $e(f; X)$ menyatakan kesalahan model, misalnya MAE, pada data asli dan $e(f; X^{(j)})$ menyatakan kesalahan model setelah nilai fitur j diacak antarbaris. Semakin besar kenaikan kesalahan, semakin penting fitur tersebut bagi model.

$$PI_j = e\left(f; X^{(j)}\right) - e\left(f; X\right) \tag{II.19}$$

Berbeda dengan SHAP dan LIME, *permutation importance* hanya menghasilkan penjelasan global dan tidak dapat menjelaskan satu prediksi tertentu. Kelebihannya, metode ini sederhana, tidak bergantung pada struktur model, dan langsung terkait dengan metrik kinerja yang digunakan.

II.6.4 Kriteria Perbandingan Metode XAI

Perbedaan cara kerja ketiga metode tersebut dirangkum pada Tabel II.3. Karena setiap metode dapat menghasilkan penjelasan yang berbeda untuk model yang sama, perbandingannya memerlukan kriteria yang jelas. Kriteria pertama adalah kestabilan, yaitu apakah penjelasan untuk data yang sama tetap serupa ketika metode dijalankan berulang (Zhang dkk. 2019) atau ketika input diubah sedikit (Alvarez-Melis & Jaakkola, 2018). Kriteria kedua adalah kesepakatan antarmetode, yaitu apakah ketiga metode menunjukkan urutan fitur penting yang serupa pada tingkat global, dengan penjelasan lokal SHAP dan LIME dirata-ratakan terlebih dahulu. Kriteria ketiga adalah waktu komputasi yang dibutuhkan setiap metode. Tinjauan Černevičienė dan Kabašinskas (2024) juga mencatat bahwa banyak penelitian keuangan menggabungkan beberapa metode XAI dalam satu kerangka penjelasan, sehingga perbandingan antarmetode menjadi relevan.

Tabel II.3 Perbandingan karakteristik metode XAI yang digunakan

Aspek	**SHAP**	**LIME**	***Permutation importance***
Cakupan	Lokal dan global	Lokal	Global
Ketergantungan model	TreeSHAP khusus model pohon, varian lain *model-agnostic*	*Model-agnostic*	*Model-agnostic*
Unsur acak	Tidak ada pada TreeSHAP	Sampel tiruan acak	Pengacakan nilai fitur
Satuan penjelasan	Satuan target (persen CAR)	Bobot model sederhana	Kenaikan kesalahan

II.7 Metrik Evaluasi dan Uji Signifikansi

II.7.1 Metrik Regresi

Kinerja prediksi besar CAR diukur menggunakan *mean absolute error* (MAE) dan *root mean squared error* (RMSE), seperti pada Persamaan II.20 dan Persamaan II.21, dengan n menyatakan jumlah data uji. MAE menyatakan rata-rata besar kesalahan dalam satuan yang sama dengan target, sehingga mudah diinterpretasikan sebagai rata-rata selisih persen antara CAR prediksi dan CAR aktual. Willmott dan Matsuura (2005) berpendapat bahwa MAE merupakan ukuran rata-rata kesalahan yang lebih alami dibandingkan RMSE, karena RMSE juga dipengaruhi oleh sebaran besarnya kesalahan. Meskipun demikian, RMSE tetap dilaporkan karena memberikan penalti lebih besar terhadap kesalahan yang besar. Hal ini relevan karena CAR dapat memiliki nilai ekstrem, misalnya pada berita kasus hukum besar.

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i| \tag{II.20}$$

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{II.21}$$

II.7.2 Ketepatan Arah dengan Zona Netral

Arah prediksi dibaca dari tanda nilai CAR yang diprediksi, sedangkan arah aktual ditentukan dari CAR aktual dengan zona netral pada Persamaan II.4. Sampel dengan CAR aktual di dalam zona netral tidak menunjukkan pergerakan yang berarti, sehingga tidak tepat apabila model dinilai benar atau salah dalam menebak arahnya. Karena itu, ketepatan arah dihitung hanya pada sampel yang CAR aktualnya berada di

luar zona netral, seperti pada Persamaan II.22, dengan S menyatakan himpunan sampel tersebut dan $\mathbb{1}[\cdot]$ bernilai satu apabila kondisi di dalamnya terpenuhi. Gagasan ini serupa dengan Amel-Zadeh dkk. (2020), yang menilai persentase ketepatan tanda prediksi untuk reaksi pasar dengan berbagai ambang besar reaksi. Ketepatan tanda pada seluruh sampel tanpa zona netral juga dilaporkan sebagai pelengkap.

$$DA = \frac{1}{|S|} \sum_{i \in S} \mathbb{1}\left[\text{sign}(\hat{y}_i) = \text{sign}(y_i)\right], \qquad S = \left\{ i : |y_i| > \hat{\sigma}_{\varepsilon_i} \sqrt{2} \right\} \tag{II.22}$$

II.7.3 Metrik Klasifikasi Jenis Peristiwa

Kualitas *classifier* jenis peristiwa yang digunakan untuk menghasilkan fitur diukur pada *test set* emas menggunakan accuracy dan F1-macro. Accuracy menyatakan proporsi prediksi yang benar, tetapi nilainya dapat menyesatkan ketika distribusi kelas tidak seimbang, misalnya ketika kategori kebijakan pemerintah jauh lebih jarang muncul dibandingkan laporan keuangan. Untuk itu, digunakan F1-macro, yaitu rata-rata F1 dari setiap kelas tanpa pembobotan berdasarkan jumlah data (Sokolova & Lapalme, 2009). F1 untuk kelas c merupakan rata-rata harmonik dari *precision* P_c dan *recall* R_c, seperti pada Persamaan II.23, dengan C menyatakan jumlah kelas.

$$F1_c = \frac{2 P_c R_c}{P_c + R_c}, \qquad \text{F1-macro} = \frac{1}{C} \sum_{c=1}^{C} F1_c \tag{II.23}$$

II.7.4 Uji Signifikansi Selisih Kinerja

Selisih metrik antara dua model pada satu data uji belum tentu menunjukkan perbedaan yang nyata, karena selisih tersebut dapat muncul akibat variasi sampel. Untuk membandingkan ketepatan arah dua model pada data uji yang sama, dapat digunakan uji McNemar (McNemar, 1947). Dietterich (1998) membandingkan beberapa uji statistik untuk membandingkan algoritma pembelajaran dan merekomendasikan uji McNemar untuk kondisi ketika model hanya dapat dilatih dan diuji satu kali. Statistik uji McNemar dengan koreksi kontinuitas ditunjukkan pada Persamaan II.24, dengan n_{01} menyatakan jumlah sampel yang arahnya salah ditebak oleh model pertama tetapi benar oleh model kedua, dan n_{10} menyatakan kebalikannya. Statistik ini mengikuti distribusi χ^2 dengan satu derajat kebebasan.

$$\chi^2 = \frac{\left(|n_{01} - n_{10}| - 1\right)^2}{n_{01} + n_{10}} \tag{II.24}$$

Uji McNemar hanya berlaku untuk perbandingan benar atau salah, sehingga tidak dapat digunakan untuk metrik seperti MAE dan RMSE. Untuk metrik tersebut, digunakan metode *bootstrap* (Efron, 1979). Pada metode ini, data uji diambil ulang secara acak dengan pengembalian sebanyak ratusan sampai ribuan kali, kemudian selisih metrik kedua model dihitung pada setiap sampel ulang. Distribusi selisih yang diperoleh digunakan untuk menyusun selang kepercayaan. Apabila selang kepercayaan tersebut tidak memuat nol, selisih kinerja kedua model dapat dianggap signifikan pada tingkat kepercayaan yang digunakan.

II.8 Penelitian Terkait

Penelitian terkait pada subbab ini dikelompokkan menjadi lima, yaitu penelitian berbasis berita di Indonesia, *event study* di BEI, penelitian yang menghubungkan peristiwa dari teks dengan *abnormal return*, penelitian yang membandingkan model untuk prediksi *return*, serta penelitian yang menggunakan *explainable AI* untuk prediksi saham. Pengelompokan ini digunakan untuk melihat komponen apa saja yang sudah dikerjakan oleh penelitian sebelumnya dan komponen apa yang belum.

II.8.1 Penelitian Berbasis Berita di Indonesia

Attar (2024) menggunakan IndoBERT untuk mengklasifikasikan sentimen 2.857 berita saham dan memperoleh akurasi 0,78. Hasil klasifikasi tersebut kemudian dikorelasikan dengan pergerakan harga per sektor, dengan korelasi Pearson tertinggi sebesar 0,389 pada sektor *basic materials*. Alamsyah dkk. (2025) menganalisis 192.582 berita keuangan Indonesia periode 2018 sampai 2023, mendeteksi perusahaan yang disebutkan dalam berita, dan menyusun jaringan kemunculan bersama antarperusahaan. Penelitian tersebut menemukan bahwa korelasi sentimen dengan harga meningkat dari 0,26 pada tingkat perusahaan menjadi 0,30 pada tingkat industri dan 0,43 pada klaster perusahaan yang sering muncul bersama dalam berita. Temuan ini menunjukkan bahwa pengelompokan berdasarkan industri dan kemunculan bersama dapat memperjelas hubungan antara berita dan harga.

Kusuma dkk. (2026) menggabungkan sentimen IndoBERT dari 9.819 berita CNBC Indonesia dengan data harga untuk mengklasifikasikan tren harga lima emiten LQ45 menggunakan LSTM. Berbeda dengan dua penelitian sebelumnya yang bersifat korelasional, penelitian ini sudah berbentuk model prediksi. Sementara itu, Elli (2025) menguji hubungan sentimen 23.406 *tweet* dengan *abnormal return* saham IDX30 pada periode Juli sampai Desember 2023 menggunakan uji kausalitas Granger. Penelitian tersebut sudah menggunakan *abnormal return* sebagai target, tetapi sumber

datanya berupa *tweet* dan analisisnya bersifat statistik agregat. Secara umum, keempat penelitian tersebut masih menggunakan sentimen sebagai satu-satunya informasi dari teks, dan belum ada yang mengoreksi pengaruh sektor maupun menjelaskan kontribusi fitur pada tingkat berita.

II.8.2 *Event Study* di Bursa Efek Indonesia

Event study di BEI umumnya meneliti satu atau dua jenis peristiwa yang ditentukan oleh peneliti. Fauzi dan Mutasowifin (2021) meneliti dampak *stock split* terhadap *abnormal return* pada 34 emiten periode 2015 sampai 2019 menggunakan uji-t. Penelitian tersebut menemukan bahwa pada sampel gabungan terdapat tiga dari sebelas hari pengamatan yang memiliki *abnormal return* signifikan, dan bahwa pengaruhnya berbeda antarsektor industri. Sudirman dkk. (2026) meneliti pengumuman *right issue* dan *stock split* pada periode 2022 sampai 2024, dengan *abnormal return* dihitung sebagai selisih *return* saham terhadap *return* IHSG.

Penelitian *event study* tersebut memberikan bukti bahwa peristiwa korporasi tertentu dapat diikuti oleh *abnormal return* di BEI. Namun, peristiwa dan tanggalnya ditentukan secara manual, sehingga pendekatan tersebut tidak dapat langsung digunakan untuk menilai berita baru. Model *return* normal yang digunakan juga belum mengoreksi pengaruh sektor, padahal temuan Fauzi dan Mutasowifin (2021) menunjukkan bahwa reaksi harga dapat berbeda antarsektor. Selain itu, setiap penelitian hanya membahas jenis peristiwa yang sangat terbatas, sehingga perbandingan dampak antarjenis peristiwa belum dapat dilakukan dalam satu kerangka yang sama.

II.8.3 Peristiwa dari Teks dan *Abnormal Return*

Luss dan d'Aspremont (2015) memprediksi *return* intrahari dari berita menggunakan klasifikasi teks dengan *multiple kernel learning* yang menggabungkan teks dan *return* historis. *Abnormal return* pada penelitian tersebut didefinisikan sebagai *return* yang nilai absolutnya melewati ambang tertentu, bukan *return* yang dikoreksi pasar. Temuannya menunjukkan bahwa arah *return* tidak dapat diprediksi menggunakan teks maupun *return* historis, tetapi besarnya pergerakan dapat diprediksi, dan fitur teks memberikan kinerja yang lebih baik dibandingkan *return* historis saja. Temuan ini menjadi dasar penelitian ini untuk mengevaluasi model tidak hanya dari ketepatan arah, tetapi juga dari estimasi besar *abnormal return*.

Zhou dkk. (2021) menyusun dataset EDT yang berisi 9.721 artikel berita dengan label peristiwa pada tingkat token serta 303.893 artikel berita dengan stempel waktu hingga menit dan label harga saham. Strategi *trading* yang dibangun dari detektor peristiwa mereka mengungguli seluruh pembanding dari sisi *winning rate*, *ex-*

cess return terhadap pasar, dan rata-rata *return* per transaksi. Dogra dkk. (2022) mengklasifikasikan berita perbankan dan pemerintah India secara otomatis menggunakan *embedding* DistilBERT dengan Random Forest dan memperoleh akurasi 94%, kemudian menghitung CAR untuk kelompok bank swasta dan bank pemerintah. Penelitian tersebut menemukan bahwa berita negatif berpengaruh terhadap bank swasta selama satu bulan dan terhadap bank pemerintah selama dua bulan. Namun, kelas yang digunakan masih berupa sentimen, dan CAR dihitung per kelompok, bukan diprediksi per berita.

Penelitian yang lebih baru memanfaatkan *large language model* (LLM) untuk memberi label peristiwa dalam skala besar. Kargarzadeh dkk. (2026) menggunakan LLM yang didistilasi menjadi *classifier* untuk memberi 17 label peristiwa dan lima atribut pada 4,57 juta artikel berita mengenai sekitar 3.000 saham Amerika Serikat periode 2023 sampai 2026. Hasilnya menunjukkan bahwa pergerakan harga terkonsentrasi sebelum dan pada saat publikasi berita, serta pasar bereaksi kurang terhadap berita fundamental yang terkuantifikasi seperti laba dan panduan kinerja. Dolphin dkk. (2026) memberi label 119 jenis peristiwa pada 292.984 laporan 8-K periode 2022 sampai 2026 dan menunjukkan bahwa taksonomi yang lebih rinci dapat membedakan peristiwa yang secara ekonomi berbeda walaupun berada pada kode item yang sama. Kedua penelitian tersebut mendukung premis bahwa jenis peristiwa berkaitan dengan besar *abnormal return*. Di sisi lain, Gao dkk. (2025) menemukan bahwa akurasi prediksi LLM dapat meningkat secara semu karena model sudah mengetahui hasil yang terjadi pada periode data pelatihannya, dan kecenderungan tersebut hampir hilang setelah batas waktu data pelatihan. Risiko ini menjadi salah satu pertimbangan penelitian ini untuk tidak menggunakan LLM generatif.

II.8.4 Perbandingan Model untuk Prediksi *Return*

Sejumlah penelitian telah membandingkan model *machine learning* untuk memprediksi *return* saham. Gu dkk. (2020) membandingkan model linear, model reduksi dimensi, model berbasis pohon, dan *neural network* untuk memprediksi *return* saham Amerika Serikat, dan menemukan bahwa model berbasis pohon dan *neural network* memberikan hasil terbaik karena mampu menangkap interaksi nonlinear antarprediktor. Krauss dkk. (2017) membandingkan *deep neural network*, *gradient-boosted trees*, dan Random Forest untuk strategi *statistical arbitrage* pada saham S&P 500, sedangkan Fischer dan Krauss (2018) menemukan bahwa LSTM mengungguli Random Forest, *deep neural network*, dan *logistic regression* dalam memprediksi arah pergerakan saham S&P 500, walaupun keuntungannya menurun setelah 2010.

Untuk target yang lebih dekat dengan penelitian ini, Amel-Zadeh dkk. (2020) memprediksi tanda dan besar *abnormal return* di sekitar pengumuman laba berdasarkan data laporan keuangan. Penelitian tersebut menemukan bahwa Random Forest dan *recurrent neural network* mengungguli *deep neural network* serta model linear seperti OLS dan Lasso, dengan model nonlinear relatif lebih baik untuk reaksi pasar yang ekstrem dan model linear relatif lebih baik untuk reaksi yang moderat. Schnaubelt dan Seifert (2020) memanfaatkan lebih dari 45.000 pengumuman laba emiten S&P 1500 dan menemukan bahwa Random Forest menghasilkan *abnormal return* yang lebih tinggi dibandingkan tiga model pembanding. Penelitian-penelitian tersebut menunjukkan pentingnya membandingkan beberapa model sebelum menyimpulkan model terbaik. Namun, fitur yang digunakan berupa data keuangan atau harga di pasar Amerika Serikat, bukan jenis peristiwa dari berita berbahasa Indonesia.

II.8.5 *Explainable AI* untuk Prediksi Saham

Ruan dan Jiang (2025) menggabungkan sentimen dari judul berita yang diekstraksi menggunakan FinBERT dengan indikator teknikal dan statistik, kemudian menggunakan XGBoost untuk memprediksi pergerakan harga jangka pendek saham S&P 500 periode 2018 sampai 2023. Model tersebut mengungguli *baseline* yang hanya menggunakan indikator teknikal maupun sentimen berbasis kamus dari sisi AUC, F1, dan simulasi profitabilitas *trading*, dan SHAP digunakan untuk menguraikan setiap prediksi menjadi kontribusi fitur. Gite dkk. (2021) menggunakan LIME untuk menjelaskan prediksi harga saham berbasis LSTM yang memanfaatkan sentimen berita. Pada tingkat yang lebih luas, Černevičienė dan Kabašinskas (2024) meninjau 138 artikel XAI di bidang keuangan periode 2005 sampai 2022 dan menemukan bahwa prediksi harga saham termasuk tiga tugas yang paling sering dijelaskan, dengan *feature importance*, SHAP, dan metode berbasis aturan sebagai metode yang paling banyak digunakan. Kedua penelitian prediksi saham tersebut masing-masing hanya memakai satu metode XAI, dengan fitur berita berupa sentimen dan target berupa pergerakan harga, sehingga kontribusi berita yang dijelaskan masih bercampur dengan pergerakan pasar. Berdasarkan penelusuran literatur yang telah dilakukan, belum ditemukan penelitian yang membandingkan metode XAI pada target *abnormal return* yang dikoreksi pengaruh sektor.

II.8.6 Posisi Penelitian

Perbandingan komponen penelitian terdahulu dengan penelitian ini dirangkum pada Tabel II.4. Kolom pada tabel tersebut menunjukkan apakah penelitian menggunakan data pasar Indonesia, mengekstraksi jenis peristiwa secara otomatis, menggunakan

abnormal return sebagai target, mengoreksi pengaruh sektor, berupa model prediksi dan bukan analisis korelasi atau uji statistik agregat, serta menyediakan penjelasan prediksi dengan metode XAI.

Tabel II.4 Perbandingan komponen penelitian terdahulu dengan penelitian ini

Penelitian	**IDN**	**JP**	**AR**	**KS**	**PB**	**XAI**
Attar (2024)	✓	–	–	–	–	–
Alamsyah dkk. (2025)	✓	–	–	–	–	–
Kusuma dkk. (2026)	✓	–	–	–	✓	–
Elli (2025)	✓	–	✓	–	–	–
Fauzi & Mutasowifin (2021)	✓	–	✓	–	–	–
Sudirman dkk. (2026)	✓	–	✓	–	–	–
Dogra dkk. (2022)	–	–	✓	–	–	–
Amel-Zadeh dkk. (2020)	–	–	✓	–	✓	–
Luss & d'Aspremont (2015)	–	–	–	–	✓	–
Ding dkk. (2015)	–	✓	–	–	✓	–
Zhou dkk. (2021)	–	✓	–	–	✓	–
Kargarzadeh dkk. (2026)	–	✓	✓	–	–	–
Dolphin dkk. (2026)	–	✓	✓	–	–	–
Gite dkk. (2021)	–	–	–	–	✓	✓
Ruan & Jiang (2025)	–	–	–	–	✓	✓
Penelitian ini	✓	✓	✓	✓	✓	✓

IDN: pasar atau berita Indonesia; JP: jenis peristiwa diekstraksi otomatis dari teks; AR: target berupa *abnormal return* yang dikoreksi pasar; KS: koreksi indeks sektor; PB: berupa model prediksi, bukan analisis korelasi atau uji statistik agregat; XAI: penjelasan prediksi dengan metode XAI.

Berdasarkan Tabel II.4, penelitian di Indonesia sudah mencakup deteksi emiten dari berita, analisis sentimen, dan pengukuran *abnormal return*, tetapi komponen-komponen tersebut belum digabungkan. Penelitian yang memanfaatkan berita masih berfokus pada sentimen dengan target harga, sedangkan penelitian yang mengukur *abnormal return* masih menentukan peristiwa secara manual atau menggunakan *tweet* sebagai sumber data. Penelitian global sudah mengekstraksi jenis peristiwa secara otomatis dan mengukur *abnormal return*, tetapi berfokus pada pasar Amerika Serikat, sebagian besar memanfaatkan LLM, dan tidak mengoreksi pengaruh sektor. Penelitian yang membandingkan model prediksi umumnya menggunakan fitur keuangan atau harga, sedangkan penelitian prediksi saham yang menggunakan XAI, seperti Ruan dan Jiang (2025) dan Gite dkk. (2021), masing-masing hanya memakai satu metode dengan fitur sentimen dan target harga.

Penelitian ini mengisi celah tersebut untuk berita berbahasa Indonesia dan emiten IDX80 melalui tiga hal. Pertama, target yang digunakan adalah $CAR[0, +1]$ yang dikoreksi IHSG dan indeks sektoral IDX-IC berdasarkan model dua faktor. Kedua,

jenis peristiwa yang diekstraksi secara otomatis dari berita digunakan sebagai fitur utama, di samping sentimen dan kondisi pasar sebelum berita terbit. Ketiga, empat model regresi dan tiga metode XAI dibandingkan pada target tersebut, sehingga dapat diketahui model yang paling sesuai serta metode penjelasan yang paling andal. Dengan kombinasi tersebut, penelitian ini memberikan dasar empiris dalam memilih model dan metode penjelasan untuk memprediksi dampak khusus berita terhadap emiten setelah pengaruh pasar dan sektor dikendalikan.

BAB III

ANALISIS MASALAH

III.1 Analisis Kondisi Saat Ini

Menurut Laudon dan Laudon (2020), gambarkan terlebih dahulu model konseptual sistem yang ada saat ini. Model konseptual ini berisi berbagai komponen atau subsitem dan interaksi antarsubsistem tersebut. Setelah itu, berikan penjelasan tentang masalah yang ada pada sistem tersebut. Paragraf berikut berisi contoh penjabaran masalah sistem informasi fasilitas kesehatan untuk pasien (Pressman, 2019).

III.2 Analisis Kebutuhan

Quisque ullamcorper placerat ipsum. Cras nibh. Morbi vel justo vitae lacus tincidunt ultrices. Lorem ipsum dolor sit amet, consectetuer adipiscing elit. In hac habitasse platea dictumst. Integer tempus convallis augue. Etiam facilisis. Nunc elementum fermentum wisi. Aenean placerat. Ut imperdiet, enim sed gravida sollicitudin, felis odio placerat quam, ac pulvinar elit purus eget enim. Nunc vitae tortor. Proin tempus nibh sit amet nisl. Vivamus quis tortor vitae risus porta vehicula.

III.2.1 Identifikasi Masalah Pengguna

Fusce mauris. Vestibulum luctus nibh at lectus. Sed bibendum, nulla a faucibus semper, leo velit ultricies tellus, ac venenatis arcu wisi vel nisl. Vestibulum diam. Aliquam pellentesque, augue quis sagittis posuere, turpis lacus congue quam, in hendrerit risus eros eget felis. Maecenas eget erat in sapien mattis porttitor. Vestibulum porttitor. Nulla facilisi. Sed a turpis eu lacus commodo facilisis. Morbi fringilla, wisi in dignissim interdum, justo lectus sagittis dui, et vehicula libero dui cursus dui. Mauris tempor ligula sed lacus. Duis cursus enim ut augue. Cras ac magna. Cras nulla. Nulla egestas. Curabitur a leo. Quisque egestas wisi eget nunc. Nam feugiat lacus vel est. Curabitur consectetuer.

III.2.2 Kebutuhan Fungsional

Suspendisse vel felis. Ut lorem lorem, interdum eu, tincidunt sit amet, laoreet vitae, arcu. Aenean faucibus pede eu ante. Praesent enim elit, rutrum at, molestie

non, nonummy vel, nisl. Ut lectus eros, malesuada sit amet, fermentum eu, sodales cursus, magna. Donec eu purus. Quisque vehicula, urna sed ultricies auctor, pede lorem egestas dui, et convallis elit erat sed nulla. Donec luctus. Curabitur et nunc. Aliquam dolor odio, commodo pretium, ultricies non, pharetra in, velit. Integer arcu est, nonummy in, fermentum faucibus, egestas vel, odio.

III.2.3 Kebutuhan Nonfungsional

Sed commodo posuere pede. Mauris ut est. Ut quis purus. Sed ac odio. Sed vehicula hendrerit sem. Duis non odio. Morbi ut dui. Sed accumsan risus eget odio. In hac habitasse platea dictumst. Pellentesque non elit. Fusce sed justo eu urna porta tincidunt. Mauris felis odio, sollicitudin sed, volutpat a, ornare ac, erat. Morbi quis dolor. Donec pellentesque, erat ac sagittis semper, nunc dui lobortis purus, quis congue purus metus ultricies tellus. Proin et quam. Class aptent taciti sociosqu ad litora torquent per conubia nostra, per inceptos hymenaeos. Praesent sapien turpis, fermentum vel, eleifend faucibus, vehicula eu, lacus.

III.3 Analisis Pemilihan Solusi

III.3.1 Alternatif Solusi

Pellentesque habitant morbi tristique senectus et netus et malesuada fames ac turpis egestas. Donec odio elit, dictum in, hendrerit sit amet, egestas sed, leo. Praesent feugiat sapien aliquet odio. Integer vitae justo. Aliquam vestibulum fringilla lorem. Sed neque lectus, consectetuer at, consectetuer sed, eleifend ac, lectus. Nulla facilisi. Pellentesque eget lectus. Proin eu metus. Sed porttitor. In hac habitasse platea dictumst. Suspendisse eu lectus. Ut mi mi, lacinia sit amet, placerat et, mollis vitae, dui. Sed ante tellus, tristique ut, iaculis eu, malesuada ac, dui. Mauris nibh leo, facilisis non, adipiscing quis, ultrices a, dui.

III.3.2 Analisis Penentuan Solusi

Morbi luctus, wisi viverra faucibus pretium, nibh est placerat odio, nec commodo wisi enim eget quam. Quisque libero justo, consectetuer a, feugiat vitae, porttitor eu, libero. Suspendisse sed mauris vitae elit sollicitudin malesuada. Maecenas ultricies eros sit amet ante. Ut venenatis velit. Maecenas sed mi eget dui varius euismod. Phasellus aliquet volutpat odio. Vestibulum ante ipsum primis in faucibus orci luctus et ultrices posuere cubilia Curae; Pellentesque sit amet pede ac sem eleifend consectetuer. Nullam elementum, urna vel imperdiet sodales, elit ipsum pharetra ligula, ac pretium ante justo a nulla. Curabitur tristique arcu eu metus. Vestibulum lectus. Proin mauris. Proin eu nunc eu urna hendrerit faucibus. Aliquam auctor, pede consequat laoreet varius, eros tellus scelerisque quam, pellentesque hendrerit

ipsum dolor sed augue. Nulla nec lacus.

BAB IV

DESAIN KONSEP SOLUSI

Ilustrasikan desain konsep solusi dalam bentuk model konseptual dan penjelasan secara ringkas, beserta perbedaannya dengan sistem saat ini. Ilustrasi harus dapat dibandingkan (*before* and *after*). Karena masih berupa proposal, bab ini hanya berisi gambar desain konsep solusi tersebut dan penjelasan perbandingannya dengan gambar sistem yang ada saat ini (yang tergambar di awal Bab III).

BAB V

RENCANA SELANJUTNYA

Jelaskan secara detail langkah-langkah rencana selanjutnya, hal-hal yang diperlukan atau akan disiapkan, dan risiko dan mitigasinya, yang meliputi:

1. Rencana implementasi, termasuk alat dan bahan yang diperlukan, lingkungan, konfigurasi, biaya, dan sebagainya.
2. Desain pengujian dan evaluasi, misalnya metode verifikasi dan validasi.
3. Analisis risiko dan mitigasi, misalnya tindakan selanjutnya jika ada yang tidak berjalan sesuai rencana.

DAFTAR PUSTAKA

Alamsyah, A., Ramadhani, D. P., Kristanti, F. T., Nasution, A. H., Mohamad, M. S. b., Sokkalingam, R., Widiyanesti, S., & Saputra, M. A. A. (2025). Deciphering news sentiment and stock price relationships in Indonesian companies: An AI-based exploration of industry affiliation and news co-occurrence. *Discover Artificial Intelligence*, *5*(1), Article 87. https://doi.org/10.1007/s44163-025-00350-5

Alvarez-Melis, D., & Jaakkola, T. S. (2018). On the robustness of interpretability methods. https://doi.org/10.48550/arXiv.1806.08049

Amel-Zadeh, A., Calliess, J.-P., Kaiser, D., & Roberts, S. (2020). Machine learning-based financial statement analysis. *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.3520684

Arsenault, P.-D., Wang, S., & Patenaude, J.-M. (2025). A survey of explainable artificial intelligence (XAI) in financial time series forecasting. *ACM Computing Surveys*, *57*(10), 1–37. https://doi.org/10.1145/3729531

Attar, R. N. (2024). *Penggunaan IndoBERT untuk klasifikasi sentimen berita saham dan analisis korelasi dengan pergerakan harga di Bursa Efek Indonesia* [Tugas Akhir]. Institut Teknologi Bandung. https://digilib.itb.ac.id/gdl/view_data/penggunaan-indobert-untuk-klasifikasi-sentimen-berita-saham-dan-analisis-korelasi-dengan-pergerakan-harga-di-bursa-efek-indonesia

Ball, R., & Brown, P. (1968). An empirical evaluation of accounting income numbers. *Journal of Accounting Research*, *6*(2), 159–178. https://doi.org/10.2307/2490232

Breiman, L. (2001). Random forests. *Machine Learning*, *45*(1), 5–32. https://doi.org/10.1023/A:1010933404324

Brown, S. J., & Warner, J. B. (1980). Measuring security price performance. *Journal of Financial Economics*, *8*(3), 205–258. https://doi.org/10.1016/0304-405X(80)90002-1

Brown, S. J., & Warner, J. B. (1985). Using daily stock returns: The case of event studies. *Journal of Financial Economics*, *14*(1), 3–31. https://doi.org/10.1016/0304-405X(85)90042-X

Bursa Efek Indonesia. (2024, March 27). *Panduan dan metodologi indeks IDX80, LQ45 dan IDX30 (lampiran pengumuman BEI no. peng-00058/BEI.POP/03-2024)*. Retrieved October 16, 2026, from https://www.idx.id/media/3lvd1yk1/lampiran-panduan-metodologi-indeks-idx80-lq45-dan-idx30.pdf

Černevičienė, J., & Kabašinskas, A. (2024). Explainable artificial intelligence (XAI) in finance: A systematic literature review. *Artificial Intelligence Review*, *57*(8). https://doi.org/10.1007/s10462-024-10854-8

Chan, W. S. (2003). Stock price reaction to news and no-news: Drift and reversal after headlines. *Journal of Financial Economics*, *70*(2), 223–260. https://doi.org/10.1016/S0304-405X(03)00146-6

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794. https://doi.org/10.1145/2939672.2939785

Cohen, J. (1960). A coefficient of agreement for nominal scales. *Educational and Psychological Measurement*, *20*(1), 37–46. https://doi.org/10.1177/001316446002000104

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of deep bidirectional transformers for language understanding. *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers)*, 4171–4186. https://doi.org/10.18653/v1/N19-1423

Dietterich, T. G. (1998). Approximate statistical tests for comparing supervised classification learning algorithms. *Neural Computation*, *10*(7), 1895–1923. https://doi.org/10.1162/089976698300017197

Ding, X., Zhang, Y., Liu, T., & Duan, J. (2015). Deep learning for event-driven stock prediction. *Proceedings of the 24th International Joint Conference on Artificial Intelligence (IJCAI 2015)*, 2327–2333. https://www.ijcai.org/Proceedings/15/Papers/329.pdf

Dogra, V., Alharithi, F. S., Álvarez, R. M., Singh, A., & Qahtani, A. M. (2022). NLP-based application for analyzing private and public banks stocks reaction to news events in the Indian stock exchange. *Systems*, *10*(6), Article 233. https://doi.org/10.3390/systems10060233

Dolphin, R., Dursun, J., Blankenship, J., Adams, K., & Pike, Q. (2026). Grounded event extraction from SEC 8-K filings with a fine-grained taxonomy. https://doi.org/10.48550/arXiv.2607.08346

Efron, B. (1979). Bootstrap methods: Another look at the jackknife. *The Annals of Statistics*, *7*(1), 1–26. https://doi.org/10.1214/aos/1176344552

Elli, F. G. (2025). Impact Twitter (X) sentiment to abnormal return IDX30 stocks. *Quantitative Economics and Management Studies*, *6*(3), 470–482. https://doi.org/10.35877/454RI.qems4003

Fama, E. F. (1970). Efficient capital markets: A review of theory and empirical work. *The Journal of Finance*, *25*(2), 383–417. https://doi.org/10.2307/2325486

Fama, E. F., Fisher, L., Jensen, M. C., & Roll, R. (1969). The adjustment of stock prices to new information. *International Economic Review*, *10*(1), 1–21. https://doi.org/10.2307/2525569

Fauzi, A. A., & Mutasowifin, A. (2021). Dampak stock split terhadap abnormal return pada emiten terdaftar di Bursa Efek Indonesia. *Jurnal Dinamika Ekonomi Pembangunan*, *4*(2), 75–83. https://doi.org/10.33005/jdep.v4i2.302

Fischer, T., & Krauss, C. (2018). Deep learning with long short-term memory networks for financial market predictions. *European Journal of Operational Research*, *270*(2), 654–669. https://doi.org/10.1016/j.ejor.2017.11.054

Fisher, A., Rudin, C., & Dominici, F. (2019). All models are wrong, but many are useful: Learning a variable's importance by studying an entire class of prediction models simultaneously. *Journal of Machine Learning Research*, *20*(177), 1–81. https://www.jmlr.org/papers/v20/18-760.html

Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. *The Annals of Statistics*, *29*(5), 1189–1232. https://doi.org/10.1214/aos/1013203451

Gao, Z., Jiang, W., & Yan, Y. (2025). Detecting lookahead bias in LLM forecasts. https://doi.org/10.48550/arXiv.2512.23847

Gite, S., Khatavkar, H., Kotecha, K., Srivastava, S., Maheshwari, P., & Pandey, N. (2021). Explainable stock prices prediction from financial news articles using sentiment analysis. *PeerJ Computer Science*, *7*, Article e340. https://doi.org/10.7717/peerj-cs.340

Grinsztajn, L., Oyallon, E., & Varoquaux, G. (2022). Why do tree-based models still outperform deep learning on typical tabular data? *Advances in Neural Information Processing Systems 35*, 507–520. https://doi.org/10.52202/068431-0037

Gu, S., Kelly, B., & Xiu, D. (2020). Empirical asset pricing via machine learning. *The Review of Financial Studies*, *33*(5), 2223–2273. https://doi.org/10.1093/rfs/hhaa009

Guennioui, O., Chiadmi, D., & Amghar, M. (2024). Global stock price forecasting during a period of market stress using LightGBM. *International Journal of Computing and Digital Systems*, *15*(1), 19–27. https://doi.org/10.12785/ijcds/150103

Intan, K. (2021, January 21). *Mengenal klasifikasi indeks sektoral berdasarkan IDX-IC*. Kontan.co.id. Retrieved October 16, 2026, from https://investasi.kontan.co.id/news/mengenal-klasifikasi-indeks-sektoral-berdasarkan-idx-ic

Joachims, T. (1998). Text categorization with support vector machines: Learning with many relevant features. *Machine Learning: ECML-98*, *1398*, 137–142. https://doi.org/10.1007/BFb0026683

Kargarzadeh, A., Khaledian, N., Parvini, N., Ghatak, S., & Khaledian, A. (2026). Buy the rumor, sell the news: When is news priced in? https://doi.org/10.48550/arXiv.2608.14014

Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T.-Y. (2017). LightGBM: A highly efficient gradient boosting decision tree. *Advances in Neural Information Processing Systems 30*, 3146–3154.

Kearney, C., & Liu, S. (2014). Textual sentiment in finance: A survey of methods and models. *International Review of Financial Analysis*, *33*, 171–185. https://doi.org/10.1016/j.irfa.2014.02.006

Koto, F., Rahimi, A., Lau, J. H., & Baldwin, T. (2020). IndoLEM and IndoBERT: A benchmark dataset and pre-trained language model for Indonesian NLP. *Proceedings of the 28th International Conference on Computational Linguistics*, 757–770. https://doi.org/10.18653/v1/2020.coling-main.66

Krauss, C., Do, X. A., & Huck, N. (2017). Deep neural networks, gradient-boosted trees, random forests: Statistical arbitrage on the S&P 500. *European Journal of Operational Research*, *259*(2), 689–702. https://doi.org/10.1016/j.ejor.2016.10.031

Kusuma, F. W., Kusumadinata, A. A., & Putra, H. A. A. (2026). Analisis sentimen berita keuangan berbahasa Indonesia menggunakan IndoBERT dan LSTM untuk klasifikasi tren harga saham pada lima emiten blue chip LQ45. *Jurnal Ilmu Komputer dan Sistem Informasi*, *5*(2), 462–473. https://doi.org/10.70340/jirsi.v5i2.407

Landis, J. R., & Koch, G. G. (1977). The measurement of observer agreement for categorical data. *Biometrics*, *33*(1), 159–174. https://doi.org/10.2307/2529310

Laudon, K. C., & Laudon, J. P. (2020). *Sistem informasi manajemen*. Pearson Education.

Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N., & Lee, S.-I. (2020). From local explanations to global understanding with explainable AI for trees. *Nature Machine Intelligence*, *2*(1), 56–67. https://doi.org/10.1038/s42256-019-0138-9

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems 30*, 4765–4774.

Luss, R., & d'Aspremont, A. (2015). Predicting abnormal returns from news using text classification. *Quantitative Finance*, *15*(6), 999–1012. https://doi.org/10.1080/14697688.2012.672762

MacKinlay, A. C. (1997). Event studies in economics and finance. *Journal of Economic Literature*, *35*(1), 13–39.

Maharani, N. P. I., Yustiawan, Y., Rochim, F. C., & Purwarianti, A. (2023). Domain-specific language model post-training for Indonesian financial NLP. *2023 International Conference on Electrical Engineering and Informatics (ICEEI)*, 1–6. https://doi.org/10.1109/ICEEI59426.2023.10346625

McNemar, Q. (1947). Note on the sampling error of the difference between correlated proportions or percentages. *Psychometrika*, *12*(2), 153–157. https://doi.org/10.1007/BF02295996

Pagliaro, A. (2026). Regime-aware LightGBM for stock market forecasting: A validated walk-forward framework with statistical rigor and explainable AI analysis. *Electronics*, *15*(6), Article 1334. https://doi.org/10.3390/electronics15061334

Pressman, R. S. (2019). *Rekayasa perangkat lunak: Pendekatan praktisi*. McGraw-Hill Education.

Ratner, A., Bach, S. H., Ehrenberg, H., Fries, J., Wu, S., & Ré, C. (2017). Snorkel: Rapid training data creation with weak supervision. *Proceedings of the VLDB Endowment*, *11*(3), 269–282. https://doi.org/10.14778/3157794.3157797

Ribeiro, M. T., Singh, S., & Guestrin, C. (2016). "Why should I trust you?": Explaining the predictions of any classifier. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 1135–1144. https://doi.org/10.1145/2939672.2939778

Ruan, L., & Jiang, H. (2025). Stock price prediction using FinBERT-enhanced sentiment with SHAP explainability and differential privacy. *Mathematics*, *13*(17), Article 2747. https://doi.org/10.3390/math13172747

Schnaubelt, M., & Seifert, O. (2020). Valuation ratios, surprises, uncertainty or sentiment: How does financial machine learning predict returns from earnings announcements? *SSRN Electronic Journal*. https://doi.org/10.2139/ssrn.3577132

Shaid, N. J. (2025, April 14). *Apa itu auto rejection: Penjelasan ARA dan ARB di Bursa Efek Indonesia*. Kompas.com. Retrieved October 16, 2026, from https://money.kompas.com/read/2025/04/14/225136426/apa-itu-auto-rejection-penjelasan-ara-dan-arb-di-bursa-efek-indonesia

Shapley, L. S. (1953). A value for n-person games. Dalam H. W. Kuhn & A. W. Tucker (Penyunting), *Contributions to the theory of games, volume II* (pp. 307–317). Princeton University Press. https://doi.org/10.1515/9781400881970-018

Shwartz-Ziv, R., & Armon, A. (2022). Tabular data: Deep learning is not all you need. *Information Fusion*, *81*, 84–90. https://doi.org/10.1016/j.inffus.2021.11.011

Sidik, S. (2021, January 25). *Wow! saat ini bursa ri punya indeks techno*. CNBC Indonesia. Retrieved October 16, 2026, from https://www.cnbcindonesia.com/market/20210125161826-17-218577/wow-saat-ini-bursa-ri-punya-indeks-techno

Sokolova, M., & Lapalme, G. (2009). A systematic analysis of performance measures for classification tasks. *Information Processing & Management*, *45*(4), 427–437. https://doi.org/10.1016/j.ipm.2009.03.002

Spärck Jones, K. (1972). A statistical interpretation of term specificity and its application in retrieval. *Journal of Documentation*, *28*(1), 11–21. https://doi.org/10.1108/eb026526

Sudirman, M. D., Choiriyah, U., & Rizkia, A. A. (2026). Analisis pengaruh pengumuman right issue dan stock split terhadap abnormal return saham periode 2022–2024. *Journal of Economic, Bussines and Accounting (COSTING)*, *9*(1). https://doi.org/10.31539/3gct5f07

Tetlock, P. C. (2007). Giving content to investor sentiment: The role of media in the stock market. *The Journal of Finance*, *62*(3), 1139–1168. https://doi.org/10.1111/j.1540-6261.2007.01232.x

Tian, L., Feng, L., Yang, L., & Guo, Y. (2022). Stock price prediction based on LSTM and LightGBM hybrid model. *The Journal of Supercomputing*, *78*(9), 11768–11793. https://doi.org/10.1007/s11227-022-04326-5

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems 30*, 5998–6008.

Wilie, B., Vincentio, K., Winata, G. I., Cahyawijaya, S., Li, X., Lim, Z. Y., Soleman, S., Mahendra, R., Fung, P., Bahar, S., & Purwarianti, A. (2020). IndoNLU: Benchmark and resources for evaluating Indonesian natural language understanding. *Proceedings of the 1st Conference of the Asia-Pacific Chapter of the Association for Computational Linguistics and the 10th International Joint Conference on Natural Language Processing*, 843–857. https://doi.org/10.18653/v1/2020.aacl-main.85

Willmott, C. J., & Matsuura, K. (2005). Advantages of the mean absolute error (MAE) over the root mean square error (RMSE) in assessing average model performance. *Climate Research*, *30*, 79–82. https://doi.org/10.3354/cr030079

Xiang, B. (1993). The choice of return-generating models and cross-sectional dependence in event studies. *Contemporary Accounting Research*, *9*(2), 365–394. https://doi.org/10.1111/j.1911-3846.1993.tb00887.x

Zhang, Y., Song, K., Sun, Y., Tan, S., & Udell, M. (2019). "Why should you trust my explanation?" Understanding uncertainty in LIME explanations. https://doi.org/10.48550/arXiv.1904.12991

Zhou, Z., Ma, L., & Liu, H. (2021). Trade the event: Corporate events detection for news-based event-driven trading. *Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021*, 2114–2124. https://doi.org/10.18653/v1/2021.findings-acl.186

LAMPIRAN A

SOURCE CODE

A.1 Perangkat Lunak untuk Akuisisi Data dari Sensor Ultrasonik

Listing A.1 Binary search code

```
% -- Example of pseudocode and source code listing --
% -- Gunakan minipage agar listing tidak terpotong ke halaman
   berikutnya --



\begin{minipage}{\textwidth}
\begin{lstlisting}[caption={Iterative binary search in Python},
   label={lst:binary_iter}, frame=single, captionpos=t, language=
   Python]
def binary_search(arr, target):
    """
    Performs binary search on a sorted array.

    Args:
        arr: A sorted list of elements
        target: The element to search for

    Returns:
        Index of target if found, -1 otherwise
    """
    left = 0
    right = len(arr) - 1

    while left <= right:
        mid = (left + right) // 2

        if arr[mid] == target:
            return mid
        elif arr[mid] < target:
            left = mid + 1
        else:
```

```
            right = mid - 1

    return -1


\end{lstlisting}
\end{minipage}
```

A.2 Perangkat Lunak untuk Pengolahan Data Akuisisi dan Visualisasi Hasil Pengukuran Jarak

asdjfkjashdkjfas